Operační systémy

IOS 2020/2021

Tomáš Vojnar

vojnar@fit.vutbr.cz

Vysoké učení technické v Brně
Fakulta informačních technologií
Božetěchova 2, 612 66 Brno

❖ Tyto slajdy jsou určeny pro studenty předmětu IOS na FIT VUT. Obsahují základní popis vývoje, struktury a vlastností operačních systémů se zaměřením na systém UNIX.

❖ Předpokládají se základní znalosti programování a přehled základních pojmů z oblasti počítačů.

❖ Obsah slajdů může být v některých případech stručný, podrobnější informace jsou součástí výkladu: Velmi silně se předpokládá účast na přednáškách a doporučuje se vytvářet si poznámky.

❖ Předpokládá se také aktivní přístup ke studiu, vyhledávání informací na Internetu či v literatuře (jimiž doporučuji si případně doplnit obsah slajdů), konfrontace obsahu slajdů s jinými zdroji a také praktické experimentování s GNU/Linuxem (či FreeBSD nebo podobnými UNIXovými systémy).

Motivace

❖ Operační systém je významnou částí prakticky všech výpočetních systémů, jež typicky zahrnují:

- hardware,
- operační systém (OS),
- uživatelské aplikační programy a
- uživatele.

❖ I pro ty, kteří se nebudou podílet na vývoji žádného OS, má studium OS velký význam:

- OS mají významný vliv na fungování celého výpočetního systému a znalost principů jejich fungování je tedy zapotřebí při vývoji:
  - hardware, na kterém má běžet nějaký OS a
  - software, který má prostřednictvím nějakého OS efektivně využívat zdroje hardware, na kterém běží – což by mělo platit vždy.

- OS jsou obvykle značně komplikované systémy, jež prošly a procházejí dlouhým a nákladným vývojem, při kterém:
  - byla učiněna řada rozhodnutí ovlivňujících filozofii vývoje a trh počítačových systémů: otevřený x uzavřený software, vývoj SW v komunitách vývojářů, ovlivňování počítačového trhu na základě vlastností OS, virtualizace, ...,
  - byla použita řada zajímavých algoritmů, způsobů návrhu architektury SW, metodologií a technik softwarového inženýrství apod., jež jsou inspirující i mimo oblast OS.

❖ Zapojení se do vývoje některého OS či jeho části není navíc zcela nepravděpodobné:

- Není např. možné dodávat nově vyvinutý hardware (rozšiřující karty apod.) bez podpory v podobě ovladačů (driverů).
- Pro potřeby různých aplikací (např. u vestavěných počítačových systémů) může být zapotřebí vyvinout/přizpůsobit vhodný OS.
- Zapojení se do vývoje některého otevřeného OS (Linux, FreeBSD, mikrojádra typu L4, ...) je značnou intelektuální výzvou a může přinést příslušné intelektuální uspokojení.

Organizace studia

- Přednáška:
  - 3h/týden (případné bonusové body za účast),
  - principy a vlastnosti operačních systémů (UNIX obvykle jako případová studie),
  - UNIX z uživatelského a částečně programátorského pohledu.

- Samostatná práce:
  - min. 2h/týden,
  - samostudium, experimenty, ..., úkoly (+ dobrovolná demo-cvičení).

- Hodnocení:

projekty	30b	
půlsem. zkouška	10b	(zápočet: min 10b z půlsem. zk. a projektů)
semestrální zkouška	60b	(minimum: 27b)
celkem	100b	

Pro ilustraci: v loňském roce úspěšnost cca 62,4 %, zápočet 78,1 %.

Zdroje informací

- WWW stránky kursu: `http://www.fit.vutbr.cz/study/courses/IOS/private/`
- Diskusní fóra kursu: jsou dostupná v IS FIT – diskutujte!
- Literatura: koupit či vypůjčit (např. v knihovně FIT, ale i v jiných knihovnách).
  - Je-li některá kniha dlouhodobě vypůjčena některému zaměstnanci, neváhejte a kontaktujte ho.
- Internet:
  - vyhledávače (google, ...); často jsou užitečné dokumenty typu HOWTO, FAQ, ...
  - encyklopedie: `http://www.wikipedia.org/` – velmi vhodné při prvotním ověřování některých bodů z přednášek při studiu, lze pokračovat uvedenými odkazy, nutné křížové ověřování.
  - dokumentační projekty: `http://www.tldp.org/`, ...
- UNIX, Linux: program `man` („RTFM!“), GNU `info` a další dokumentace (`/usr/share/doc`, `/usr/local/share/doc`), ...

Literatura

[1] Silberschatz, A., Galvin, P.B., Gagne, G.: Operating Systems Concepts, 10th ed., John Wiley & Sons, 2018. (Významná část přednášek je založena na tomto textu.)

[2] Tanenbaum, A.S.: Modern Operating Systems, 4th ed., Pearson, 2014.

[3] Tanenbaum, A.S., Woodhull, A.S.: Operating Systems Design and Implementation, 3rd ed., Prentice Hall, 2006.

[4] Raymond, E.S.: The Art Of Unix Programming, Addison-Wesley, 2003. `http://www.catb.org/~esr/writings/taoup/html/`

[5] Yosifovich, P., Ionescu, A. Russinovich, M., Solomon, D.: Windows Internals, 7th ed., Microsoft Press, 2017.

[6] Skočovský, L.: Principy a problémy operačního systému UNIX, 2. vydání, 2008. `http://skocovsky.cz/paposu2008/`

Uvedeny jsou pouze některé základní, zejména přehledové knihy. Existuje samozřejmě řada dalších knih, a to včetně knih specializovaných na detaily různých subsystémů operačních systémů (plánovač, správa paměti, souborové systémy, ovladače, ...). Tyto knihy často vycházejí přímo ze zdrojových kódů příslušných subsystémů, které uvádějí s příslušným komentářem.

Základní pojmy

Význam pojmu operační systém

❖ Operační systém je program, resp. kolekce programů, která vytváří spojující mezivrstvu mezi hardware výpočetního systému (jenž může být virtualizován) a uživateli a jejich uživatelskými aplikačními programy.

❖ Cíle OS – kombinace dvou základních, do jisté míry protichůdných cílů, jejichž poměr se volí dle situace:

- Maximální využití zdrojů počítače:
  - drahé počítače, levnější pracovní síla,
  - zejména dříve (nebo na speciálních architekturách).
- Jednoduchost použití počítačů:
  - levné počítače a drahá pracovní síla,
  - dnes převažuje.

❖ Dvě základní role OS:

- Správce prostředků (paměť, procesor, periferie).
  - Dovoluje sdílet prostředky efektivně a bezpečně.
  - Více procesů sdílí procesor, více procesů sdílí paměť, více uživatelů a souborů obsazuje diskový prostor, ...

- Tvůrce prostředí pro uživatele a jejich aplikační programy (tzv. *virtuálního počítače*).
  - Poskytuje standardní rozhraní, které zjednodušuje přenositelnost aplikací a zaučení uživatelů.
  - Poskytuje abstrakce:
    - Technické vybavení je složité a značně různorodé – práci s ním je nutné zjednodušit.
    - Problémy abstrakcí: menší efektivita, nepřístupné některé nízkoúrovňové operace.
    - Příklady abstrakcí: proces[a], soubor[b], virtuální paměť, ...

---

[a] *Program: předpis, návod na nějakou činnost zakódovaný vhodným způsobem (zdrojový text, binární program). Proces: činnost řízená programem.*

[b] *Soubor: kolekce záznamů sloužící (primárně) jako základní jednotka pro ukládání dat na vnějších paměťových médiích. Adresář: kolekce souborů.*

❖ Výše uvedené není zadarmo! OS spotřebovává zdroje (paměť, čas procesoru).

❖ OS se obvykle chápe tak, že zahrnuje:

- jádro (kernel),
- systémové knihovny a utility (systémové aplikační programy),
- textové a/nebo grafické uživatelské rozhraní.

❖ Přesná definice, co vše OS zahrnuje, však neexistuje:

- Někdy bývá OS ztotožňován takřka pouze s jádrem.
- GNU – *GNU is Not UNIX*: Projekt vývoje „svobodného“ (*free*) OS, který zahrnuje jádro (Linux, Hurd), utility, grafické i textové rozhraní (bash, Gnome, KDE), vývojové prostředky a knihovny (gcc, gdb, ...) i řadu dalších programů (včetně kancelářských programů a her).
- Je či není prohlížeč Internetu/přehrávač videa/... nedílnou součástí OS?
- Distribuce Linux/Windows/MacOS jako OS.

Jádro OS

❖ Jádro OS je nejnižší a nejzákladnější část OS.

- Zavádí se první a běží po celou dobu běhu počítačového systému (tzv. *reaktivní* spíše než *transformační* program).
- Navazuje přímo na hardware, příp. virtualizovaný HW, a typicky ho pro uživatele a uživatelské aplikace zcela zapouzdřuje.
- Běží obvykle v privilegovaném režimu.
  - V tomto režimu může provádět libovolné operace nad (virtualizovaným) HW počítače.
  - Za účelem oddělení a ochrany uživatelů a jejich aplikačních programů nesmí tyto mít možnost do tohoto režimu libovolně vstupovat.
  - Nutná HW podpora v CPU.
- Zajišťuje základní správu prostředků a tvorbu prostředí pro vyšší vrstvy OS a uživatelské aplikace.
  - To, jaké konkrétní služby jádro nabízí, je výsledkem zvoleného kompromisu mezi efektivitou, bezpečností, flexibilitou a příp. dalšími aspekty.
  - Jedná se ovšem minimálně o tu část služeb, která bezprostředně vyžaduje interakci s HW (přepínání kontextu, zavádění stránek, nastavování parametrů HW apod.).

❖ Systémové i uživatelské aplikační programy mohou explicitně žádat jádro o služby prostřednictvím systémových volání (*system call*). Děje se tak přímo nebo nepřímo s využitím specializovaných instrukcí (např. u x86 softwarové přerušení nebo `SYSCALL`/`SYSENTER`), které způsobí kontrolovaný přechod do režimu jádra.

❖ Rozlišujeme dva typy rozhraní OS:

- Kernel Interface: přímé volání jádra specializovanou instrukcí (případně jen zapouzdřenou v obálce ve vyšším programovacím jazyce)
- Library Interface: volání funkcí ze systémových knihoven, které mohou (ale nemusí) vést na volání služeb jádra

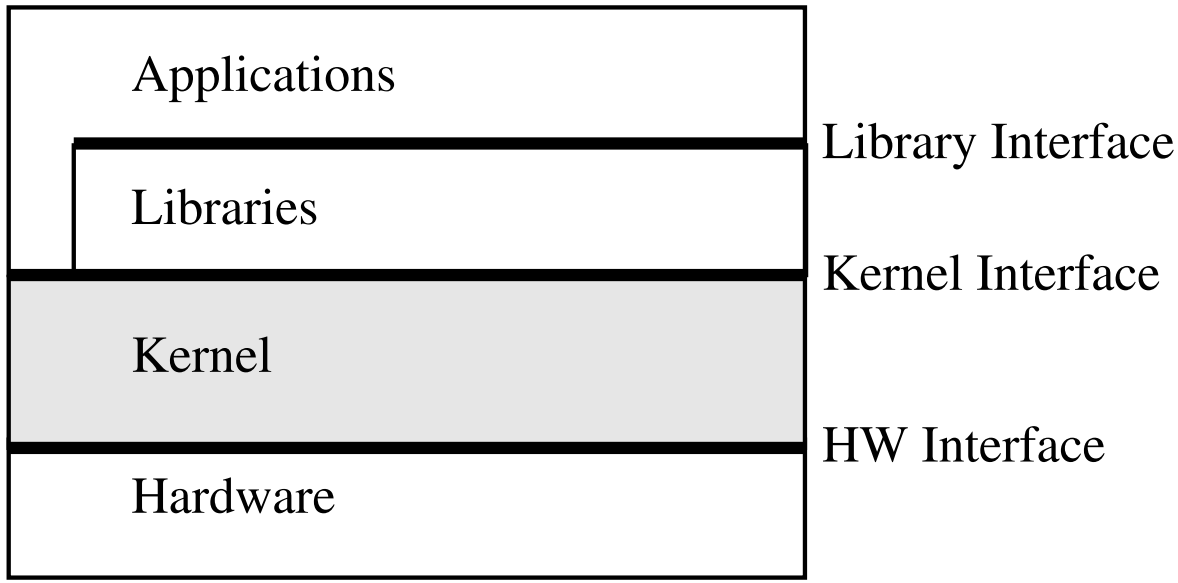

Typy jader OS

❖ Monolitická jádra:

- Vytváří vysokoúrovňové komplexní rozhraní s řadou služeb a abstrakcí nabízených vyšším vrstvám.
- Všechny subsystémy implementující tyto služby (správa paměti, plánování, meziprocesová komunikace, souborové systémy, podpora síťové komunikace apod.) běží v privilegovaném režimu a jsou těsně provázané za účelem vysoké efektivity.

❖ Vylepšením koncepce monolitických jader jsou monolitická jádra s modulární strukturou:

- Umožňuje zavádět/odstraňovat subsystémy jádra v podobě tzv. modulů za běhu.
- Např. FreeBSD či Linux (`lsmod`, `modprobe`, `rmmod`, ...)

❖ Mikrojádra:

- Minimalizují rozsah jádra a nabízí jednoduché rozhraní, s jednoduchými abstrakcemi a malým počtem služeb pro nejzákladnější správu procesoru, vstup/výstupních zařízení, paměti a meziprocesové komunikace.
- Většina služeb nabízených monolitickými jádry (včetně např. ovladačů, významných částí správy paměti či plánování) je implementována mimo mikrojádro v tzv. serverech, jež neběží v privilegovaném režimu.
- Příklady mikrojáder: Mach, QNX (a řada dalších RTOS), L4 (pouhých 7 služeb oproti takřka 400 u jader 4.x Linuxu...), ...
- Výhody mikrojáder:
  - Flexibilita – možnost více současně běžících implementací různých služeb, jejich dynamické spouštění, zastavování apod.
  - Zabezpečení – servery neběží v privilegovaném režimu, chyba v nich/útok na ně neznamená ihned selhání/ovládnutí celého OS.
- Nevýhoda mikrojáder: vyšší režie – výrazně vyšší u mikrojader 1. generace (Mach), lepší je situace u mikrojader 2. generace (např. L4: minimalismus, maximální optimalizace i s ohledem na hardware).
- Mikrojádra 3. generace: důraz na zabezpečení, virtualizaci, návrh s ohledem na možnost formální verifikace (např. seL4, ProvenCore, ...).

- Hybridní jádra:
  - Mikrojádra rozšířená o kód, který by mohl být implementován ve formě serveru, ale je za účelem menší režie těsněji provázán s mikrojádrem a běží v jeho režimu.
  - Příklady: Mac OS X (Mach kombinovaný s BSD), Windows NT (a vyšší), ...

Historie vývoje OS

❖ Je nutné znát historii, protože se opakuje... :-)

❖ První počítače:

- Knihovna podprogramů (například pro vstup a výstup) – zárodek OS.
- Dávkové zpracování: důležité je vytížení stroje, jednoduchá podpora OS pro postupné provádění jednotlivých úloh seřazených operátory do dávek.
- Multiprogramování – více úloh zpracovávaných současně:
  - Překrývání činnosti procesoru a vstup/výstupního podsystému (vyrovnávací paměti, přerušení).
  - Zatímco jedna úloha běží, jiná může čekat na dokončení I/O (problém: ochrana paměti, řešeno technickými prostředky).
  - OS začíná být významnou částí programového vybavení (nevýhoda: OS zatěžuje počítač).

❖ Příchod levnějších počítačů:

- Interaktivnost, produktivita práce – lidé nečekají na dokončení zpracování dávky.
- Stále se ještě nevyplatí každému uživateli dát počítač – terminály a sdílení času: timesharing/multitasking, tj. „současný“ běh více aplikací na jednom procesoru.
- Problém odezvy na vstup: preemptivní plánování úloh[a].
- Oddělené ukládání dat uživatelů: systémy souborů.
- Problémy s přetížením počítače mnoha uživateli.
- OS řídí sdílení zdrojů: omezené použití prostředků uživatelem (priority, quota).

---

[a] *Nepreemptivní plánování: Procesor může být procesu odebrán, pokud požádá jádro o nějakou službu (I/O operaci, ukončení, vzdání se procesoru). Preemptivní plánování: OS může procesu odebrat procesor i „ proti jeho vůli“ (tedy i když sám nežádá o nějakou službu jádra), a to na základě příchodu přerušení při určité události (typicky při vypršení přiděleného časového kvanta, ale také dokončení I/O operace jiného procesu apod.).*

❖ Ještě levnější počítače:

- Každý uživatel má svůj počítač, který musí být levný a jednoduchý (omezená paměť, chybějící ochrana paměti, jednoduchý OS – na poli OS jde o návrat zpět: CP/M, MS-DOS).
- Další pokrok v technologiích – sítě, GUI.
- Nové OS opět získávají vlastnosti starších systémů (propojení přes síť si opět vynucuje patřičné ochrany, ...).

❖ Následoval (následuje) podobný vývoj u nejprve málo výkonných notebooků, kapesních počítačů a mobilů s omezenými OS (jednoúlohovost apod.), nyní již ale běžně s více-jádrovými procesory a převzetím mnoha rysů běžných OS.

❖ Další podobný vývoj: např. vestavěné systémy, senzorové sítě, Internet of Things (IoT) apod. – prozatím málo výkonné uzly (spotřeba energie), ale co bude následovat?

Přehled technického vybavení

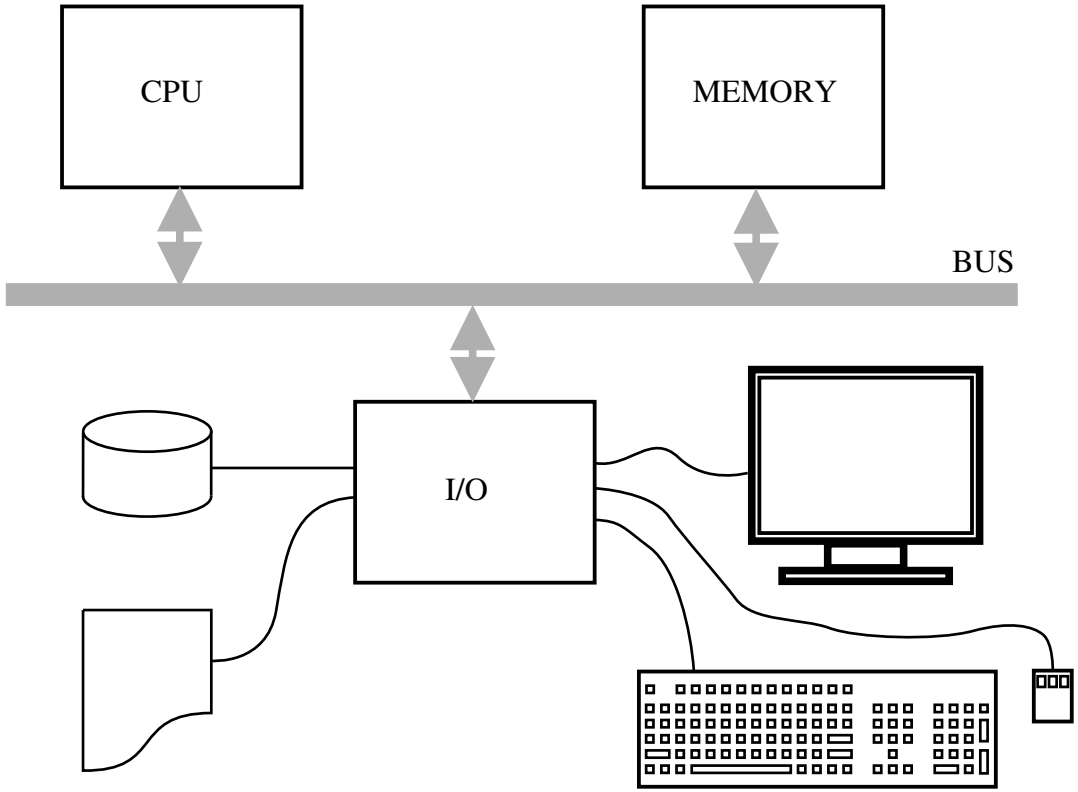

Procesor: řadič, ALU, registry (IP, SP), instrukce

Paměť: adresa, hierarchie pamětí (cache, ...)

Periferie: disk, klávesnice, monitor, (I/O porty, paměťově mapované I/O, přerušení, DMA)

Sběrnice: FSB, HyperTransport, DPI, QPI, UPI, NVLink, CAPI, PCI, USB, IEEE1394, ATA/SATA, SCSI/SAS, ...

Klasifikace počítačů

- Klasifikace počítačů podle účelu:
  - univerzální,
  - specializované:
    - vestavěné (řízení technologických zařízení, palubní počítače, spotřební elektronika, ...),
    - aplikačně orientované (databázové, výpočetní, síťové servery, ...),
    - vývojové (zkoušení nových technologií), ...

- Klasifikace počítačů podle výkonnosti:
  - vestavěné počítače, tablety, mobily, ...,
  - osobní počítače (personal computer),
  - pracovní stanice (workstation),
  - servery,
  - střediskové počítače (mainframe),
  - superpočítače.

Klasifikace OS

- Klasifikace OS podle účelu:
  - univerzální (Windows, Linux, UNIX, ...),
  - specializované:
    - real-time – RTOS (RTEMS, FreeRTOS, PikeOS, QNX, ...),
    - vestavěné (RTOS a/nebo upravený Linux, *BSD, Windows CE, ...),
    - databáze, web, ... (např. z/VSE),
    - mobilní zařízení (Android, iOS, ...), ...

- Klasifikace OS podle počtu uživatelů:
  - jednouživatelské (CP/M, MS-DOS, ...) a
  - víceuživatelské (UNIX, Windows, ...).

- Klasifikace OS podle počtu současně běžících úloh:
  - jednoúlohové a
  - víceúlohove (multitasking: ne/preemptivní).

Příklady dnes používaných OS

typ počítače	příklady OS
mainframe	z/OS, z/VM, z/VSE, varianty Linuxu, z/TPF
superpočítače	varianty Linuxu
server	Windows, Linux, FreeBSD, UNIX
PC	Windows, MacOS X, Linux
real-time	RTEMS, FreeRTOS, PikeOS, QNX
vestavěné	různé RTOS, Linux, *BSD, Windows CE
tablety, mobily, hodinky	Android, iOS, Tizen

Implementace OS

- OS se obtížně programují a ladí, protože to jsou
  - velké programové systémy,
  - paralelní a asynchronní systémy,
  - systémy závislé na technickém vybavení.

- Z výše uvedeného plyne:
  - Jistá setrvačnost při implementaci: snaha neměnit kód, který již spolehlivě pracuje.
  - Používání řady technik pro minimalizaci výskytu chyb, např.:
    - inspekce zdrojového kódu (důraz na srozumitelnost!),
    - rozsáhlé testování,
    - podpora vývoje technik automatizované statické/dynamické analýzy a verifikace, včetně technik formálních či s formálními základy.

Hlavní směry ve vývoji OS

- Pokročilé architektury (mikrojádra, hybridní jádra, ...): zdůraznění výhod, minimalizace nevýhod, možnost kombinace různých, současně běžících OS, ...
- Bezpečnost a spolehlivost.
- Multiprocessing, podpora mnoha jader.
- Virtualizace.
- Distribuované zpracování, clustery, gridy, cloud, kontejnery, Internet of Things.
- OS tabletů, mobilů, vestavěných systémů, ...
- Vývoj nových technik návrhu, implementace a verifikace OS.
- ...

Základy práce s UNIXem

Studentské počítače s UNIXem na FIT

- studentské UNIXové servery: eva (FreeBSD), merlin (Linux/CentOS)
- PC s Linuxem (CentOS): běžně na učebnách (dual boot)

❖ Přihlášení:

```
Login: xnovak00
Password:       # neopisuje se - změna: příkaz passwd
...
$               # prompt - vyzývací znak shellu
```

❖ Vzdálené přihlášení:

- programy/protokoly pro vzdálení přihlášení: ssh, telnet (telnet neužívat!)
- putty – ssh klient pro Windows

Základní příkazy

❖ Práce s adresáři a jejich obsahem:

- `cd` – change directory
- `pwd` – print working directory
- `ls [-al]` – výpis obsahu adresáře/informace o souborech

- `mkdir` – make a directory
- `rmdir` – remove a directory

- `mv` – přesun/přejmenování souboru/adresáře (move)
- `cp [-r]` – kopie souboru/adresáře (copy)
- `rm [-ir]` – smazání souboru/adresáře (remove)

❖ Výpis obsahu souboru:

- `cat` – spojí několik souborů na std. výstup
- `more`/`less` – výpis po stránkách
- `head -13 FILE` – prvních 13 řádků
- `tail -13 FILE` – posledních 13 řádků

- `file FILE` – informace o typu obsahu souboru

Speciální znaky

- `^C` – ukončení procesu na popředí
- `^Z` – pozastavení procesu na popředí (dále `bg`/`fg`)
- `^S`/`^Q` – pozastavení/obnovení výpisu na obrazovku
- `^\` – `^C` a výpis „core dump“

- `^D` – konec vstupu (`$^D` ukončí shell)

- `^H` – smazání posledního znaku (backspace)
- `^W` – smazání posledního slova
- `^U` – smazání současného řádku

Operační systémy

IOS 2020/2021

Tomáš Vojnar

vojnar@fit.vutbr.cz

Vysoké učení technické v Brně
Fakulta informačních technologií
Božetěchova 2, 612 66 Brno

Unix – úvod

Historie UNIXu

❖ 1961: CTSS (Compatible Time-Sharing System):

- vyvinut na MIT, jeden z prvních OS podporujících sdílení času (další takový OS byl Plato II z University of Illinois),
- jeden z prvních OS s emailem, zárodkem shellu, jedním z prvních programů pro formátování textu (RUNOFF, předchůdce nroff/groff).

❖ 1965: MULTICS – Multiplexed Information and Computation Service (Bell Labs, MIT, General Electric):

- v zásadě neúspěšný OS, „zhroutil se vlastní vahou“ (přílišná obecnost, přílišný rozsah služeb, přespecifikovanost), měl ale významný vliv na další vývoj OS,
- hierarchický souborový systém, paměťově mapované soubory, dynamické linkování, ACLs, dynamická rekonfigurace, předchůdce shellu, ...

❖ 1969: Začátek vývoje nového OS – PDP 7 (K. Thompson, D. Ritchie a několik jejich kolegů z Bell Labs, AT&T).

❖ 1970: Zavedeno jméno UNIX (původně UNICS).

❖ 1971: PDP-11 (24KB RAM, 512KB disk) – text processing.

- 1972: asi 10 instalací.
- 1973: UNIX přepsán do C.
- 1973/74: Článek: „Unix Timesharing System“, asi 600 instalací.
- 1977: Berkeley Software Distribution – BSD.
- 1978: SCO (Santa-Cruz Operation) – první Unixová společnost.
- 1979: UNIX Version 7 – verze UNIXu blízká současným verzím.
- 1980:
  - DARPA si vybrala UNIX jako platformu pro implementaci TCP/IP.
  - Microsoft a jeho XENIX.
- 1981: Microsoft, smlouva s IBM, QDOS, MS-DOS.
- 1982: Sun Microsystems.
- 1983:
  - AT&T UNIX System V.
  - BSD 4.2 – síť TCP/IP.
  - GNU, R. Stallman.

- 1984: X/OPEN XPG.
- 1985: POSIX (IEEE).
- 1987: AT&T, SUN: System V Release 4 a OSF/1.
- 1990: Windows 3.0.
- 1991: Solaris, Linux.
- 1992: 386BSD.
- 1994: Single Unix Specification (The Open Group).
- 1998:
  - začátek prací na sloučení základu SUS a POSIX,
  - open source software.
- 2002: SUS v3 – zahrnuje POSIX, poslední revize 2008 (SUS v4, rev. 2018).

- 2015: Spolupráce Red Hat a Microsoft v oblasti cloudových řešení a podpory .NET.
- 2018: Microsoft Azure Sphere – verze Linuxu pro IoT aplikace.
- 2019: Windows Subsystem for Linux 2 – Linuxové jádro nad Windows 10.

Příčiny úspěchu

- Mezi příčiny úspěchu UNIXu lze zařadit:
  - víceprocesový, víceuživatelský,
  - napsán v C – přenositelný,
  - zpočátku (a později) šířen ve zdrojovém tvaru,
  - „mechanism, not policy“,
  - „fun to hack“,
  - jednoduché uživatelské rozhraní,
  - skládání složitějších programů z jednodušších,
  - hierarchický systém souborů,
  - konzistentní rozhraní periferních zařízení, ...
- Řada z těchto myšlenek je inspirující i mimo oblast OS.

Varianty UNIXu

- Hlavní větve OS UNIXového typu:
  - UNIX System V,
  - BSD UNIX,
  - různé firemní varianty (AIX, Solaris, ...),
  - Linux.

- Související normy:
  - XPG – X/OPEN,
  - SVR4 – AT&T a SUN,
  - OSF/1,
  - Single UNIX Specification,
  - POSIX – IEEE standard,
  - Single UNIX Specification v3/v4 – shell a utility (CLI) a API.

Základní koncepty

- Dva základní koncepty/abstrakce v UNIXu: procesy a soubory.

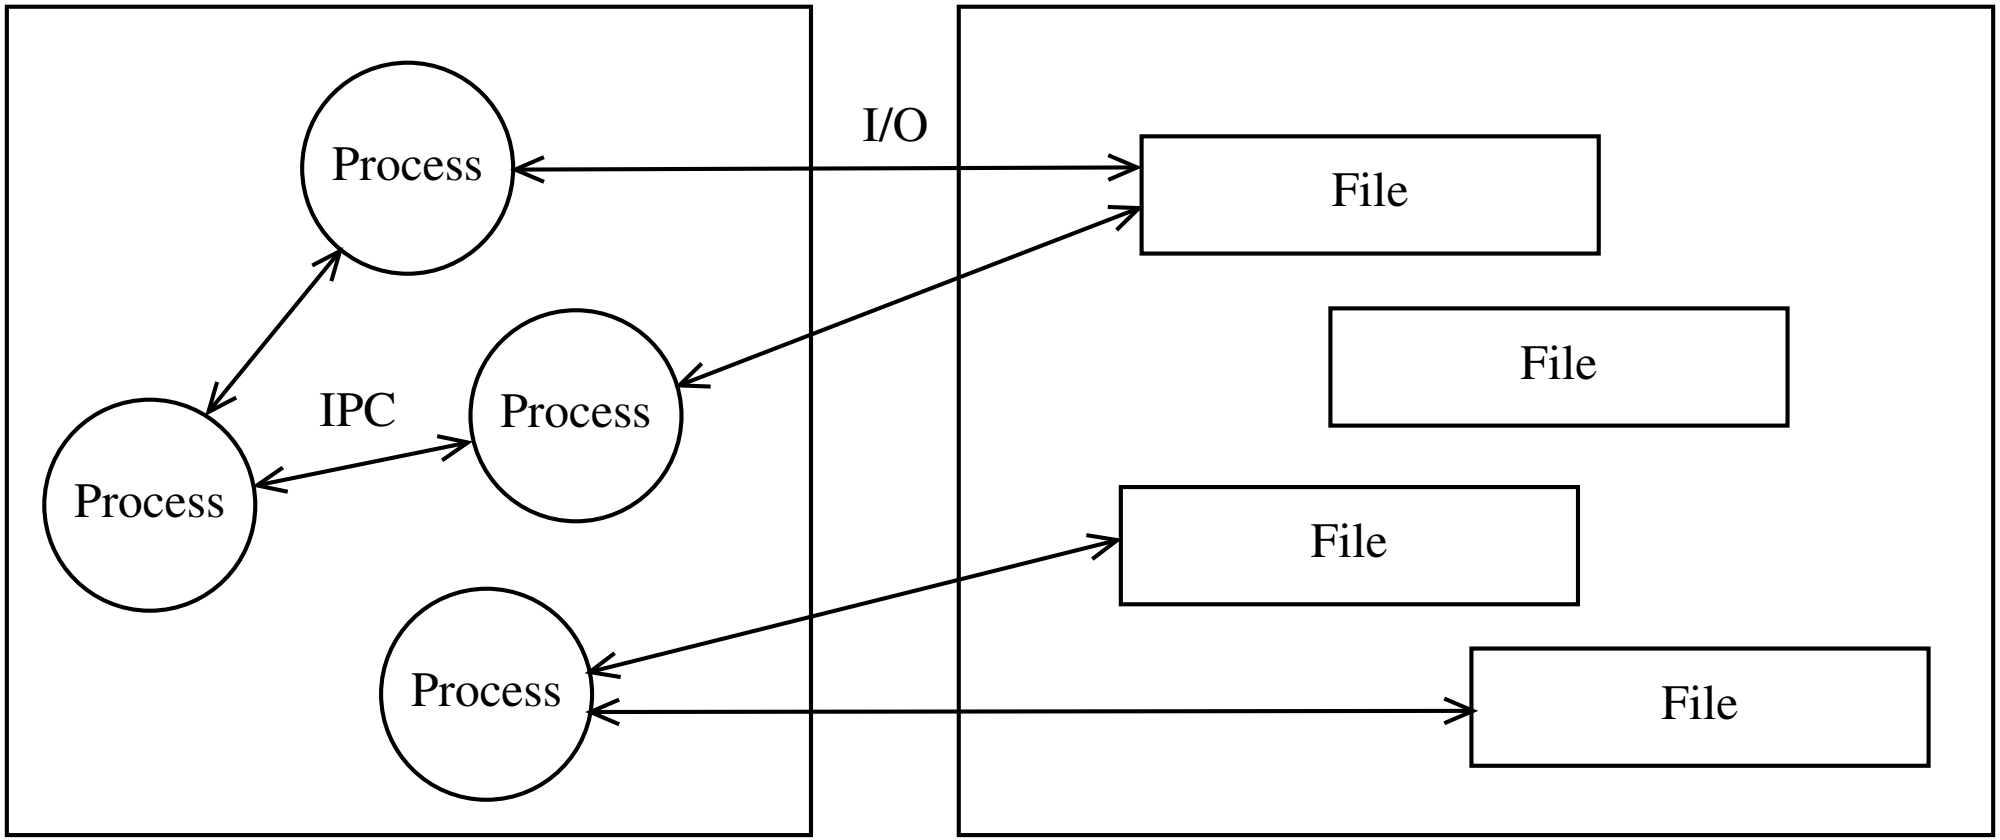

IPC = Inter-Process Communication – roury (pipes), signály, semafory, sdílená paměť, sockets, RPC, zprávy, streams...
I/O = Input/Output.

Struktura jádra UNIXu

- Základní podsystémy UNIXu:
  - Správa souborů
    (File Management)
  - Správa procesů
    (Process Management)

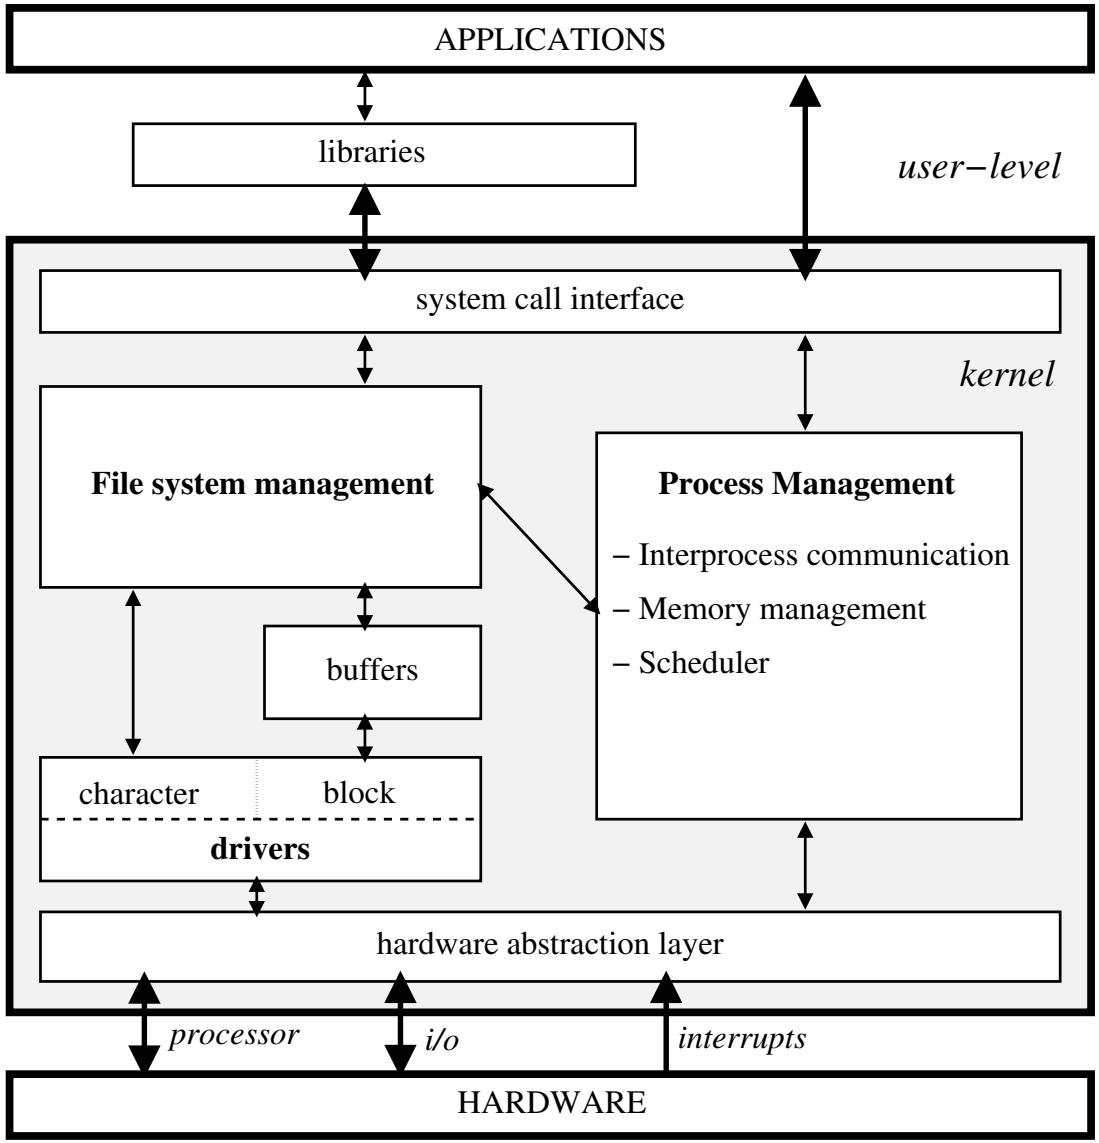

Komunikace s jádrem

❖ Služby jádra – operace, jejichž realizace je pro procesy zajišťována jádrem. Explicitně je možno o provedení určité služby žádat prostřednictvím systémového volání („system call“).

❖ Příklady některých služeb jádra dostupných systémovým voláním v UNIXu:

služba	jaká operace se provede
open	otevře soubor
close	zavře soubor
read	čte ze souboru
write	zapisuje
kill	pošle signál
fork	duplikuje proces
exec	přepíše kód
exit	ukončí proces

❖ HW přerušení (hardware interrupts) – mechanismus, kterým HW zařízení oznamují jádru asynchronně vznik událostí, které je zapotřebí obsloužit.

- Žádosti o HW přerušení přichází jako elektrické signály do řadiče přerušení.
  Na PC dříve PIC, nyní APIC (distribuovaný systém: každý procesor má lokální APIC, externí zařízení mohou být připojena přímo nebo přes I/O APIC – součást chip setu).
- Přerušení mají přiřazeny priority, dle kterých se oznamují procesoru.
- Přijme-li procesor přerušení s určitým číslem (tzv. interrupt vector) vyvolá odpovídající obslužnou rutinu (interrupt handler) na základě tabulky přerušení, přičemž automaticky přejde do privilegovaného režimu.
- Řadič může být naprogramován tak, že některá přerušení jsou maskována, případně jsou maskována všechna přerušení až po určitou prioritní úroveň.

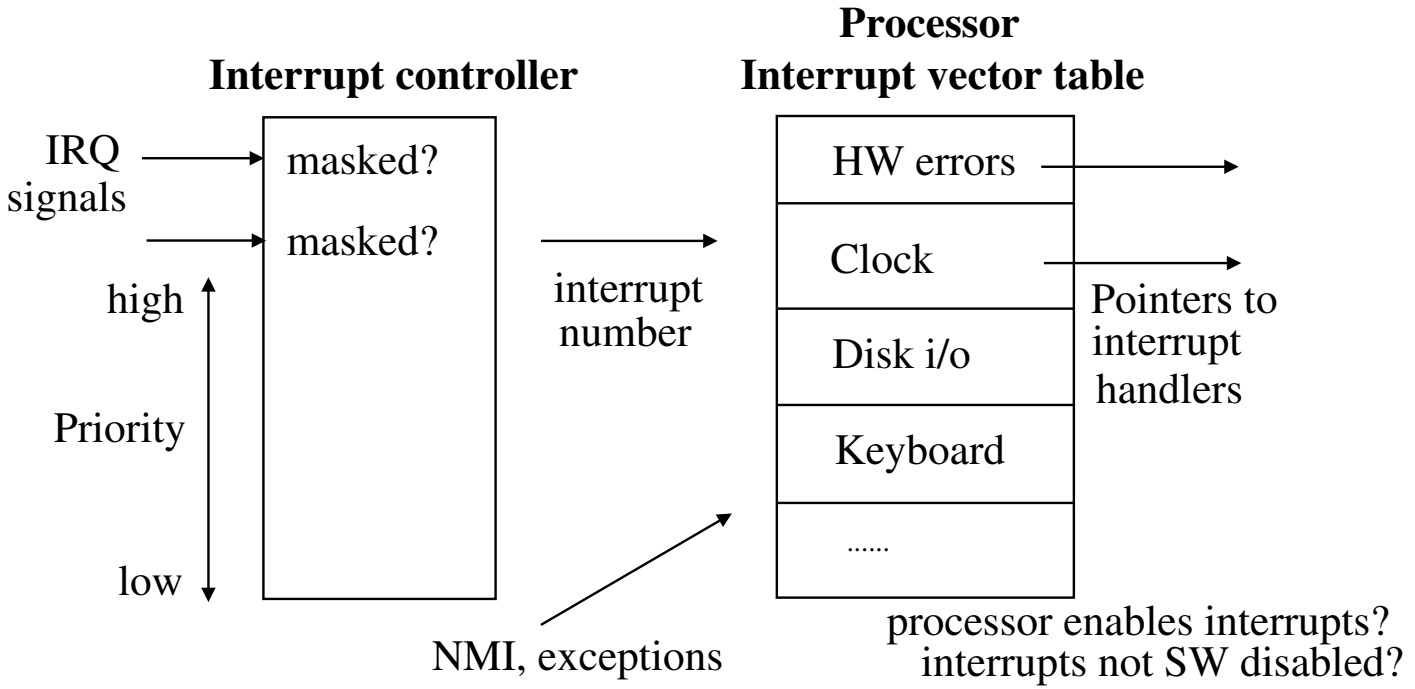

❖ Příjem nebo obsluhu HW přerušení lze také zakázat:

- na procesoru (instrukce CLI/STI na Intel/AMD),
- čistě programově v jádře (přerušení se přijme, ale jen se poznamená jeho příchod a dále se neobsluhuje).

❖ NMI (non-maskable interrupt): HW přerušení, které nelze zamaskovat na řadiči ani zakázat jeho příjem na procesoru (typicky při chybách HW bez možnosti zotavení: chyby paměti, sběrnice apod., někdy také pro ladění či řešení uváznutí v jádře: "NMI watchdog").

❖ Přerušení také vznikají přímo v procesoru – synchronní přerušení, výjimky (exceptions):

- trap: po obsluze se pokračuje další instrukcí (breakpoint, přetečení apod.),
- fault: po obsluze se (případně) opakuje instrukce, která výjimku vyvolala (např. výpadek stránky, dělení nulou, chybný operační kód apod.),
- abort: nelze určit, jak pokračovat, provádění se ukončí (např. některé zanořené výjimky typu fault, chyby HW detekované procesorem – tzv. „machine check mechanism").

- Při obsluze přerušení je zapotřebí dávat pozor na přerušení obsluhy přerušení:
  - Nutnost synchronizace obsluhy přerušení tak, aby nedošlo k nekonzistencím ve stavu jádra díky interferenci částečně provedených obslužných rutin.
  - Využívají se různé mechanismy vyloučení obsluhy přerušení (viz předchozí slajd).
  - Při vyloučení obsluhy je zapotřebí věnovat pozornost době, po kterou je obsluha vyloučena:
    - zvyšuje se latence (odezva systému),
    - může dojít ke ztrátě přerušení (nezaznamenají se opakované výskyty),
    - výpočetní systém se může dostat do nekonzistentního stavu (zpoždění času, ztráta přehledu o situaci vně jádra, neprovedení některých akcí v hardware, přetečení vyrovnávacích pamětí apod.).
  - Vhodné využití priorit, rozdělení obsluhy do více částí (viz další slajd).

❖ Obsluha přerušení je často rozdělena na dvě úrovně:

- 1. úroveň:
  - Zajišťuje minimální obsluhu HW (přesun dat z/do bufferu, vydání příkazů k další činnosti HW apod.) a plánuje běh obsluhy 2. úrovně.
  - Během obsluhy na této úrovni může být zamaskován příjem dalších přerušení stejného typu, stejné či nižší priority, případně i všech přerušení.
- 2. úroveň:
  - Postupně řeší zaznamenaná přerušení, nemusí zakazovat přerušení.
  - Obsluha může běžet ve speciálních procesech (interrupt threads ve FreeBSD, tasklety/softIRQ v Linuxu).
  - Vzájemné vyloučení se dá řešit běžnými synchronizačními prostředky (semafory apod. – nelze u 1. úrovně, kde by se blokoval proces, v rámci jehož běhu přerušení vzniklo).
  - Mohou zde být samostatné úrovně priorit.

❖ Mohou existovat i další speciální typy přerušení, která obsluhuje procesor zcela specifickým způsobem, často mimo vliv jádra. Např. na architekturách Intel/AMD:

- Interprocessor interrupt (IPI): umožňuje SW běžícímu na jednom procesoru poslat určité přerušení jinému (nebo i stejnému) procesoru – využití např. pro zajištění koherence některých vyrovnávacích pamětí ve víceprocesorovém systému (TLB), předávání obsluhy přerušení či v rámci plánování.
- System management interrupt (SMI): generováno HW i SW, způsobí přechod do tzv. system management mode (SMM) procesoru.
  - V rámci SMM běží firmware, který může být využit k optimalizaci spotřeby energie, obsluhu různých chybových stavů (přehřátí) apod.
  - Po dobu běhu SMM jsou prakticky vyloučena ostatní přerušení, což může způsobit zpožďování času v jádře a případné další nekonzistence stavu jádra oproti okolí, které mohou vést k pádu jádra.
- HW signály jako RESET, INIT, STOPCLK, FLUSH apod.

❖ Ovladače zařízení a přerušení:

- Při inicializaci ovladače (v Linuxu typicky modul), nebo jeho prvním použití, se musí registrovat k obsluze určitého IRQ.
- Příslužné IRQ je buď standardní, zjistí se přes konfigurační rozhraní sběrnic komunikací s jejich řadičem, nebo sondováním (zařízení je vyzváno ke generování přerušení a sleduje se, ke kterému dojde).
- IRQ může být sdíleno: jsou volány všechny registrované obslužné rutiny a musí být schopny komunikací s příslušným zařízením rozpoznat, zda přerušení bylo vygenerováno příslušným zařízením.

❖ Základní statistiky o obsluze přerušení v Linuxu: `/proc/interrupts`.

- Příklad komunikace s jádrem:
  - synchronní: proces-jádro
  - asynchronní: hardware-jádro

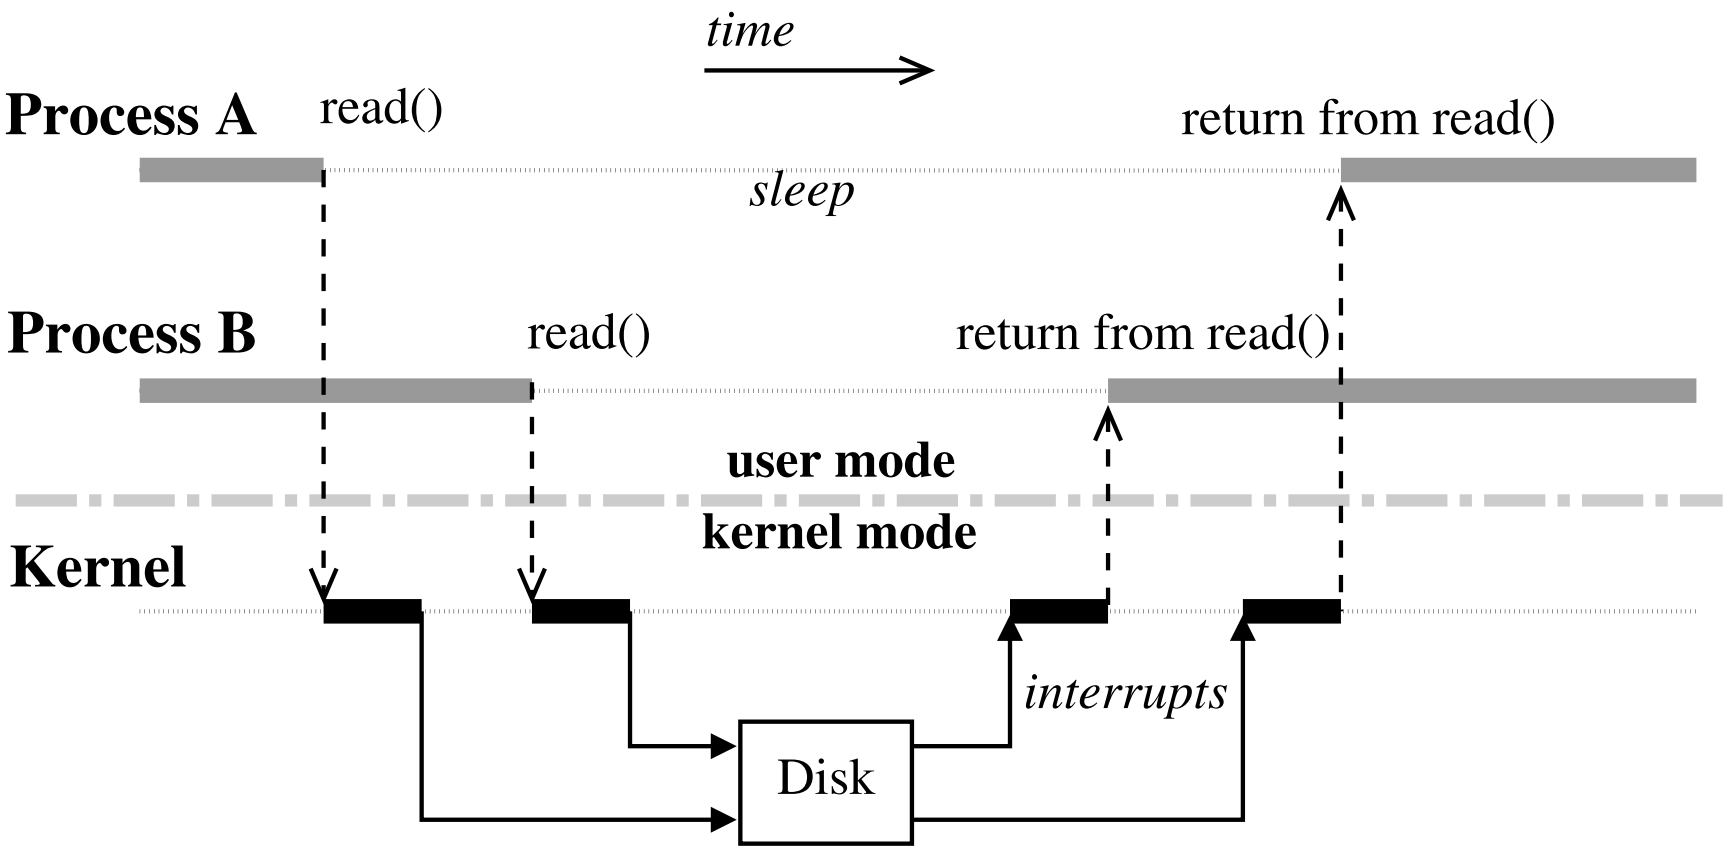

Operační systémy

IOS 2020/2021

Tomáš Vojnar

vojnar@fit.vutbr.cz

Vysoké učení technické v Brně
Fakulta informačních technologií
Božetěchova 2, 612 66 Brno

Programování v UNIXu: přehled

Nástroje programátora

- Prostředí pro programování zahrnuje:
  - API OS a různých aplikačních knihoven,
  - CLI a GUI,
  - editory,
  - překladače a sestavovače/interprety,
  - ladící nástroje,
  - nástroje pro automatizaci překladu,
  - ...
  - dokumentace.

- CLI a GUI v UNIXu:
  - CLI: shell (sh, ksh, csh, bash, dash, ...)
  - GUI: X-Window, Wayland

X-Window Systém

❖ Základní charakteristiky:

- grafické rozhraní typu client-server, nezávislé na OS, umožňující vzdálený přístup,
- otevřená implementace: XFree86/X.Org,
- mechanismy, ne politika — výhoda či nevýhoda?

❖ X-server: zobrazuje grafiku, ovládá grafický HW, myš, klávesnici...; s aplikacemi a správcem oken komunikuje přes X-protokol.

❖ Window Manager: správce oken (dekorace, změna pozice/rozměru, ...); s aplikacemi komunikuje přes ICCM protokol (Inter-Client Communication Protocol).

❖ Knihovna `xlib`: standardní rozhraní pro aplikace, implementuje X-protokol, ICCM, ...

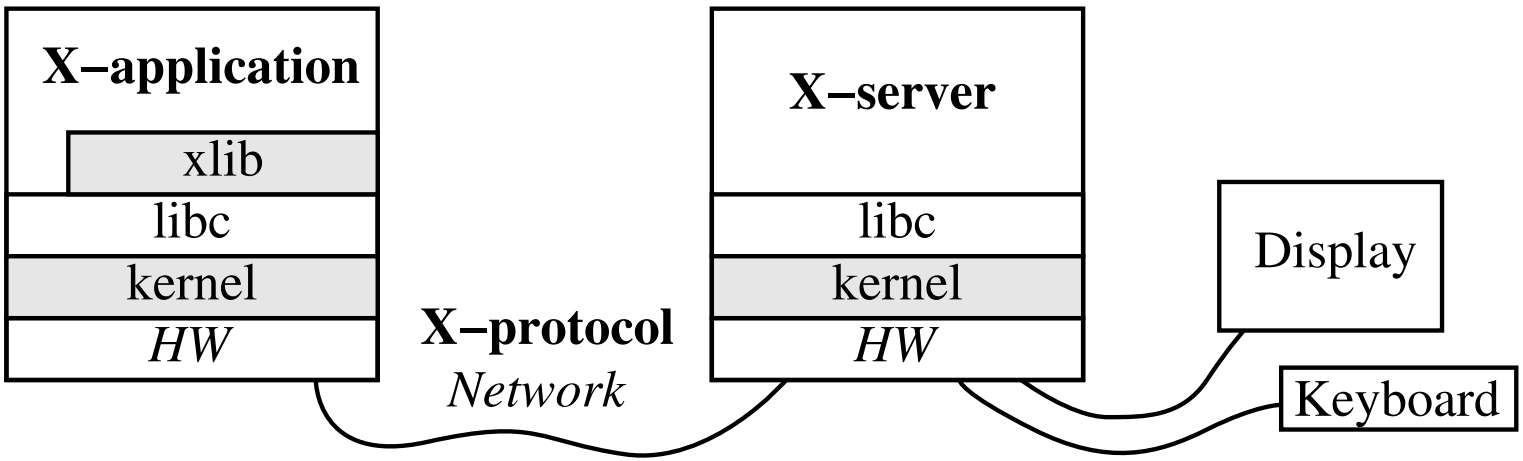

Vzdálený přístup přes X-Window

- Spuštění aplikace s GUI ze vzdáleného počítače:
  - lokální systém: `xhost + ...`
  - vzdálený systém: `export DISPLAY=...` a spuštění aplikace
  - tunelování přes ssh: `ssh -X`

- Vnořené GUI ze vzdáleného počítače: `Xnest`.

- Modernější alternativa k X-Window: Wayland, referenční implementace Weston.
  - Jednodušší architektura, bezpečnější, vždy kompozitní správa oken.
  - Distributivnost přes síť přes VNC.
  - Kompatibilita s X přes X-server XWayland.

- Na MacOS: grafický server Quartz Compositor (kompatibilita s X: XQuartz).

Editory, `vim`

- Textové editory běžné v UNIXu:
  - v terminálu: `vi`, `vim`, `emacs`, ...
  - grafické: `gvim`, `xemacs`, `gedit`, `nedit`, ...

- Tři režimy vi, vim:

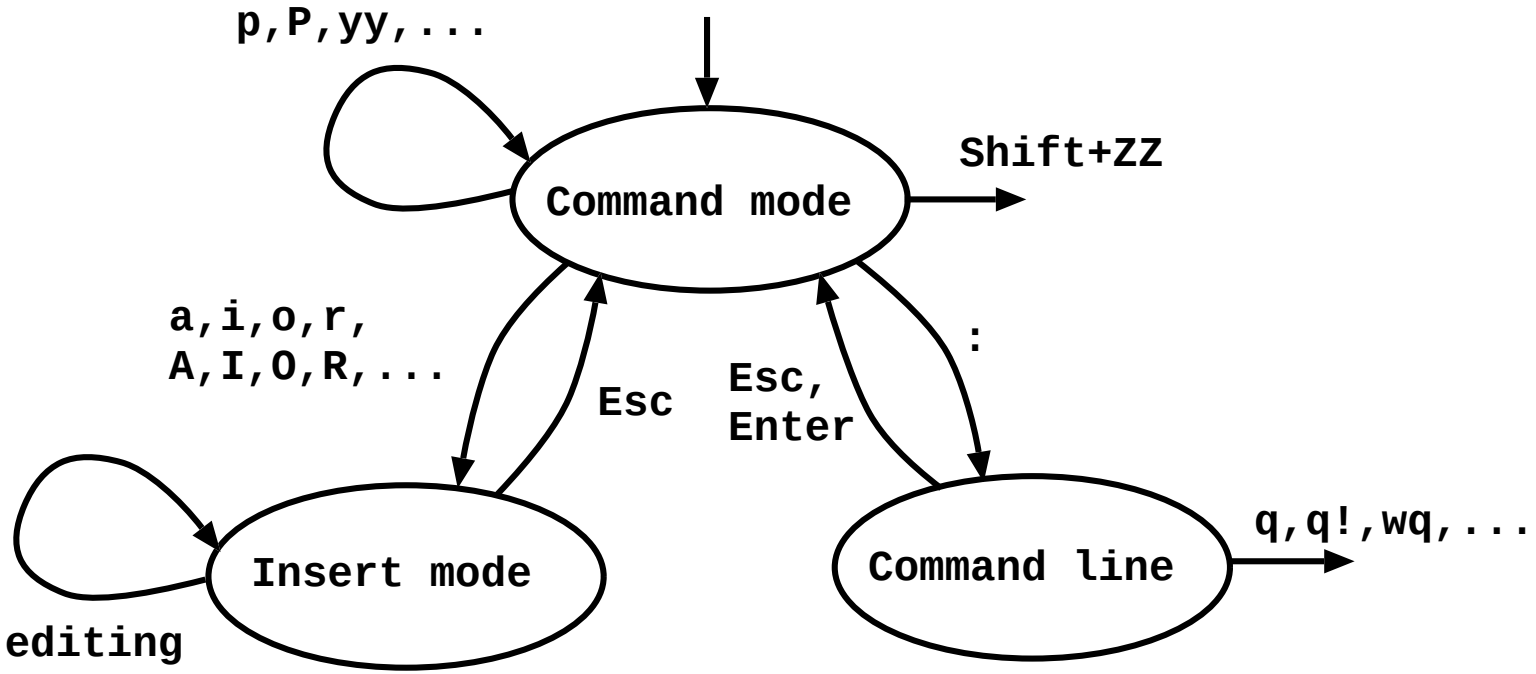

Užitečné příkazy ve `vim`

- Mazání – smaže a vloží do registru:
  - znak: `x`/`X`
  - řádek: `dd`
  - konec/začátek řádku: `dEnd` / `dHome`
  - konec/začátek slova: `dw` / `db`
  - konec/začátek odstavce: `d}` / `d{`
  - do znaku: `dt` znak
- Změna: `r`, `R` a `cc`, `cw`, `cb`, `c+End/Home`, `c}`, `ct`+ukončující znak, ...
- Vložení textu do registru: `yy`, `yw`, `y}`, `yt`+ukončující znak, ...
- Vložení registru do textu: `p`/`P`
- Bloky: (`v`+šipky)/(`Shift-v`+šipky)/(`Ctrl-v`+šipky)+`y` /`d`, ...

- Vícenásobná aplikace: číslo+příkaz (např. `5dd`)
- undo/redo: `u` /`Ctrl-R`
- Opakování posledního příkazu: `.` (tečka)
- Vyhledání: `/` regulární výraz
- Aplikace akce po vzorek: `d/` regulární výraz

Regulární výrazy

❖ Regulární výrazy jsou nástrojem pro konečný popis případně nekonečné množiny řetězců. Jejich uplatnění je velmi široké – nejde jen o vyhledávání ve `vim`!

❖ Základní regulární výrazy (existují také rozšířené RV – viz dále):

znak	význam
obyčejný znak	daný znak
`.`	libovolný znak
`*`	$0 - n$ výskytů předchozího znaku
`[`*množina*`]`	znak z množiny, např: `[0-9A-Fa-f]`
`[^`*množina*`]`	znak z doplňku množiny
`\`	ruší řídicí význam následujícího znaku
`^`	začátek řádku
`$`	konec řádku
`[[:`*k*`:]]`	znak z dané kategorie *k* podle `locale`

❖ Příklad: `"^ *\* [0-9][0-9]* *$"`

Příkazová řádka ve `vim`

- Uložení do souboru: `w`, případně `w!`

- Vyhledání a změna: řádky `s/` regulární výraz `/` regulární výraz (`/g`)

- Adresace řádků: číslo řádku, interval (`x,y`), aktuální řádek (`.`), poslední řádek (`$`), všechny řádky (`%`), nejbližší další řádek obsahující řetězec (`/řetězec/`), nejbližší předchozí řádek obsahující řetězec (`?řetězec?`)

- Příklad – vydělení čísel 10:

```
:%s/\([0-9]*\)\([0-9]\)/\1.\2/
```

Základní dokumentace v UNIXu

❖ `man`, `info`, `/usr/share/doc`, `/usr/local/share/doc`, HOWTO, FAQ, ..., README, INSTALL, ...

❖ `man` je rozdělen do sekcí (`man n name`):

1. Executable programs or shell commands
2. System calls (functions provided by the kernel)
3. Library calls (functions within program libraries)
4. Special files (usually found in `/dev`)
5. File formats and conventions, e.g., `/etc/passwd`
6. Games
7. Miscellaneous (including macro packages and conventions)
8. System administration commands (usually only for root)
9. Kernel routines (Non standard)

❖ `apropos name` – kde všude se v `man` mluví o `name`.

Bourne shell

❖ Skriptování:

- Interpret: program, který provádí činnost programu, který je jeho vstupem.
- Skript: textový soubor s programem pro interpret.
- Nevýhody: pomalejší, je třeba interpret.
- Výhody: nemusí se překládat (okamžitě spustitelné), čitelný obsah programu.

❖ Spuštění skriptu v UNIXu:

```
sh skript.sh          # explicitní volání interpretu

chmod +x skript.sh    # nastaví příznak spustitelnosti
./skript.sh           # spuštění

. ./skript.sh         # spuštění v aktuálním shellu
```

❖ “Magic number” = číslo uvedené na začátku souboru a charakterizující jeho obsah:

- U spustitelných souborů jádro zjistí na základě magic number, jak soubor spustit: tj. u binárních programů jejich formát určující způsob zevedení do paměti, u intepretovaných programů pak, který interpret použít (první řádek: `#!/cesta/interpret`).
- Výhoda: možnost psát programy v libovolném skriptovacím jazyku.

❖ Příklady:

```
#!/bin/sh              - skript pro Bourne shell

#!/bin/ksh             - skript pro Korn shell
#!/bin/csh             - skript pro C shell

#!/usr/bin/perl        - skript v Perlu
#!/usr/bin/python      - skript v Pythonu

\177ELF                - binární program - formát ELF
```

Speciální znaky (metaznaky)

- Jsou interpretovány shellem, znamenají provedení nějaké speciální operace.
- Jejich speciální význam lze zrušit například znakem \ těsně před speciálním znakem.
- Poznámky:

znak	význam a příklad použití
#	poznámka do konce řádku `echo "text" # poznámka`

- Práce s proměnnými:

$	zpřístupnění hodnoty proměnné `echo $TERM`

❖ Přesměrování vstupu a výstupu:

znak	význam a příklad použití

>	přesměrování výstupu, přepíše soubor
	
	`echo "text" >soubor # přesměrování stdout`
	`příkaz 2>soubor # přesměrování stderr`
	
	`příkaz [n]>soubor # n je číslo, implicitně 1`
	
	Čísla zde slouží jako popisovače otevřených souborů (file handle).
	Standardně používané a otevírané popisovače:
	• `stdin=0` standardní vstup (klávesnice)
	• `stdout=1` std. výstup (obrazovka)
	• `stderr=2` std. chybový výstup (obrazovka)

znak	význam a příklad použití

`>&`	duplikace popisovače pro výstup
	
	`echo "text" >&2 # stdout do stderr`
	`příkaz >soubor 2>&1 # přesm. stderr i stdout`
	`příkaz 2>&1 >soubor # stdout do souboru,`
	`# stderr na obrazovku`
	
	`m>&n # m a n jsou čísla`

`>>`	přesměrování výstupu, přidává do souboru
	
	`echo "text" >> soubor`
	`příkaz 2>>log-soubor`

znak	význam a příklad použití
`<`	přesměrování vstupu `příkaz < soubor`

`<<token`	přesměrování vstupu, čte ze skriptu až po *token*, který musí být samostatně na řádku – tzv. “here document” (expanze proměnných a vnořených příkazů)
	
	`cat >soubor <<__END__`
	`jakýkoli text, i $PROMENNA`
	`kromě ukončovacího řádku`
	`__END__`
	
	Varianty:
	`<<\token` quoting jako ’, dále žádná expanze
	`<<-token` možno odsadit tabelátory

❖ Zástupné znaky ve jménech souborů:

znak	význam a příklad použití

`*`	zastupuje libovolnou sekvenci libovolných znaků mimo / a . na začátku jména (což lze ale ovlivnit proměnnými shellu), shell vyhledá všechna odpovídající jména souborů a nahradí jimi příslušný vzor – pokud žádné nenajde, expanzi neprovede (lze ovlivnit opět proměnnými shellu):
	`ls *.c`
	`ls *archiv*gz`
	`ls .*/*.conf  # soubory s příponou conf ve skrytých adresářích`
	
	Poznámka: Programy nemusí zpracovávat tyto expanzní znaky samy.
	Poznámka: Pozor na limit délky příkazového řádku!

`?`	zastupuje 1 libovolný znak jména souboru (výjimky viz výše)
	`ls x???.txt`
	`ls soubor-?.txt`

`[množina]`	zastupuje jeden znak ze zadané množiny (výjimky viz výše)
	`ls [A-Z]*`
	`ls soubor-[1-9].txt`

❖ Skládání příkazů:

znak	význam a příklad použití

`|`	přesměrování `stdout` procesu na `stdin` dalšího procesu, slouží pro vytváření *kolon* procesů-filtrů:
	`ls | more`
	`cat /etc/passwd |`
	`  awk -F: '{print $1}' | sort`
	`příkaz | tee soubor | příkaz`

`‘příkaz‘`	je zaměněno za standardní výstup příkazu (command substitution)
	`ls -l ‘which sh‘`
	`DATUM=‘date +%Y-%m-%d‘  # ISO formát`
	`echo Přihlášeno ‘who|wc -l‘ uživatelů`

znak	význam a příklad použití
`;`	sekvence příkazů na jednom řádku `ls ; echo ; ls /`
`||`	provede následující příkaz, pokud předchozí neuspěl (`exitcode<>0`) `cc program.c || echo Chyba překladu`
`&&`	provede následující příkaz, pokud předchozí uspěl (`exitcode=0`) `cc program.c && ./a.out`

❖ Spouštění příkazů:

znak	význam a příklad použití

`(příkazy)`	spustí *subshell*, který provede příkazy
	
	`( echo "Text: "`
	`  cat soubor`
	`  echo "konec"`
	`) > soubor2`

`&`	spustí příkaz *na pozadí* (pozor na výstupy programu) `program &`

❖ Rušení významu speciálních znaků (quoting):

- Znak \ ruší význam jednoho následujícího speciálního znaku (i znaku "nový řádek").

```
echo \* text \*   \\
echo "fhgksagdsahfgsjdagfjkdsaagjdsagjhfdsa\
jhdsajfhdsafljkshdafkjhadsk"
echo 5 \> 2 text \$TERM
```

- Uvozovky "" ruší význam speciálních znaků kromě: $proměnná, ‘příkaz‘ a \.

```
echo  3 * 4 = 12 # chyba, pokud
                 # jsou v adresáři soubory
echo "3 * 4 = 12"
echo "Dnešní datum: ‘date‘"
echo "PATH=$PATH"
echo "\ <\"test\"> *** ‘date‘ *** $PATH *** "
```

- Apostrofy ’’ ruší speciální význam všech znaků v řetězci.

```
echo ’$<>*‘ jakýkoli text kromě apostrofu ’
echo ’toto ->’\’’<- je apostrof’
echo ’*\** \" $PATH ‘ls‘ <> \’
```

Postup při hledání příkazů

- Po zadání příkazu postupuje shell následovně:
  1. Test, zda se jedná o funkci nebo zabudovaný příkaz shellu (např. `break`), a případné provedení této funkce/příkazu.
  2. Pokud se jedná o příkaz zadaný i s cestou (např. `/bin/sh`), pokus provést program s příslušným jménem v příslušném adresáři.
  3. Postupné prohlížení adresářů v `PATH`.
  4. Pokud program nenalezne nebo není spustitelný, hlásí chybu.

- Poznámka: Vlastní příkazy do `$HOME/bin` a přidat do `PATH`.

Vestavěné příkazy

- Které příkazy jsou vestavěné závisí na použitém interpretu.
- Příklad: `cd`, `wait`, `break`, ...
- Výhoda: rychlost provedení.
- Ostatní příkazy jsou běžné spustitelné soubory.

Příkaz `eval`

- `eval příkaz`:
  - Jednotlivé argumenty jsou načteny (a je proveden jejich rozvoj), výsledek je konkatenován, znovu načten (a rozvinut) a proveden jako nový příkaz.
  - Možnost za běhu sestavovat příkazy (tj. program) na základě aktuálně čteného obsahu souboru, vstupu od uživatele apod.

- Příklady:

```
echo "text > soubor"
eval echo "text > soubor"
eval ‘echo x=1‘ ; echo "x=$x"
```

Ukončení skriptu

- Ukončení skriptu: `exit [číslo]`
  - vrací exit-code `číslo` nebo exit-code předchozího příkazu,
  - vrácenou hodnotu lze zpřístupnit pomocí `$?`,
  - možné hodnoty:
    - 0 – O.K.
    - <>0 – chyba

- Spuštění nového kódu: `exec příkaz`:
  - nahradí kód shellu provádějícího `exec` kódem daného příkazu,
  - spuštění zadaného programu je rychlé – nevytváří se nový proces,
  - bez parametru umožňuje přesměrování vstupu/výstupu uvnitř skriptu.

Správa procesů

`ps`	výpis stavu procesů
`nohup`	proces nekončí při odhlášení
`kill`	posílání signálů procesům
`wait`	čeká na dokončení potomka/potomků

- Příklady:

```
ps ax           # všechny procesy
nohup program   # pozor na vstup/výstup
kill -9 1234    # nelze odmítnout
```

Subshell

❖ Subshell se implicitně spouští v případě použití:

`./skript.sh`	spuštění skriptu (i na pozadí)
`(příkazy)`	skupina příkazů

❖ Subshell dědí proměnné prostředí, nedědí lokální proměnné (tj. ty, u kterých nebyl proveden `export`).

❖ Změny proměnných a dalších nastavení v subshellu se neprojeví v původním shellu!

❖ Provedení skriptu aktuálním interpretem:

- příkaz `.`
- např. `. skript`

❖ Posloupnost příkazů `{ příkazy }` – stejné jako `( )`, ale nespouští nový subshell.

❖ Příklad – možné použití `{ }` (a současně demonstrace jedné z programovacích technik používaných v shellu):

```
# Changing to a log directory.

cd $LOG_DIR

if [ "`pwd`" != "$LOG_DIR" ]  # or   if [ "$PWD" != "$LOG_DIR" ]
                              # Not in /var/log?
then
  echo "Cannot change to $LOG_DIR."
  exit $ERROR_CD
fi  # Doublecheck if in right directory, before messing with log file.

# However, a far more efficient solution is:

cd $LOG_DIR || {
  echo "Cannot change to $LOG_DIR." >&2
  exit $ERROR_CD;
}
```

Proměnné

- Rozlišujeme proměnné:
  - lokální (nedědí se do subshellu)

```
PROM=hodnota
PROM2="hodnota s mezerami"
```

  - proměnné prostředí (dědí se do subshellu)

```
PROM3=hodnota
export PROM3   # musíme exportovat do prostředí
```

- Příkaz `export`:
  - `export seznam_proměnných`
  - exportuje proměnné do prostředí, které dědí subshell,
  - bez parametru vypisuje obsah prostředí.

❖ Přehled standardních proměnných:

`$HOME`	jméno domovského adresáře uživatele
`$PATH`	seznam adresářů pro hledání příkazů
`$MAIL`	úplné jméno poštovní schránky pro e-mail
`$USER`	login jméno uživatele
`$SHELL`	úplné jméno interpretu příkazů
`$TERM`	typ terminálu (viz termcap/terminfo)
`$IFS`	obsahuje oddělovače položek na příkazové řádce – implicitně mezera, tabelátor a nový řádek
`$PS1`	výzva interpretu na příkazové řádce – implicitně znak `$`
`$PS2`	výzva na pokračovacích řádcích – implicitně znak >

❖ Další standardní proměnné:

`$$`	číslo = PID interpretu
`$0`	jméno skriptu (pokud lze zjistit)
`$1..$9`	argumenty příkazového řádku (dále pak `${n}` pro $n \geq 10$)
`$*`/`$@`	všechny argumenty příkazového řádku
`"$*"`	všechny argumenty příkazového řádku jako 1 argument v ""
`"$@"`	všechny argumenty příkazového řádku, individuálně v ""
`$#`	počet argumentů
`$?`	exit-code posledního příkazu
`$!`	PID posledního příkazu na pozadí
`$-`	aktuální nastavení shellu

❖ Příklady:

```
echo "skript: $0"
echo první argument: $1
echo všechny argumenty: $*
echo PID=$$
```

❖ Použití proměnných:

`$PROM text`	mezi jménem a dalším textem musí být oddělovací znak
`${PROM}text`	není nutný další oddělovač
`${PROM-word}`	`word` pokud nenastaveno
`${PROM+word}`	`word` pokud nastaveno, jinak nic
`${PROM=word}`	pokud nenastaveno, přiřadí a použije `word`
`${PROM?word}`	pokud nenastaveno, tisk chybového hlášení `word` a konec (exit)

❖ Příkaz `env`:

- `env nastavení_proměnných program [argumenty]`
- spustí program s nastaveným prostředím,
- bez parametrů vypíše prostředí.

❖ Proměnné pouze pro čtení:

- `readonly seznam_proměnných`
- označí proměnné pouze pro čtení,
- subshell toto nastavení nedědí.

❖ Posun argumentů skriptu:

- příkaz `shift`,
- posune `$1 <- $2 <- $3` ...

Čtení ze standardního vstupu

❖ Příkaz `read seznam_proměnných` čte řádek ze `stdin` a přiřazuje slova do proměnných, do poslední dá celý zbytek vstupního řádku.

❖ Příklady:

```
echo "x y z" | (read A B; echo "A='$A'  B='$B'")

IFS=","; echo "x,y z" | (read A B; echo "A='$A'  B='$B'")

IFS=":"; head -1 /etc/passwd | (read A B; echo "$A")
```

Příkazy větvení

- Příkaz `if`:

```
if seznam příkazů
then
  seznam příkazů
elif seznam příkazů
then
  seznam příkazů
else
  seznam příkazů
fi
```

Příklad použití:

```
if [ -r soubor ]; then
    cat soubor
else
    echo soubor nelze číst
fi
```

Testování podmínek

- Testování podmínek:
  - konstrukce `test výraz` nebo `[ výraz ]`,
  - výsledek je v `$?`.

výraz	význam
`-d file`	je adresář
`-f file`	je obyčejný soubor
`-r file`	je čitelný soubor
`-w file`	je zapisovatelný soubor
`-x file`	je proveditelný soubor
`-t fd`	deskriptor `fd` je spojen s terminálem
`-n string`	neprázdný řetězec
`string`	neprázdný řetězec
`-z string`	prázdný řetězec
`str1 = str2`	rovnost řetězců
`str1 != str2`	nerovnost řetězců

výraz	význam
`int1 -eq int2`	rovnost čísel
`int1 -ne int2`	nerovnost čísel
`int1 -gt int2`	$>$
`int1 -ge int2`	$>=$
`int1 -lt int2`	$<$
`int1 -le int2`	$<=$
`! expr`	negace výrazu
`expr1 -a expr2`	and
`expr1 -o expr2`	or
`\( \)`	závorky

❖ Příkaz case:

```
case výraz in
  vzor { | vzor }* )
    seznam příkazů
    ;;
esac
```

Příklad použití:

```
echo -n "zadejte číslo: "
read reply
case $reply in
   "1")
        echo "1"
        ;;
   "2"|"4")
        echo "2 nebo 4"
        ;;
    *)
        echo "něco jiného"
        ;;
esac
```

Cykly

❖ Cyklus `for`:

```
for identifikátor [ in seznam slov ]  # bez []: $1 ...
do
    seznam příkazů
done
```

Příklad použití:

```
    for i in *.txt ; do
       echo Soubor: $i
    done
```

❖ Cyklus `while`:

```
while seznam příkazů # poslední exit-code se použije
do
    seznam příkazů
done
```

Příklad použití:

```
    while true ; do
        date; sleep 1
    done
```

❖ Cyklus `until`:

```
until seznam příkazů # poslední exit-code se použije
do
    seznam příkazů
done
```

❖ Ukončení/pokračování cyklu:

```
break, continue
```

❖ Příklady:

```
stop=ne
while [ "$stop" != ano ]; do
    echo -n "má skript skončit: "
    read stop
    echo $stop
    if [ "$stop" = ihned ] ; then
        echo "okamžité ukončení"
        break
    fi
done
```

Zpracování signálů

- Příkaz `trap`:
  - `trap [příkaz] {signál}+`
  - při výskytu signálu provede příkaz,
  - pro ladění lze užít `trap příkaz DEBUG`.

- Příklad zpracování signálu:

```
#!/bin/sh

trap 'echo Ctrl-C; exit 1' 2  # ctrl-C = signál č.2

while true; do
   echo "cyklíme..."
   sleep 1
done
```

Vyhodnocování výrazů

- Příkaz `expr výraz`:
  - Vyhodnotí výraz, komponenty musí být odděleny mezerami (pozor na quoting!).
  - Operace podle priority:

```
\*     /      %
+      -
=      \>     \>=    \<    \<=    !=
\&
\|
```

  - Lze použít závorky: `\( \)`

- Příklady:

```
V=‘expr 2 +  3  \* 4‘ ; echo $V

expr 1 = 1  \&  0 != 1 ; echo $?

expr "$P1" = "$P2" # test obsahu proměnných

V=‘expr $V + 1‘    # V++
```

❖ Řetězcové operace v `expr`:

`String : Regexp`
`match String Regexp`
– vrací délku prefixu řetězce, který vyhovuje `Regexp`, nebo 0

`substr String Start Length`
– získá podřetězec od zadané pozice

`index String Charlist`
– vrací pozici prvního znaku ze seznamu, který se najde

`length String`
– vrací délku řetězce

Korn shell – `ksh`

❖ Rozšíření Bourne shellu, starší verze `ksh88` základem pro definici POSIX, jeho důležité vlastnosti jsou zabudovány rovněž v bash-i.

❖ Příkaz `alias`: `alias rm='rm -i'`.

❖ Historie příkazů: možnost vracet se k již napsaným příkazům a editovat je (bash: viz šipka nahoru a dolů a `^R`).

❖ Vylepšená aritmetika:

- příkaz `let`, např. `let "x=2*2"`,
- operace: `+ - * / % ! < > <= >= == != = ++`,
- vyhodnocení bez spouštění dalšího procesu,
- zkrácený zápis, bez expanze cest:

```
(( x=2 ))
(( x=2*x ))
(( x++ ))
echo $x
```

❖ Vylepšené testování:

```
[[ ]]
(výraz)
výraz && výraz
výraz || výraz
```

Dodatečné operátory == a =~ pro práci s regulárními výrazy, zbytek stejně jako `test`.

❖ Substituce příkazů:

```
‘command‘       $(command)
```

❖ Speciální znak “vlnovka”:

`~`	`$HOME`	domovský adresář
`~user`		domovský adresář daného uživatele
`~+`	`$PWD`	pracovní adresář
`~-`	`$OLDPWD`	předchozí prac. adresář

❖ Primitivní menu:

```
select identifikátor [in seznam slov]
do
    seznam příkazů
done
```

– funguje jako cyklus; nutno ukončit!

❖ Pole:

```
declare -a p          # pole (deklarace nepovinná)
p[1]=a
echo ${p[1]}
p+=(b c)              # přidání prvků
echo ${p[*]}
p=([1]=er [2]=rror) # celé pole
p+=([5]=c [6]=d)    # přidání na pozici

declare -A q          # asociativní pole (deklarace povinná!)
q[abc]=xyz
q[def]=mno
echo ${q[*]}
echo ${!q[*]}         # použité klíče
```

❖ Příkaz `printf`: formátovaný výpis na standardní výstup.

❖ Zásobník pro práci s adresáři:

- `pushd` – uložení adresáře do zásobníku,
- `popd` – přechod do adresáře z vrcholu zásobníku,
- `dirs` – výpis obsahu zásobníku.

❖ Příkaz `set`

- bez parametrů vypíše proměnné,
- jinak nastavuje vlastnosti shellu:

parametr	akce
`-n`	neprovádí příkazy
`-u`	chyba pokud proměnná není definována
`-v`	opisuje čtené příkazy
`-x`	opisuje prováděné příkazy
`--`	další znaky jsou argumenty skriptu

- vhodné pro ladění skriptů.

❖ Příklady:

```
set -x -- a b c *
for i ; do echo $i; done
```

❖ Zpracování přepínačů – `getopts`:

```
# Handling options a, b with a parameter, c.

while getopts :ab:c o
do      case "$o" in
        a)      echo "Option 'a' found.";;
        b)      echo "Option 'b' found with parameter '$OPTARG'.";;
        c)      echo "Option 'c' found.";;
        *)      echo "Use options a, b with a parameter, or c." >&2
                exit 1;;
        esac
done

((OPTIND--))

shift $OPTIND

echo "Remaining arguments: '$*'"
```

Omezení zdrojů

❖ Restricted shell: zabránění shellu (a jeho uživateli) provádět jisté příkazy (použití `cd`, přesměrování, změna `PATH`, spouštění programů zadaných s cestou, použití `exec`...).

❖ `ulimit`: omezení prostředků dostupných shellu a procesům z něj spuštěným (počet procesů, paměť procesu, počet otevřených souborů, ...).

❖ `quota`: omezení diskového prostoru pro uživatele.

Funkce

- Definice funkce:

```
function ident ()
{
    seznam příkazů
}
```

- Parametry jako u skriptu: `$1` ...

- Ukončení funkce s `exit-code`: `return [exit-code]`.

- Definice lokální proměnné: `typeset prom`.

- Možnost rekurze.

Správa prací – job control

- Job (úloha) v shellu odpovídá prováděné koloně procesů (pipeline).
- Při spuštění kolony se vypíše `[jid] pid`, kde `jid` je identifikace úlohy a `pid` identifikace posledního procesu v koloně.
- Příkaz `jobs` vypíše aktuálně prováděné úlohy.
- Úloha může být spuštěna na popředí, nebo pomocí `&` na pozadí.
- Úloha běžící na popředí může být pozastavena pomocí `^Z` a přesunuta na pozadí pomocí `bg` (a zpět pomocí `fg`).
- Explicitní identifikace úlohy v rámci `fg`, `bg`, `kill`,...: %jid

Interaktivní a log-in shell

❖ Shell může být spuštěn v různých režimech – pro bash máme dva významné módy, které se mohou kombinovat:

- interaktivní bash (parametr `-i`, typicky vstup/výstup z terminálu) a
- log-in shell (parametr `-l` či `-login`).

❖ Start, běh a ukončení interpretu příkazů závisí na režimu v němž shell běží. Např. pro interaktivní log-in bash platí:

1. úvodní sekvence: `/etc/profile` (existuje-li) a dále `~/.bash_profile`, `~/.bash_login`, nebo `~/.profile`,
2. tisk `$PS1`, zadávání příkazů,
3. `exit`,`^D`,`logout` – ukončení interpretu s provedením `~/.bash_logout`.

❖ Výběr implicitního interpretu příkazů:

- `/etc/passwd`
- `chsh` – change shell

Shrnutí expanzí v shellu

- Při provádění příkazu shell provádí následující expanze:
  1. Zleva doprava rozvoj
     - složených závorek (např. `a{b,c,d}e` na `abe ace ade`) – není ve standardu,
     - vlnovek,
     - proměnných,
     - vložených příkazů a
     - aritmetických výrazů `$((...))`.
  2. Rozčlenění na argumenty dle `IFS`.
  3. Rozvoj jmen souborů.
  4. Odstranění kvotování.

Utility UNIXu

❖ Utiliy UNIXu:

- užitečné programy (asi 150),
- součást normy SUSv3/v4,
- různé nástroje na zpracování textu atd.

❖ Přehled základních programů:

`awk`	jazyk pro zpracování textu, výpočty atd.
`cmp`	porovnání obsahu souborů po bajtech
`cut`	výběr sloupců textu
`dd`	kopie (a konverze) části souboru
`bc`	kalkulátor s neomezenou přesností

Pokračování na dalším slajdu...

❖ Přehled základních programů – pokračování...

`df`	volné místo na disku
`diff`	rozdíl textových souborů (viz i `tkdiff`)
`du`	zabrané místo na disku
`file`	informace o typu souboru
`find`	hledání souborů
`grep`	výběr řádků textového souboru
`iconv`	překódování znakových sad
`nl`	očíslování řádků
`od`	výpis obsahu binárního souboru
`patch`	oprava textu podle výstupu `diff`
`sed`	neinteraktivní editor textu
`sort`	řazení řádků
`split`	rozdělení souboru na menší
`tr`	záměna znaků v souboru
`uniq`	vynechání opakujících se řádků
`xargs`	zpracování argumentů (např. po `find`)

Program `grep`

- Umožňuje výběr řádků podle regulárního výrazu.

- Existují tři varianty:
  - `fgrep` – rychlejší, ale neumí regulární výrazy
  - `grep` – základní regulární výrazy
  - `egrep` – rozšířené regulární výrazy

- Příklady použití:

```
fgrep -f seznam  soubor
grep '^ *[A-Z]'  soubor
egrep '(Jan|Honza) +Novák'  soubor
```

- Rozšířené (extended) regulární výrazy:

znak	význam
+	$1-n$ výskytů předchozího podvýrazu
?	$0-1$ výskyt předchozího podvýrazu
{m}	m výskytů předchozího podvýrazu
{m,n}	$m-n$ výskytů předchozího podvýrazu
(*r*)	specifikuje podvýraz, např: `(ab*c)*`
|	odděluje dvě varianty, např: `(ano|ne)?`

Manipulace textu

❖ Program `cut` – umožňuje výběr sloupců textu.

```
cut -d: -f1,5 /etc/passwd
cut -c1,5-10 soubor  # znaky na pozici 1 a 5-10
```

❖ Program `sed`:

- Neinteraktivní editor textu (streaming editor).
- Kromě základních editačních operací umožňuje i podmíněné a nepodmíněné skoky (a tedy i cykly) a práci s registrem.

```
sed 's/novák/Novák/g'  soubor
sed 's/^[^:]*/-/'  /etc/passwd
sed -e "/$xname/p" -e "/|/d"  soubor_seznam
sed '/tel:/y/0123456789/xxxxxxxxxx/'  soubor
sed -n '3,7p'  soubor
sed '1a\
tento text bude přidán na 2. řádek'  soubor
sed -n '/start/,/stop/p' soubor
```

❖ Program `awk`:

- AWK je programovací jazyk vhodný pro zpracování textu (často strukturovaného do tabulek), výpočty atd.

```
awk '{s+=$1}END{print s}' soubor_cisel
awk '{if(NF>0){s+=$1;n++}}
     END{print n " " s/n}' soubor_cisel
awk -f awk-program  soubor
```

❖ Program `paste`:

- Spojení odpovídajících řádků vstupních souborů.

```
paste -d\| sloupec1.txt sloupec2.txt
```

Porovnání souborů a patchování

- Program `cmp`:
  - Porovná dva soubory nebo jejich části byte po bytu.

```
cmp soubor1 soubor2
```

- Program `diff`:
  - Výpis rozdílů textových souborů (porovnává řádek po řádku).

```
diff old.txt new.txt
diff -C2 old.c new.c
diff -u2 old.c new.c
diff -urN dir1 dir2
```

- Program `patch`:
  - Změna textu na základě výstupu z programu `diff`.
  - Používá se pro správu verzí programů (cvs, svn, ...).

Hledání souborů

❖ Program `find`:

- Vyhledání souborů podle zadané podmínky a provedení určitých akcí nad nalezenými soubory.

```
find . -name '*.c'
find / -type d
find / -size +1000000c -exec ls -l {} \;
find / -size +1000000c -execdir command {} \;
find / -type f -size -2 -print0 | xargs -0 ls -l
find / -type f -size -2 -exec ls -l {} +
find . -mtime -1
find . -mtime +365 -exec ls -l {} \;
```

Řazení

- Program `sort`:
  - seřazení řádků.

```
sort  soubor
sort  -u  -n  soubor_čísel
sort  -t:  -k3,3n  /etc/passwd
```

- Program `uniq`:
  - odstranění duplicitních řádků ze seřazeného souboru.

- Program `comm`:
  - výpis unikátních/duplicitních řádků seřazených souborů.

```
comm soubor1 soubor2 # 3 sloupce
comm  -1 -2  s1 s2   # jen duplicity
comm  -2 -3  s1 s2   # pouze v s1
```

Další nástroje programátora

- skriptovací jazyky a interprety (perl, python, tcl, ...)
- překladače (cc/gcc, c++/g++, ...)
- assemblery (nasm, ...)
- linker `ld` (statické knihovny `.a`, dynamické knihovny `.so`)
  - výpis dynamických knihoven používaných programem: `ldd`,
  - knihovny standardně v `/lib` a `/usr/lib`,
  - cesta k případným dalším knihovnám: `LD_LIBRARY_PATH`,
  - run-time sledování funkcí volaných z dynamických knihoven: `ltrace`.

- Program `make`:
  - automatizace (nejen) překladu a linkování,
  - příklad souboru `makefile` (pozor na odsazení tabelátory):

```
test: test.o tisk.o
        gcc $(CFLAGS) -o test test.o tisk.o

test.o: test.c
        gcc $(CFLAGS) -c test.c

tisk.o: tisk.c
        gcc $(CFLAGS) -c tisk.c

clean:
        rm -f *.o test
```

  - použití: `make`, `make CFLAGS=-g`, `make clean`.

- automatizovaná konfigurace – GNU `autoconf`:
  - Generuje na základě šablony založené na volání předpřipravených maker skripty pro konfiguraci překladu (určení platformy, ověření dostupnosti knihoven a nástrojů, nastavení cest, ...), překlad a instalaci programů šířených ve zdrojové podobě.
  - Používá se mj. spolu s `automake` (usnadnění tvorby makefile) a `autoscan` (usnadnění tvorby šablon pro `autoconf`).
  - Použití vygenerovaných skriptů: `./configure`, `make`, `make install`
- ladění: debugger např. `ddd` postavený na `gdb` (překlad s ladícími informacemi `gcc -g ...`)
- sledování volání jádra: `strace`
- profiling: profiler např. `gprof` (překlad pomocí `gcc -pg ...`)

Operační systémy

IOS 2020/2021

Tomáš Vojnar

vojnar@fit.vutbr.cz

Vysoké učení technické v Brně
Fakulta informačních technologií
Božetěchova 2, 612 66 Brno

Správa souborů

Pevný disk

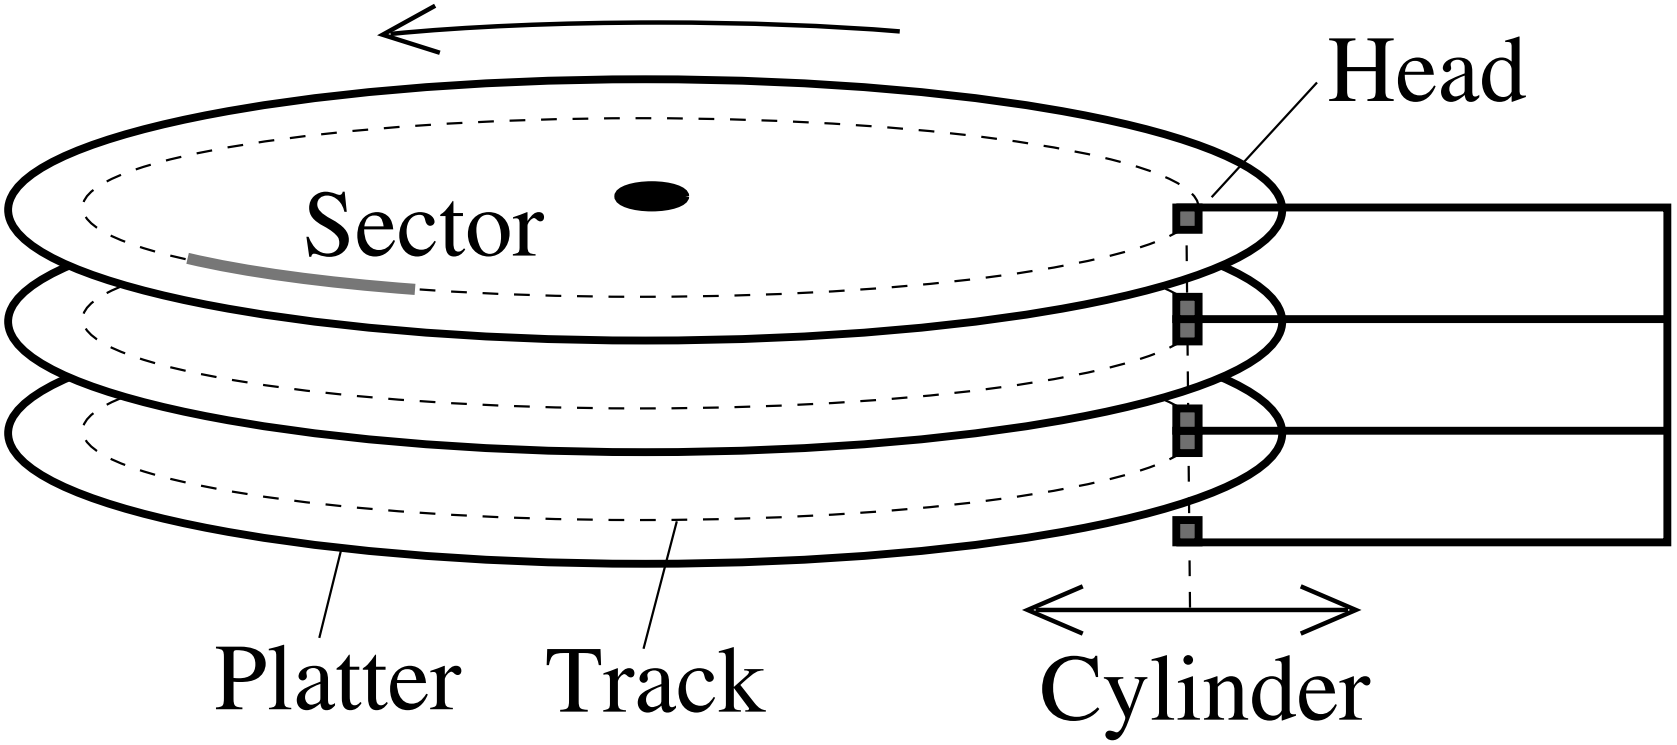

- Diskový sektor: nejmenší jednotka, kterou disk umožňuje načíst/zapsat.
- Velikost sektoru: dříve 512B, 2048B CD/DVD/BD, nyní 4096B (příp. emulace 512B).
- Adresace sektorů:
  - CHS = Cylinder, Head (typicky 1-6 hlav), Sector
  - LBA = Linear Block Address (číslo 0..N)

❖ Pro připojení disků se používá řada různých diskových (či obecněji periferních) rozhraní: primárně ATA/PATA/SATA či SCSI/SAS, ale také USB, FireWire, FibreChannel, Thunderbolt, PCI Express aj.

- Nad nimi může být další HW rozhraní jako AHCI, OHCI, UHCI, EHCI, xHCI, NVMe, které je připojí k vyšším sběrnicím.

❖ Diskové sběrnice se liší mj. rychlostí (např. SATA fyzicky 6 Gb/s, data 600 MB/s, SAS fyzicky 22.5 Gb/s, data 2.25 GB/s), počtem připojitelných zařízení (desítky SATA/65535 SAS), max. délkou kabelů (1–2m SATA, 10m SAS), architekturou připojení (např. více cest k zařízení u SAS), podporovanými příkazy (flexibilita při chybách).

❖ Stejným způsobem jako disky mohou být zpřístupněny i jiné typy pamětí: flash disky, SSD, pásky, CD/DVD/BD, ...

❖ Vzniká hierarchie pamětí, ve které stoupá kapacita a klesá rychlost a cena/B:

- primární paměť: RAM (nad ní ještě registry, cache L1-L3),
- sekundární paměť: pevné disky, SSD (mají také své cache),
- terciární paměť: pásky, CD, DVD, BlueRay, ... (externí disk, síťový disk, cloud).

Parametry pevných disků

❖ Přístupová doba = doba vystavení hlav + rotační zpoždění.

❖ Typické parametry současných disků (orientačně – neustále se mění):

kapacita	do 20 TB
průměrná doba přístupu	od nízkých jednotek ms
otáčky	4200-15000/min
přenosová rychlost	desítky až nízké stovky MB/s

❖ U kapacity disku udávané výrobcem/prodejcem je třeba dávat pozor, jakým způsobem ji počítá: GB = 10^9B nebo $1000 * 2^{20}$B nebo ... Správně: GiB = $1024^3 = 2^{30}$B.

❖ U přenosových rychlostí pozor na sustained transfer rate (opravdové čtení z ploten) a maximum transfer rate (z bufferu disku).

❖ Možnost měření přenosových rychlostí: `hdparm -t`.

- `hdparm` umožňuje číst/měnit celou řadu dalších parametrů disků.
- Pozor! `hdparm -T` měří rychlost přenosu z vyrovnávací paměti OS (tedy z RAM).

Solid State Drive – SSD

❖ SSD je nejčastěji založeno na nevolatilních pamětech NAND flash, ale vyskytují se i řešení založená na DRAM (se zálohovaným napájením) či na kombinacích.

❖ Výhody SSD:

- rychlý (v zásadě okamžitý) náběh,
- náhodný přístup – přístupová doba od jednotek μs (DRAM) do desítek či nízkých stovek μs,
- větší přenosové rychlosti – stovky MB/s (do cca 600 MB/s, 7 GB/s s M.2), zápis může být (mírně) pomalejší (viz dále).
- tichý provoz, mechanická a magnetická odolnost, ...,
- obvykle nižší spotřeba (neplatí pro DRAM).

❖ Nevýhody SSD:

- vyšší cena za jednotku prostoru (dříve nižší kapacita, dnes až 100 TB),
- omezený počet přepisů (nevýznamné pro běžný provoz),
- větší riziko katastrofického selhání, menší výdrž mimo provoz,
- možné komplikace se zabezpečením (např. bezpečné mazání/šifrování přepisem dat vyžaduje speciální podporu – disk může data sám přesouvat přes několik míst).

Problematika zápisu u SSD

❖ NAND flash SSD jsou organizovány do stránek (typicky 4KiB) a ty do bloků (typicky 128 stránek, tj. 512KiB).

❖ Prázdné stránky lze zapisovat jednotlivě. Pro přepis nutno načíst celý blok do vyrovnávací paměti, v ní změnit, na disku vymazat a pak zpětně zapsat.

- Problém je menší při sekvenčním než při náhodném zápisu do souboru.

❖ Řešení problémů s přepisem v SSD:

- Aby se problém minimalizoval, SSD může mít více stránek, než je oficiální kapacita.
- Příkaz TRIM umožňuje souborovému systému sdělit SSD, které stránky nejsou používány a následně vymazat bloky tvořené takovými stránkami.
- Řadič SSD může také sám interně přesouvat stránky, aby mohl některé bloky uvolnit.
- Přesto jistý rozdíl v rychlosti čtení/zápisu může zůstat.
- TRIM navíc nelze užít vždy (souborové systémy uložené jako obrazy, kde nemusí být možné uvolňovat bloky, které nejsou na samém konci obrazu; podobně u RAID či databází ukládajících si data do velkého předalokovaného souboru).

❖ Aby řadič SSD minimalizoval počet přepisů stránek, může přepisovanou stránku zapsat na jinou pozici; případně i přesouvá dlouho neměněné stránky.

Zabezpečení disků

❖ Disková elektronika používá ECC = Error Correction Code: k užitečným datům sektoru si ukládá redundantní data, která umožňují opravu (a z hlediska OS transparentní realokaci), nebo alespoň detekci chyb.

❖ S.M.A.R.T. – Self Monitoring Analysis and Reporting Technology: disky si automaticky shromažďují řadu statistik, které lze použít k předpovídání/diagnostice chyb. Viz `smartctl`, `smartd`, ...

❖ Rozpoznávání a označování vadných bloků (bad blocks) může probíhat také na úrovni OS (např. `e2fsck` a `badblocks`), pokud si již s chybami disk sám neporadí (což je ale možná také vhodná doba disk raději vyměnit).

Disková pole

❖ RAID (Redundant Array of Independent Disks):

- RAID 0 – *disk striping*, následné bloky dat rozmístěny na různých discích, vyšší výkonnost, žádná redundance.
- RAID 1 – *disk mirroring*, všechna data ukládána na dva disky, velká redundance (existuje také RAID 0+1 a RAID 1+0/10).
- RAID 2 – data rozdělena mezi disky po bitech, použito zabezpečení Hammingovým kódem uloženým na zvláštních discích (např. 3 bity zabezpečení pro 4 datové: chybu na 1 disku lze automaticky opravit, na 2 discích detekovat).
- RAID 3 – data uložena po bajtech (nebo i bitech) na různých discích, navíc je užit disk s paritami.
- RAID 4 – bloky (sektory či jejich násobky) dat na různých discích a paritní bloky na zvláštním disku.
- RAID 5 – jako RAID 4, ale paritní a datové bloky jsou rozloženy na všech discích, redukce kolizí u paritního disku při zápisu.
- RAID 6 – jako RAID 5, ale parita uložena 2x, vyrovná se i se ztrátou 2 disků.

Uložení souboru na disku

❖ Alokační blok: skupina pevného počtu sektorů, typicky 2^n pro nějaké n, následujících logicky (tj. v souboru) i fyzicky (tj. na disku) za sebou, která je nejmenší jednotkou diskového prostoru, kterou OS čte či zapisuje při běžných operacích.

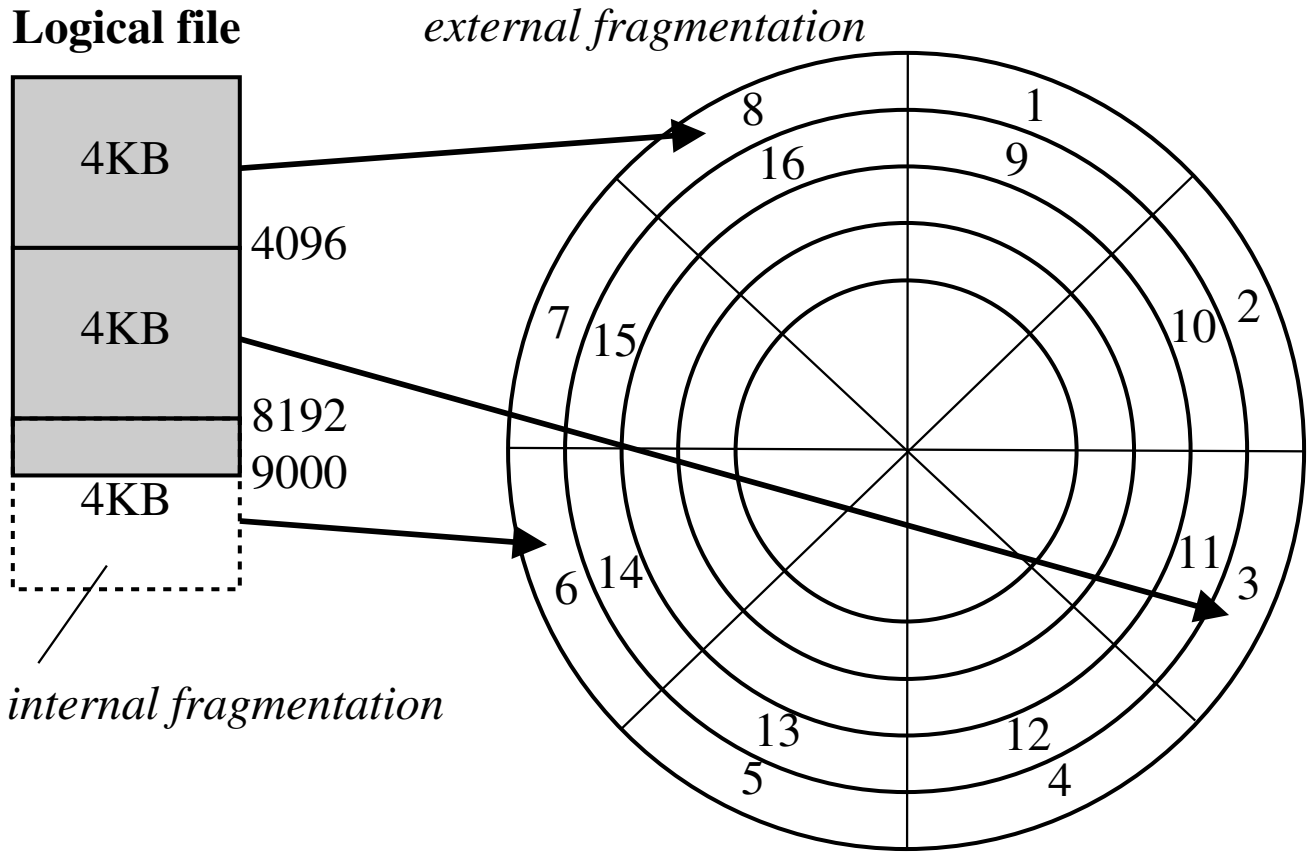

❖ Poznámka: Někdy se též užívá označení cluster.

Fragmentace

❖ Při přidělování a uvolňování prostoru pro soubory dochází k tzv. externí fragmentaci – na disku dochází k proložení volných oblastí a oblastí použitých různými soubory (může tedy existovat i na plně obsazeném disku), což má dva možné důsledky:

1. Vzniknou nevyužité oblasti diskového prostoru, které se nedají využít (a) v daném okamžiku nebo (b) vůbec.
   - Případ (a): pokud se použije *spojité přidělování* prostoru pro soubory, může na disku být v sumě dost místa pro uložení daného souboru, ale žádná volná oblast sama o sobě nepostačuje a soubor tedy nelze uložit.
   - Případ (b): pokud *není prostor přidělován v násobcích dostatečně velké jednotky prostoru* a současně je zapotřebí do každého alokovaného prostoru uložit kromě užitečného obsahu ještě metadata, nemusí být prostor dostatečný ani na uložení metadat (a pak je zcela nevyužitelný).
2. Při nespojitém přidělování prostoru po dostatečně velkých alokačních blocích výše uvedený problém nevzniká, ale data/metadata souboru jsou na disku uložena nespojitě – složitější a pomalejší přístup (menší vliv u SSD, ale i tam se může projevit).

Fragmentace

❖ Souborové systémy užívají různé techniky k minimalizaci externí fragmentace:

- rozložení souborů po disku: tedy neukládají soubory bezprostředně za sebe, je-li to možné;
- předalokace: alokuje se více místa, než je momentálně zapotřebí (např. `fallocate` na Linuxu);
- odložená alokace: odkládá zápis, než se nasbírá více požadavků a je lepší povědomí, kolik je třeba alokovat (např. "allocate-on-flush" v různých soborových systémech).

❖ Přesto bývají k dispozici nástroje pro defragmentaci.

❖ Interní fragmentace – nevyužité místo v posledním přiděleném alokačním bloku – plýtvání místem.

- Některé souborové systémy (např. Btrfs) umožňují sdílení posledních alokačních bloků více soubory.

Přístup na disk

❖ Prostřednictvím I/O portů a/nebo paměťově mapovaných I/O operací (HW zajišťuje, že některé adresy RAM ve skutečnosti odkazují do interní paměti I/O zařízení) se řadiči disku předávají přes příslušné sběrnice a HW rozhraní příkazy definované diskovým rozhraním (ATA/SCSI/... + AHCI/.../NVMe).

❖ Přenos z/na disk je typicky řízen řadičem disku s využitím technologie přímého přístupu do paměti (DMA). O ukončení operací či chybách informuje řadič procesor (a na něm běžící jádro OS) pomocí přerušení.

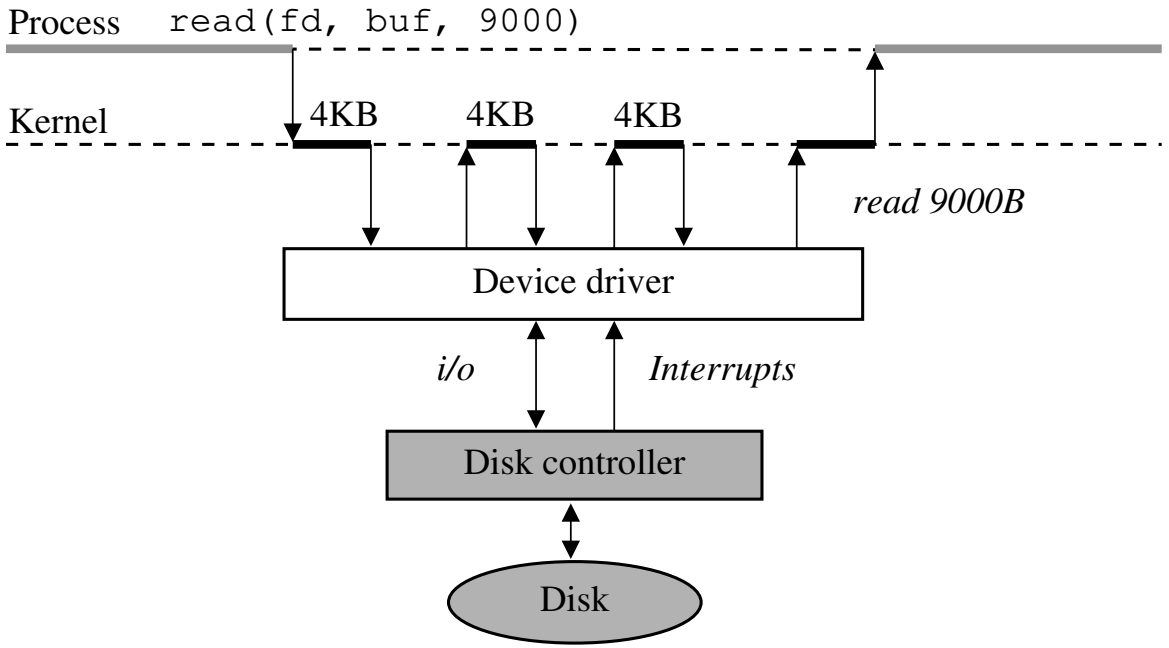

Plánování přístupu na disk

- Pořadí bloků čtených/zapisovaných na disk ovlivňuje plánovač diskových operací.
  - (1) Požadavky na čtení/zápis ukládá do vyrovnávací paměti a (2) jejich pořadí případně mění tak, aby se minimalizovala režie diskových operací.
  - Např. tzv. výtahový algoritmus (elevator algorithm, SCAN algorithm) pohybuje hlavičkami od středu k okraji ploten a zpět a vyřizuje požadavky v pořadí odpovídajících pozici a směru pohybu hlaviček.
  - Další plánovací algoritmy: Circular SCAN (vyřizuje požadavky vždy při pohybu jedním směrem – rovnoměrnější doba obsluhy), LOOK (pohybuje se jen v mezích daných aktuálními požadavky – nižší průměrná doba přístupu), C-LOOK, ...
  - Plánovač dále může sdružovat operace, vyvažovat požadavky různých uživatelů, implementovat priority operací, odkládat operace v naději, že je bude možno později propojit, implementovat časová omezení možného čekání operací na provedení apod.
  - Možnost více vstupních front z různých CPU i více výstupních front pro paralelní zpracování zařízením (Linux: `blk-mq`).

- V Linuxu možno zjistit/změnit nastavení prostřednictvím `/sys/block/<devicename>/queue/scheduler`.

Logický disk

❖ Dělení fyzického disku na logické disky – diskové oblasti (partitions), na které se instaluje následně souborový systém:

- Starší systémy PC: MBR (Master Boot Record) – tabulka diskových oblastí s 1-4 primárními diskovými oblastmi, jedna z nich může být nahrazena rozšířenou diskovou oblastí, obsahující zřetězený seznam logických diskových oblastí, každou z nich popsanou EBR (Extended Boot Record).
- Novější PC: GUID Partition Table (GPT) – vynechaný prostor pro MBR, hlavička GPT a následně pole 128 odkazů na logické diskové oblasti. Zabezpečeno kontrolními součty, s rezervní kopií GPT. GUID = Globally Unique Identifier fyzických/logických disků, založeno např. na kryptografii.
- Pro správu diskových oblastí lze užít programy `cfdisk`, `fdisk`, `gparted`, ...
- LVM = Logical Volume Manager: umožňuje tvorbu logických disků přesahujících hranice fyzického disku, snadnou změnu velikosti, přidávání a ubírání disků, tvorbu snímků, ... (někdy přímo v souborovém systému: ZFS).

❖ Formátování – program `mkfs`; existuje (existovalo) také nízkoúrovňové formátování.

❖ Kontrola konzistence souborového systému: program `fsck`.

❖ Různé typy souborových systémů: fs, ufs, ufs2, ext2, ext3, ext4, Btrfs, HFS+/APFS (Mac OS X), XFS (od Silicon Graphics, původně pro IRIX), JFS (od IBM, původně pro AIX), ZFS (od Sunu, původně pro OpenSolaris), HPFS, FAT, VFAT, FAT32, ExFAT, NTFS, ReFS, F2FS, ISO9660 (Rock Ridge, Joliet), UDF, Lustre (Linuxové clustry a superpočítače), GPFS (clustry a superpočítače), zonefs (disk rozdělen na sekvenčně zapisované či kompletně mazané zóny)...

❖ Virtuální souborový systém (VFS) – vrstva, která zastřešuje všechny použité souborové systémy a umožňuje pracovat s nimi jednotným, abstraktním způsobem.

❖ Síťové souborové systémy: NFS, ...

❖ Speciální souborové systémy: procfs, sysfs (souborové systémy informující o dění v systému a umožňující nastavení jeho parametrů), tmpfs (souborový systém alokující prostor v RAM a sloužící pro ukládání dočasných dat), unionfs, autofs, ...

Žurnálování

- Žurnál slouží pro záznam modifikovaných metadat (příp. i dat) před jejich zápisem na disk.
  - Obvykle implementován jako cyklicky přepisovaný buffer ve speciální oblasti disku.
  - Operace pokryté žurnálováním jsou atomické – vytváří transakce: buď uspějí všechny jejich dílčí kroky nebo žádný.
    - Např. mazání souboru v UNIXU znamená odstranění záznamu z adresáře, pak uvolnění místa na disku.

- Systémy souborů se žurnálem: ext3, ext4, ufs, XFS, JFS, NTFS, ...

- Umožňuje spolehlivější a rychlejší návrat do konzistentního stavu po chybách.

- Data obvykle nejsou žurnálována (byť mohou být): velká režie.

- Kompromis mezi žurnálováním a nežurnálováním dat představuje předřazení zápisu dat na disk před zápis metadat do žurnálu: zajistí konzistenci při chybě během zápisu dat na konec souboru (částečně zapsaná nová data nebudou uvažována).

Implementace žurnálování

- Implementace na základě dokončení transakcí (REDO), např. ext3/4:
  - sekvence dílčích operací se uloží nejprve do žurnálu mezi značky označující začátek a konec transakce, typicky spolu s kontrolním součtem,
  - poté se dílčí operace provádí na disku,
  - uspějí-li všechny dílčí operace, transakce se ze žurnálu uvolní,
  - při selhání se dokončí všechny transakce, které jsou v žurnálu zapsány celé (a s korektním kontrolním součtem).
- Implementace na základě anulace transakcí (UNDO):
  - záznam dílčích operací do žurnálu a na disk se prokládá,
  - proběhne-li celá transakce, ze žurnálu se uvolní,
  - při chybě se eliminují nedokončené transakce.
- UNDO a REDO je možno kombinovat (NTFS).
- Implementace žurnálování musí zajišťovat správné pořadí zápisu operací, které ovlivňuje plánování diskových operací v OS a také případně jejich přeuspořádání v samotném disku.

Alternativy k žurnálování

❖ Copy-on-write (např. ZFS, Btrfs, ReFS) – nejprve zapisuje nová data či metadata na disk, pak je zpřístupní:

- Změny provádí hierarchicky v souladu s hierarchickým popisem obsahu disku:
  – vyhledávací strom popisující uložení dat a metadat na disku, ne adresářový strom;
  – data vyhledává na základě unikátní identifikace souborů a posuvu v nich.
- Začne měněným uzlem, vytvoří jeho kopii a upraví ji.
  Potom vytvoří kopii uzlu nadřazeného změněnému uzlu, upraví ji tak, aby odkazovala příslušným odkazem na uzel vytvořený v předchozím kroku atd.
- Na nejvyšší úrovni se udržuje několik verzí kořenového záznamu se zabezpečovacím kódem a časovými razítky.
  Po chybě bere kořen s nejnovějším razítkem a správným kontrolním součtem.

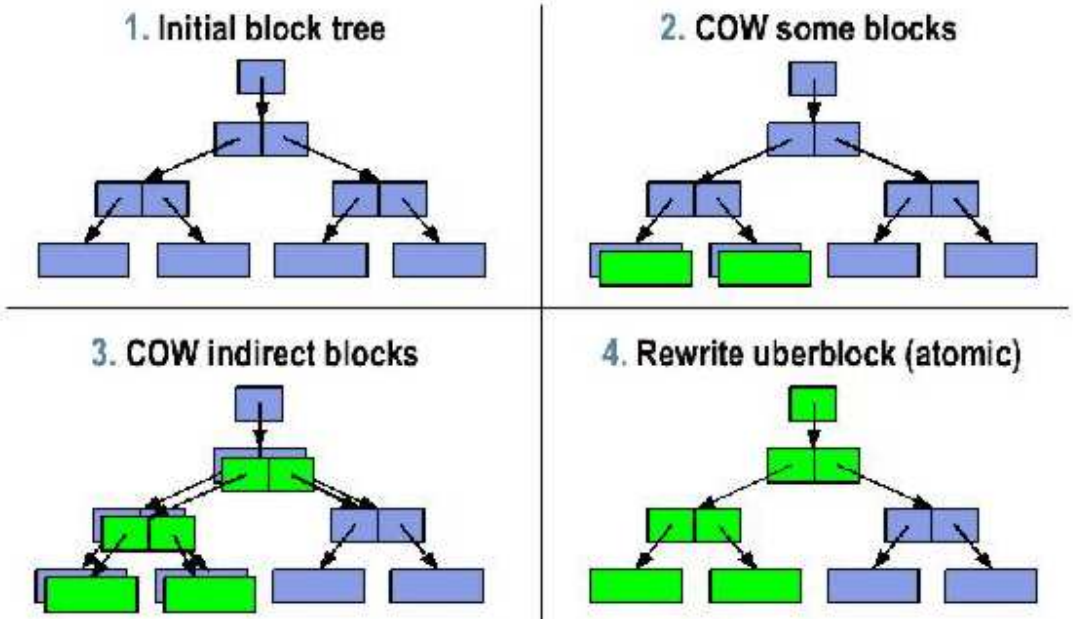

Alternativy k žurnálování

❖ Poznámka: CoW nabízí rovněž bázi pro implementaci:

- snímků souborového systému: uložení stavu v určitém okamžiku s možností pozdějšího návratu – stačí zálohovat si starší verze kořene a z něj dostupné záznamy;
- klonů souborového systému: vytvoření kopií, které jsou v budoucnu samostatně manipulovány – vzniká několik kopií kořene, které se dále mění samostatně.

V obou případech vznikají částečně sdílené stromové struktury popisujících různé verze obsahu souborového systému.

❖ Další možnosti:

- Soft updates (např. UFS): sleduje závislosti mezi změněnými metadaty a daty a zaručuje zápis na disk v takovém pořadí, aby v kterékoli době byl obsah disku konzistentní (až na možnost vzniku volného místa považovaného za obsazené).
- Log-structured file systems (LFS, UDF, F2FS): celý souborový systém má charakter logu (zapsaného v cyklicky přepisované frontě) s obsahem disku vždy přístupným přes poslední záznam (a odkazy z něj).

Klasický UNIXový systém souborů (FS)

boot blok	pro zavedení systému při startu
super blok	informace o souborovém systému (typ, velikost, počet i-uzlů, volné místo, volné i-uzly, kořenový adresář, UUID, ...)
tabulka i-uzlů	tabulka s popisy souborů
datové bloky	data souborů a bloky pro nepřímé odkazy

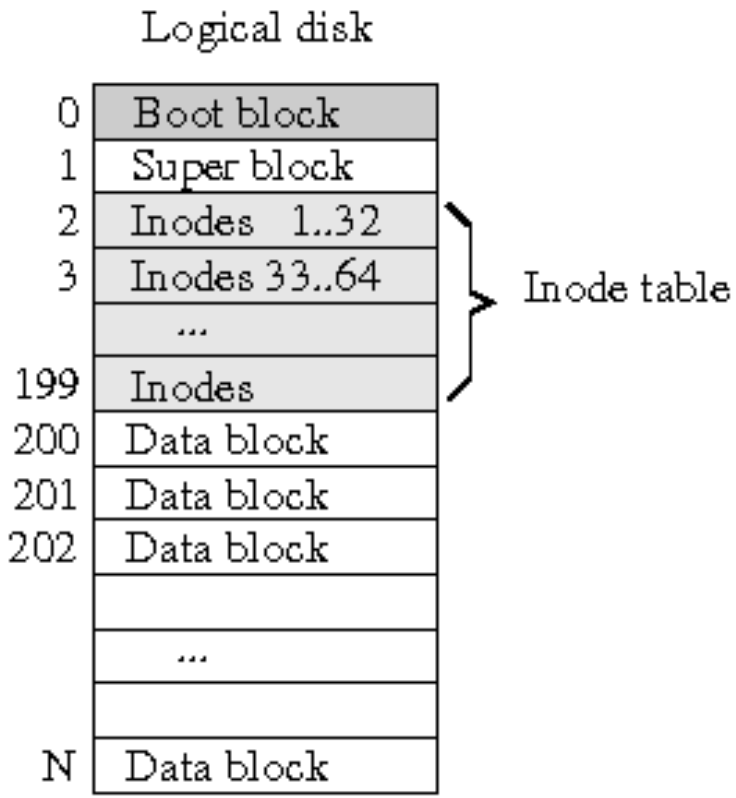

❖ Modifikace základního rozložení FS v navazujících souborových systémech:

- Disk rozdělen do skupin bloků.
- Každá skupina má své i-uzly a datové bloky a také svůj popis volných bloků: lepší lokalita.
- Superblok se základními informacemi o souborovém systému je rovněž uložen vícenásobně.

i-uzel

❖ Základní datová struktura popisující soubor v UNIX-ových souborových systémech.

- obsahuje metadata, ve speciálních případech i data (např. symbolický odkaz),
- jiné souborové systémy mívají analogické struktury: např. záznam v MFT u NTFS.

❖ U FS, ext2, ext3 (více modifikováno ext4, btrfs, ...):

- stav i-uzlu (alokovaný, volný)
- typ souboru (obyčejný, adresář, zařízení, ...)
- délka souboru v *bajtech*
- mtime = čas poslední modifikace dat
- atime = čas posledního přístupu
- ctime = čas poslední modifikace i-uzlu
- UID = identifikace vlastníka (číslo)
- GID = identifikace skupiny (číslo)
- přístupová práva (číslo, například 0644 znamená rw-r–r–)
- počet pevných odkazů (jmen)
- tabulka odkazů na datové bloky:

10	přímých odkazů (12 u ext2, ...)
1	nepřímý odkaz první úrovně
1	nepřímý odkaz druhé úrovně
1	nepřímý odkaz třetí úrovně

- (odkaz na) další informace (ACL, extended attributes, dtime, ...)

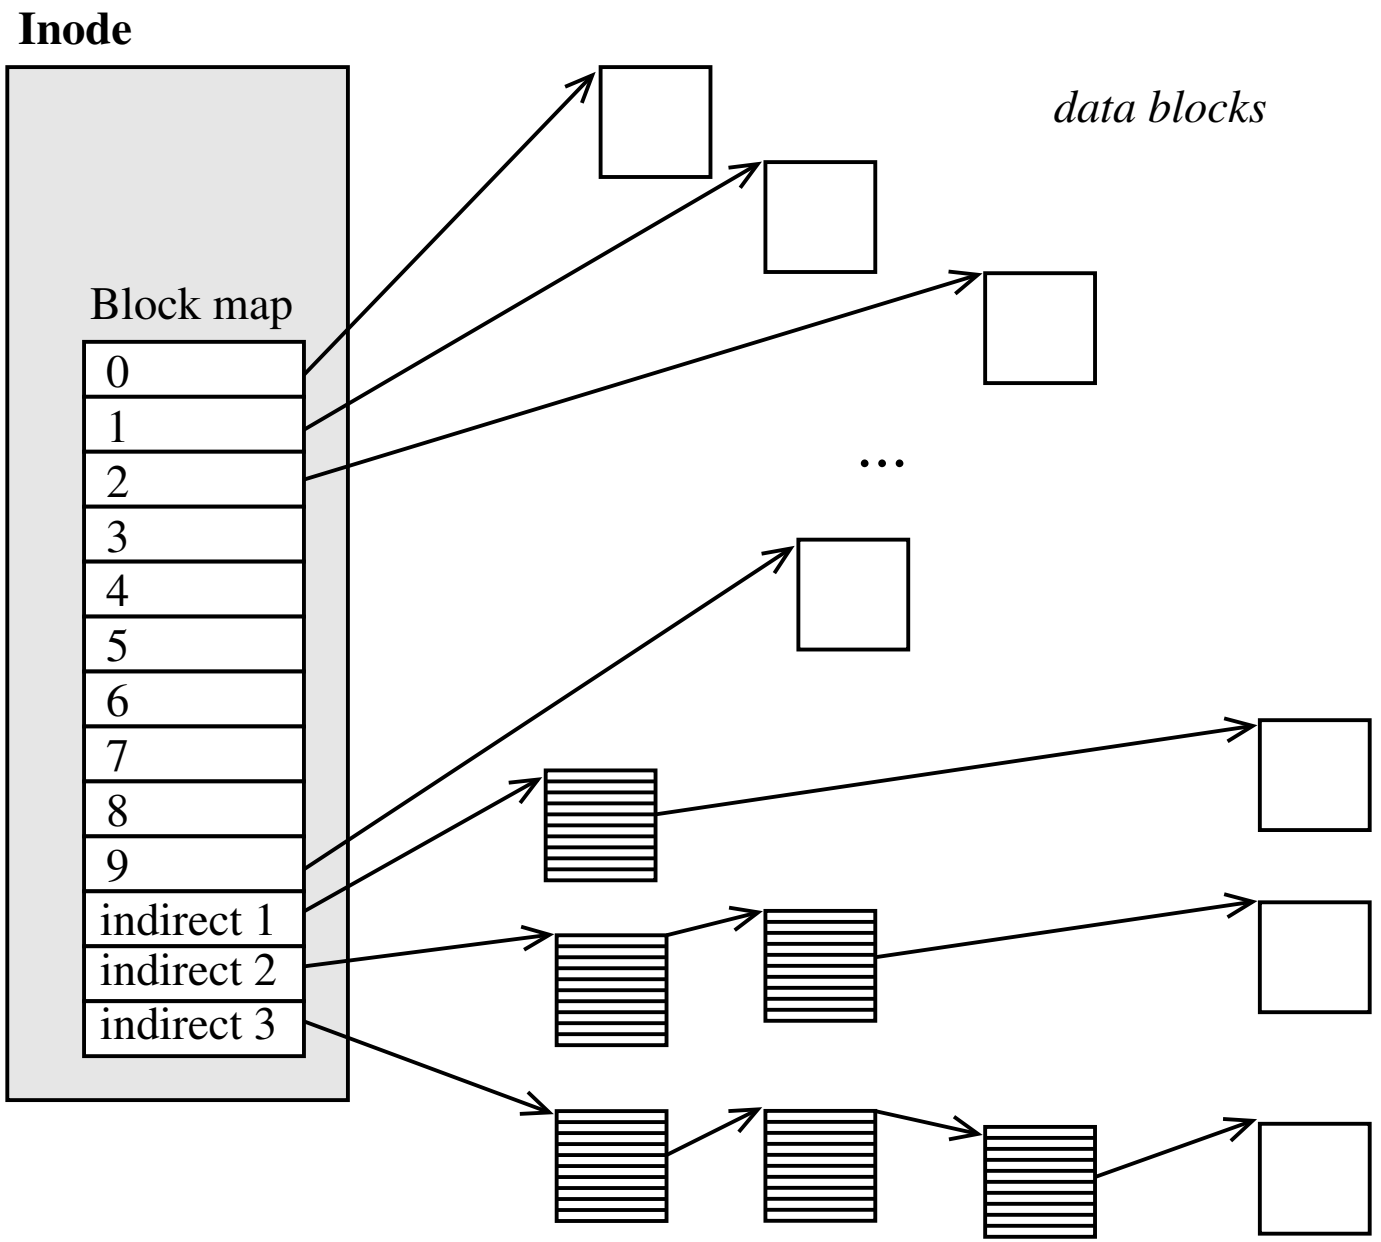
Inode
Block map
0
1
2
3
4
5
6
7
8
9
indirect 1
indirect 2
indirect 3
data blocks
...

❖ Teoretický limit velikosti souboru:

$$10 * D + N * D + N^2 * D + N^3 * D,$$

kde:

- $N = D/M$ je počet odkazů v bloku, je-li M velikost odkazu v bajtech (běžně 4B),
- D je velikost bloku v bajtech (běžně 4096B).

❖ Velikost souborů je omezena také dalšími strukturami FS, VFS, rozhraním jádra a architekturou systému (32b/64b) – viz Large File System support: podpora souborů $> 2GiB$.

❖ Co vypisují programy o velikosti souborů?

- `du soubor` – zabrané místo v blocích, včetně režie,
- `ls -l soubor` – velikost souboru v bajtech,
- `df` – volné místo na namontovaných discích.

❖ Zpřístupnění i-uzlu:

- `ls -i soubor` – číslo i-uzlu souboru soubor,
- `ils -e /dev/... n` – výpis i-uzlu n na `/dev/...`

❖ Základní informace o souborovém systému ext2/3/4: `dumpe2fs`.

❖ Popis rozložení souboru na disku je ovlivňován snahou o minimalizaci režie při práci s obsahem souboru, zejména při průchodu souborem (čtení/přepis), přesunu v souboru (seek), zvětšování/zmenšování souboru:

- snadnost *vyhledání adresy prvního/určitého bloku* souboru,
- snadnost *vyhledání následujících bloků*,
- snadnost *přidání/ubrání dalších bloků*,
- snadnost *alokace/dealokace volného prostoru*
  (informace o volných oblastech, minimalizace externí fragmentace).

❖ FS (a řada jeho následníků UFS, ext2, ext3) představuje kompromis s ohledem na převážně malé soubory.

- U větších souborů nutno procházet/modifikovat větší objem metadat.

❖ Další optimalizace pro malé soubory: data přímo v i-uzlu (např. u symbolických odkazů definovaných dostatečně krátkou cestou, tzv. fast symlinks).

Jiné způsoby organizace souborů

❖ Kontinuální uložení: jedna spojitá posloupnost na disku.

- Problémy se zvětšováním souborů díky externí fragmentaci nebo obsazení prostoru hned za koncem souboru.

❖ Zřetězené seznamy bloků: každý datový blok obsahuje kromě dat odkaz na další blok (nebo příznak konce souboru).

- Při přístupu k náhodným blokům či ke konci souboru (změna velikosti) nutno projít celý soubor.
- Chyba kdekoliv na disku může způsobit ztrátu velkého objemu dat (rozpojení seznamu).

❖ FAT (File Allocation Table): seznamy uložené ve speciální oblasti disku. Na začátku disku je (pro vyšší spolehlivost zdvojená) tabulka FAT, která má položku pro každý blok. Do této tabulky vedou odkazy z adresářů. Položky tabulky mohou být zřetězeny do seznamů, příp. označeny jako volné či chybné.

- Opět vznikají problémy s náhodným přístupem.

Jiné způsoby organizace souborů

❖ B+ stromy:

- Vnitřní uzly obsahují sekvenci $link_0, key_0, link_1, key_1, ..., link_n, key_n, link_{n+1}$, kde $key_i < key_{i+1}$ pro $0 \leq i < n$. Hledáme-li záznam s klíčem k, pokračujeme $link_0$, je-li $k < key_0$; jinak $link_i$, $1 \leq i \leq n$, je-li $key_{i-1} \leq k < key_i$; jinak užijeme key_{n+1}.
- Listy mají podobnou strukturu. Je-li $key_i = k$ pro nějaké $0 \leq i \leq n$, $link_i$ odkazuje na hledaný záznam. Jinak hledaný záznam neexistuje.
- Poslední odkaz $link_{n+1}$ v listech je užit k odkazu na následující listový uzel pro urychlení lineárního průchodu indexovanými daty.

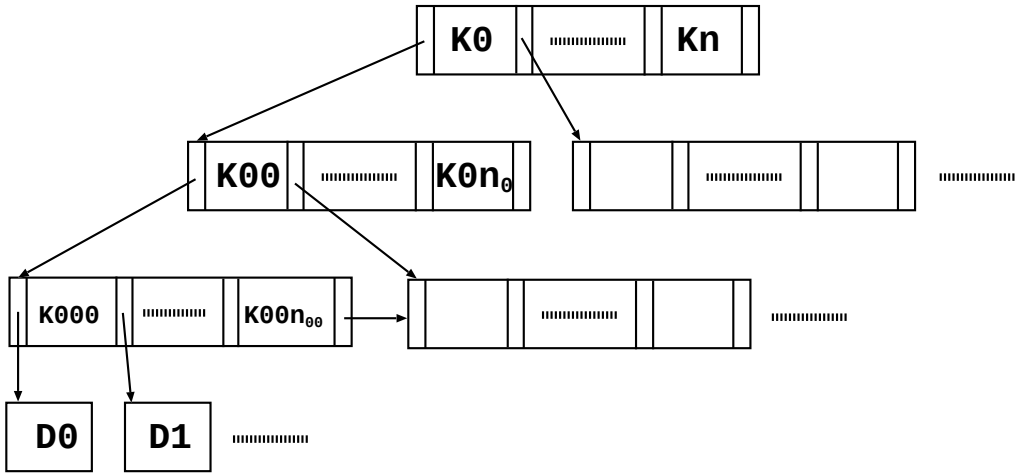

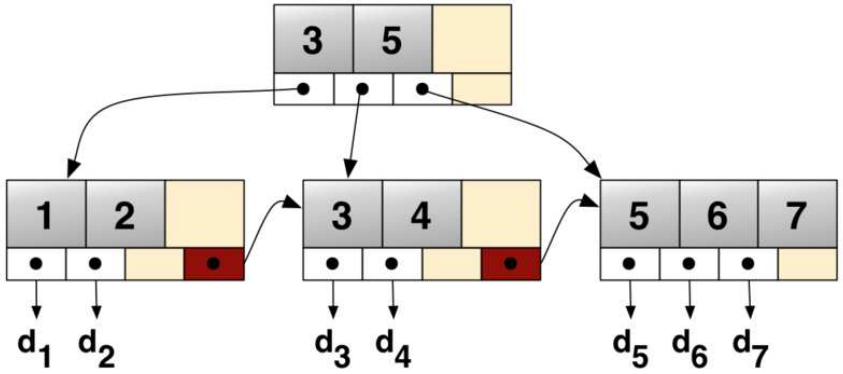

Jiné způsoby organizace souborů

❖ B+ stromy:

- Strom zůstává výškově vyvážený.
- Limity zaplnění pro uzly s m odkazy (tedy klíči key_0 až key_{m-2}): sólo kořen 1 až $m-1$, kořen 2 až m, vnitřní uzel $\lceil m/2 \rceil$ až m, list $\lceil m/2 \rceil - 1$ až $m-1$.
- Vkládá se na listové úrovni. Dojde-li k přeplnění, list se rozštěpí a přidá se nový odkaz do nadřazeného vnitřního uzlu. Při přeplnění se pokračuje směrem ke kořeni. Nakonec může být přidán nový kořen.
- Ruší se od listové úrovně. Při nenaplnění minimální kapacity, pokus o přerozdělení mezi sourozenci (potomky předka uzlu, ve kterém se ruší odkaz). Nestačí-li, sourozenci se spojí a ruší se jeden odkaz na nadřazené úrovni. Nutno upravit klíče. Rušení může pokračovat směrem ke kořeni. Nakonec může jedna úroveň ubýt.

❖ B+ stromy a jejich různé varianty jsou použity pro popis diskového prostoru přiděleného souborům v různých souborových systémech:

- XFS, JFS, ZFS, Btrfs, APFS, ReFS, ...,
- omezená analogie v podobě tzv. stromů extentů v ext4, podobně i v NTFS.

Jiné způsoby organizace souborů

❖ Alokovaný prostor se často indexuje po tzv. extentech, tj. posloupnostech proměnného počtu bloků jdoucích za sebou logicky v souboru a uložených i fyzicky na disku za sebou:

- zrychluje se práce s velkými soubory: menší, lépe vyvážené indexové struktury; menší objem metadat, které je třeba procházet a udržovat; lepší lokalita dat i metadat.

❖ Extenty jsou použity ve všech výše zmíněných systémech s B+ stromy a jejich variantami.

- B+ stromy se snadno kombinují s extenty. To neplatí pro klasický Unixový strom, který není kompatibilní s adresováním jednotek proměnné velikosti.
  - Pro bloky proměnné velikosti není kam ve vyhledávací struktuře uložit jejich velikost.

❖ Spojitému průchodu může pomoci prolinkování listů vyhledávacích stromů, je-li použito.

❖ Pro malé soubory může B+ strom představovat zbytečnou režii:
přímé uložení v i-uzlu nebo přímé odkazy na extenty z i-uzlu (do určitého počtu).

Ext4 – strom extentů

- Analogie B+ stromu bez vyvažování a bez zřetězení listů:

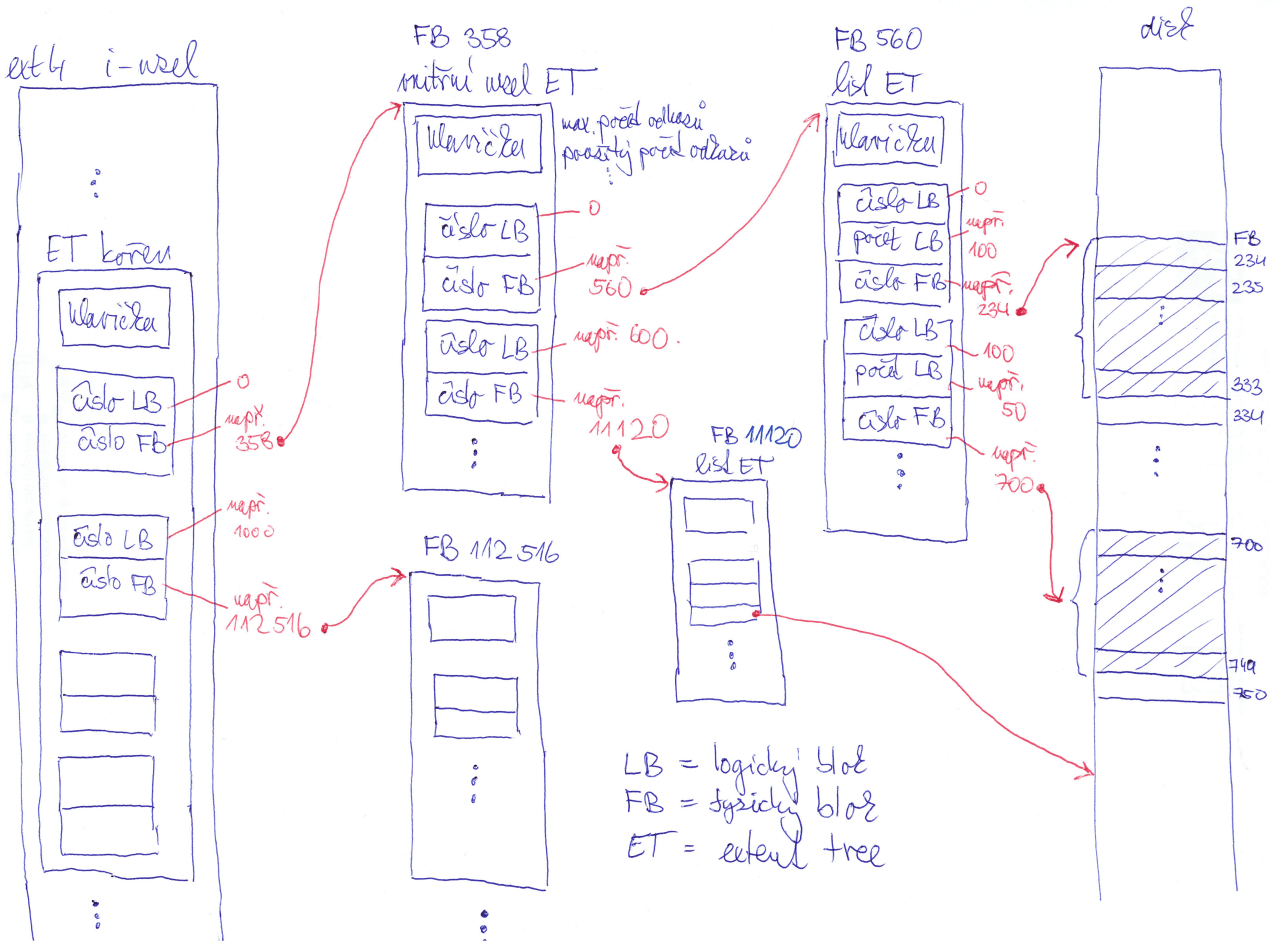

- Max. 5 úrovní + kořen, extent max. 32767 bloků, soubor max. 2^{32} bloků.

- „Malé“ soubory: až 4 extenty odkazované přímo z kořenového uzlu extentového stromu umístěného v i-uzlu, příp. přímo v i-uzlu (symbolické odkazy).

NTFS

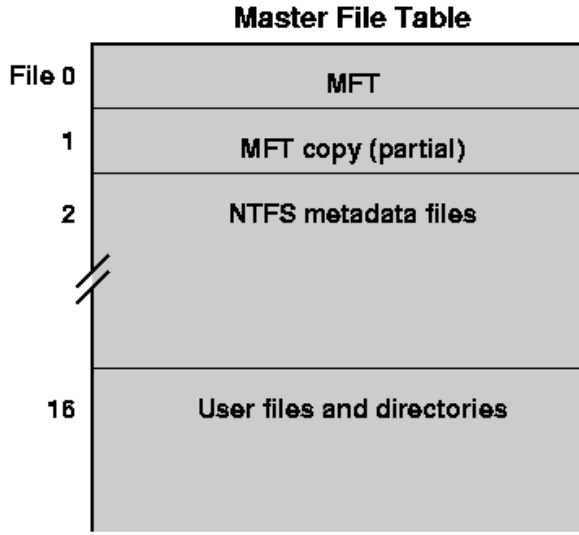

❖ MFT – Master File Table: alespoň jeden řádek pro každý soubor.

❖ Obsah souboru (a) přímo v záznamu MFT odpovídajícímu příslušnému souboru, (b) nebo rozdělen na extenty odkazované z tohoto záznamu, (c) nebo z pomocných MFT záznamů odkazovaných z primárního MFT záznamu analogicky k B+ stromu.

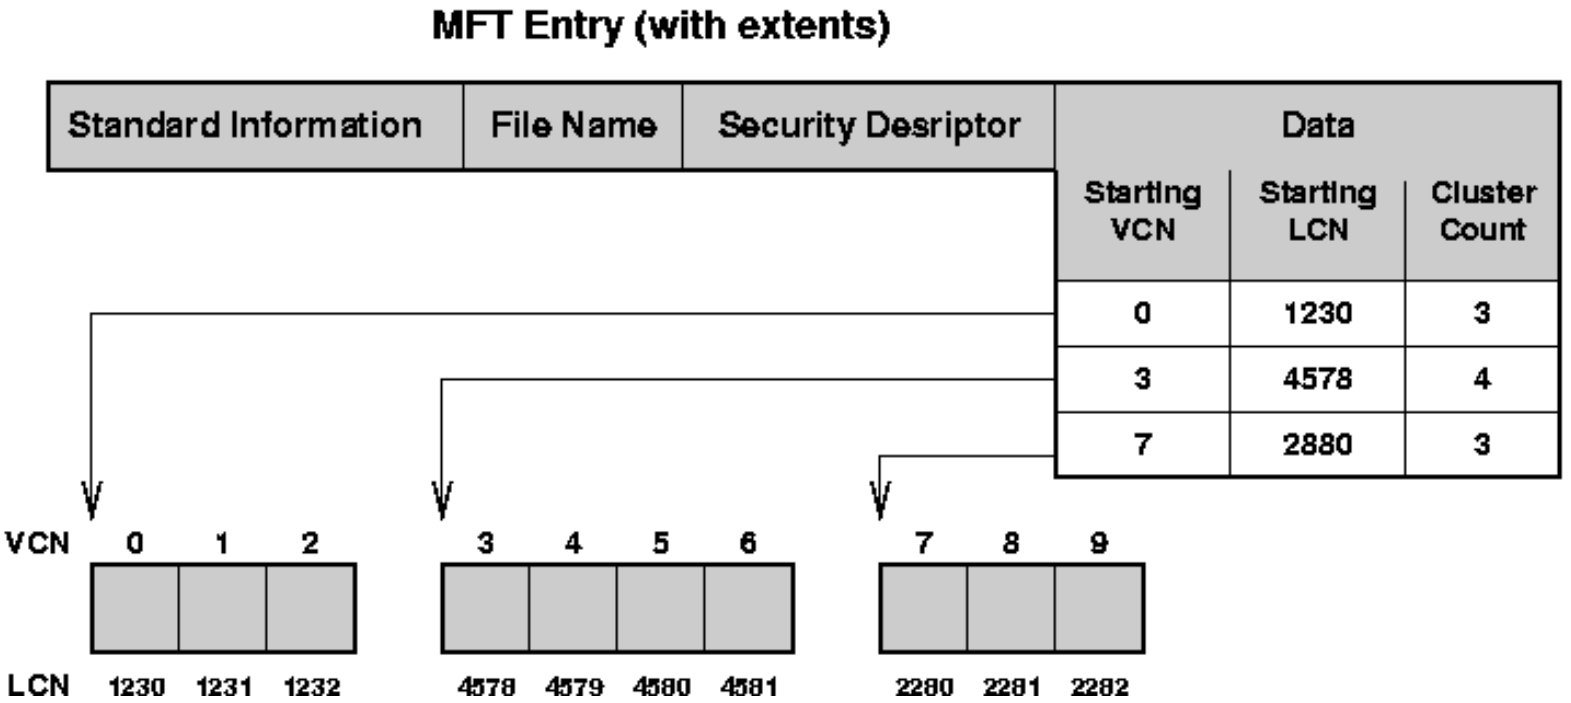

Organizace volného prostoru

❖ Organizace volného prostoru v klasickém Unixovém FS a řadě jeho následovníků (UFS, ext2, ext3, ext4) a také v NTFS: bitová mapa s jedním bitem pro každý blok (případně rozdělená na několik částí, pokud je disk rozdělen na několik skupin bloků).

- Umožňuje zrychlit vyhledávání volné souvislé oblasti pomocí bitového maskování (test volnosti několika bloků současně).

❖ Další způsoby organizace volného prostoru zahrnují:

- seznam – zřetězení volných bloků,
- označení (zřetězení) volných položek v tabulce bloků (FAT),
- B+ strom – adresace velikostí a/nebo offsetem.

❖ Volný prostor může být také organizován po extentech.

Deduplikace

- Snaha odhalit opakované ukládání těchže dat, uložit je jednou a odkázat vícenásobně.
- Může být podporována na různých úrovních: sekvence bytů, bloky, extenty, soubory.
- Založeno na kryptografickém hashování, případně s následnou kontrolou plné shody.
- Může být implementováno při zápisu, nebo dodatečně (případně na přání).
- Může uspořit diskový prostor při virtualizaci, na mail serverech, repozitářích apod., paměťový prostor (sdílení stránek, vyrovnávacích pamětí) i čas (není nutno opakovaně číst/zapisovat).
- Při menším objemu duplikace může naopak zvýšit spotřebu procesorového času, paměťového i diskového prostoru.
- Podpora (někdy ve vývoji/externí): ZFS, NTFS, Btrfs, XFS, ...

Typy souborů v UNIXu

- Příkaz `ls -l` vypisuje typ jako první znak na řádku:

`-`	obyčejný soubor
`d`	adresář
`b`	blokový speciální soubor
`c`	znakový speciální soubor
`l`	symbolický odkaz (symlink)
`p`	pojmenovaná roura
`s`	socket

Adresář

- Soubor obsahující množinu dvojic – "hard-links" – `(jméno souboru, číslo souboru)`:
  - `jméno souboru`:
    - mělo v tradičním UNIXu délku max 14 znaků, dnes typicky až 255 znaků,
    - může obsahovat jakékoli znaky kromě `'/'` a `'\0'`,
  - `číslem souboru` je u klasického Unixového FS (a souborových systémů z něj odvozených) číslo i-uzlu, které je indexem do tabulky i-uzlů logického disku (v jiných případech může sloužit jako klíč pro vyhledávání v B+ stromu apod.).

- Adresář vždy obsahuje jména:
  - `.` odkaz na sebe
  - `..` odkaz na rodičovský adresář

- Implementace – jednoduchost implementace vs rychlost vyhledávání/vkládání:
  - seznam,
  - B+ stromy a jejich varianty: NTFS, XFS, JFS, Btrfs, APFS, ext3/4 (H-stromy: 1–2 úrovně, bez vyvažování, vyhledává na základě zahashovaného jména),
  - (rozšiřitelné) hashovací tabulky (extendible hashing) – např. ZFS.

❖ Soubor v Unixu může mít více jmen:

- `ln jmeno-existujiciho-souboru nove-jmeno`

❖ Omezení: Obě jména musí být v rámci jednoho logického disku!

❖ Rušení souboru (`rm soubor`) ruší pevný odkaz `(jméno, číslo i-uzlu)` a snižuje počitadlo odkazů v i-uzlu. Dokud je počitadlo nenulové, soubor se nemaže.

❖ Poznámka: Pokud „číslo souboru“ odkazuje přímo na první blok na disku (tedy není užit i-uzel či nějaká jeho analogie, např. FAT), pak nelze rozumně implementovat soubory s více jmény.

Montování disků

- Princip montování disků:
  - Všechny soubory jsou v jednom “stromu” adresářů.
  - V systému je jeden kořenový logický disk, další logické disky lze připojit programem `mount` do již existujícího adresářového stromu.

- Příklad: `mount /dev/floppy /mnt`

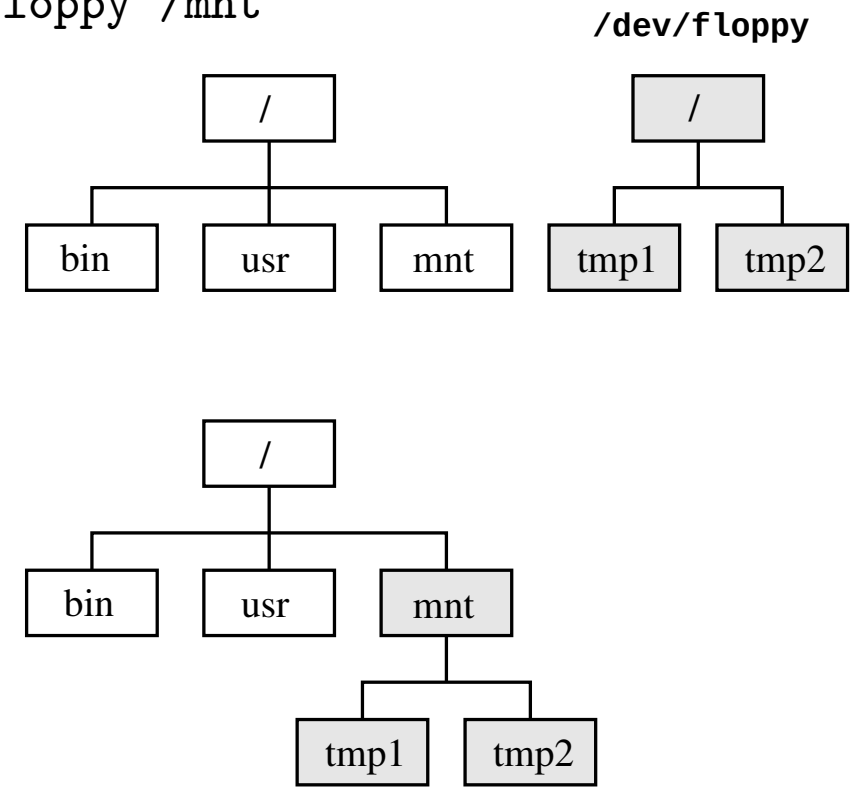

❖ Poznámky:

- Parametry příkazu `mount` – viz `man mount`.
- Soubor `/etc/fstab` – popis disků typicky připojovaných na určité pozice adresářového stromu.
- Soubor `/etc/mtab` – tabulka aktuálně připojených disků.
- Některé technologie umožnují automatické montování nově připojených zařízení. Např. systém udev dynamicky vytváří rozhraní souborového systému na zařízení v adresáři `/dev` a informuje zbytek systému prostřednictvím sběrnice D-Bus, aplikace typu správce souborů pak může provést automatické montování a další akce (parametry může zjišťovat automaticky, čerpat z různých nastavení zúčastněných technologií, ale přednost má stále `/etc/fstab`).
- Automounter (např. autofs) – automaticky připojuje disky při pokusu o přístup na pozici adresářového stromu, kam by měly být připojeny, a také po určité době neaktivity disky odpojuje (výhodné zejména u síťových souborových systémů).
- Union mount:
  - Montuje více disků (adresářů) do jednoho místa – obsah je pak sjednocením obsahu namontovaných adresářů s tím, že se vhodným způsobem řeší kolize (např. prioritou zdrojových disků/adresářů).
  - Plan9, Linux – UnionFS, ...
  - UnionFS: má copy-on write sémantiku: soubor původně v read-only větvi, při změně se uloží do read-write větve s vyšší prioritou.

Symbolické odkazy

```
ln -s cílový-soubor symbolický-odkaz
```

- V datech souboru typu “symlink” je jméno cílového souboru.
- Systém při otevření souboru automaticky provede otevření cílového souboru.
  - Nutné vícenásobné zpracování cesty (cesta k symlinku, cesta uvnitř symlinku).
- Po zrušení cílového souboru zůstává symlink nezměněn.
  - Přístup k souboru přes něj vede k chybě.
- Symlink může odkazovat na i jiný logický disk.
- Řešení cyklů: omezený počet úrovní odkazů.
- Rychlé symlinky: uloženy v i-uzlu, pomalé symlinky: uloženy ve zvláštním souboru (užívá se tehdy, je-li cesta, která definuje symlink, příliš dlouhá pro uložení do i-uzlu).

Blokové a znakové speciální soubory

❖ Blokové a znakové speciální soubory implementují souborové rozhraní k fyzickým či virtuálním zařízením.

soubor	tvoří souborové rozhraní na zařízení
/dev/hda	dříve první fyzický disk (master) na prvním ATA/PATA rozhraní
/dev/hda1	dříve první logický disk (partition) na hda
/dev/sda	dříve první fyzický disk SCSI (nyní i emulované SATA/PATA)
/dev/mem	fyzická paměť
/dev/zero	nekonečný zdroj nulových bajtů
/dev/null	soubor typu "černá díra"– co se zapíše, to se zahodí; při čtení se chová jako prázdný soubor
/dev/random	generátor náhodných čísel
/dev/tty	terminál
/dev/lp0	první tiskárna
/dev/mouse	myš
/dev/dsp	zvuková karta
/dev/loop	souborové systémy nad soubory (`losetup`/`mount -o loop=...`)
.....	.....

Poznámka: Názvy závisí na použitém systému (Linux).

❖ Výhoda zavedení speciálních souborů: Programy mohou použít běžné souborové rozhraní pro práci se soubory i na čtení/zápis z různých zařízení.

❖ Příklady práce se speciálními soubory:

```
dd if=/dev/hda of=mbrbackup bs=512 count=1
cat /dev/hda1 | gzip >zaloha-disku.gz
cp /dev/zero /dev/hda1 # vynulování disku
```

Přístupová práva

- V UNIXu jsou typicky rozlišena práva pro vlastníka, skupinu a ostatní.
  (Rozšíření: ACL (access control lists), viz `man acl`, `man getfacl`/`setfacl`...)
- Uživatelé:
  - Uživatele definuje administrátor systému (root): `/etc/passwd`,
  - UID: číslo identifikující uživatele (root UID = 0).
  - Příkaz `chown` – změna vlastníka souboru (pouze root).
- Skupiny:
  - Skupiny definuje administrátor systému (root): `/etc/group`,
  - GID: číslo identifikující skupinu uživatelů,
  - Uživatel může být členem více skupin, jedna z nich je aktuální (používá se při vytváření souborů). Ve své primární skupině z `/etc/passwd` nemusí být v `/etc/group` explicitně uveden.
  - `groups` – výpis skupin uživatele,
  - `chgrp` – změna skupiny souboru,
  - `newgrp` – nový shell s jiným aktuálním GID.

Typy přístupových práv

obyčejné soubory	
`r`	právo číst obsah souboru
`w`	právo zapisovat do souboru
`x`	právo spustit soubor jako program

adresáře	
`r`	právo číst obsah (`ls adresář`)
`w`	právo zapisovat = vytváření a rušení souborů
`x`	právo přistupovat k souborům v adresáři (`cd adresář`, `ls -l adresář/soubor`)

❖ Příklad: `-rwx---r--` (číselné vyjádření: `0704`):

- obyčejný soubor,

vlastník: čtení, zápis, provedení

- skupina: nemá žádná práva

ostatní: pouze čtení

❖ Změna přístupových práv – příkaz `chmod`:

```
chmod a+rw soubory   # všichni mohou číst i zapisovat
chmod 0644 soubor    # rw-r--r--
chmod -R u-w .       # zakáže zápis vlastníkovi
chmod g+s soubor     # nastaví SGID -- viz dále
```

❖ Výpis informací o souboru:

```
ls -l soubor

-rw-r--r-- 1 joe joe  331 Sep 24 13:10 .profile
typ
 práva
          počet pevných odkazů
            vlastník
                skupina
                     velikost
                          čas poslední modifikace
                                       jméno souboru
```

Sticky bit

❖ Sticky bit je příznak, který nedovoluje rušit či přejmenovávat cizí soubory v adresáři, i když mají všichni právo zápisu.

```
chmod +t adresar      # nastaví Sticky bit
chmod 1777 /tmp
```

❖ Příklad: `/tmp` má práva `rwxrwxrwt`

SUID, SGID

❖ Určení práv pro procesy:

UID	reálná identifikace uživatele = kdo spustil proces
EUID	efektivní UID se používá pro kontrolu přístupových práv (pro běžné programy je rovno UID)
GID	reálná identifikace skupiny = skupina toho, kdo spustil proces
EGID	efektivní GID se používá pro kontrolu přístupových práv (pro běžné programy je rovno GID)

❖ Vlastník programu může propůjčit svoje práva komukoli, kdo spustí program s nastaveným SUID.

❖ Příklad: Program `passwd` musí editovat soubor `/etc/shadow`, do kterého má právo zápisu pouze superuživatel `root`.

❖ Příklad propůjčených přístupových práv: `-rwsr-Sr-x fileUID fileGID`

- `s` = je nastaveno `x`, `S` = není nastaveno `x`,
- v našem příkladu `s`: SUID=set user identification, EUID:=fileUID
- v našem příkladu `S`: SGID=set group identification: EGID:=fileGID

Typická struktura adresářů v UNIXu

- FHS = Filesystem Hierarchy Standard (Linux), část:

/bin	programy pro všechny (nutné při bootování)
/boot	soubory pro zavaděč (obrazy jádra, počátečního souborového systému)
/dev	obsahuje speciální soubory – rozhraní na zařízení
/etc	konfigurační soubory pro systém i aplikace
/home	domovské adresáře uživatelů
/lib	sdílené knihovny, moduly jádra (nutné při bootování)
/media	přípojný bod pro přenosná zařízení
/mnt	přípojný bod pro dočasné souborové systémy
/proc	obsahuje informace o procesech a jádru
/root	domovský adresář superuživatele
/run	dočasné informace o běžícím systému (typicky od démonů)
/sbin	programy pro superuživatele (nutné při bootování)
/sys	informace o jádru, zařízeních, modulech, ovladačích
/tmp	dočasné pracovní soubory

Pokračování na další straně...

Typická struktura adresářů v UNIXu – pokračování:

/usr	obsahuje soubory, které nejsou nutné při zavádění systému – může se přimontovat až po bootu (například ze sítě) a může být pouze pro čtení (například na CD)
/usr/bin,sbin	programy, které nejsou třeba pro bootování
/usr/lib	knihovny (statické i dynamické)
/usr/include	hlavičkové soubory pro jazyk C atd.
/usr/share	soubory, které lze sdílet (například přes síť) nezávisle na architektuře počítače
/usr/local	další hierarchie bin, sbin, lib,... určená pro lokální (nestandardní) instalace programů
/usr/src	zdrojové texty jádra systému a programů
/var	obsahuje soubory, které se mění při běhu systému
/var/log	záznamy o činnosti systému
/var/spool	pomocné soubory pro tisk atd.
/var/mail	poštovní přihrádky uživatelů

Datové struktury a algoritmy pro vstup/výstup

Použití vyrovnávacích pamětí

- I/O buffering:
  - Buffer = vyrovnávací paměť (VP).
  - Cílem je minimalizace počtu pomalých operací s periferiemi (typicky s disky).
  - Dílčí vyrovnávací paměti mívají velikost alokačního bloku (příp. jejich skupiny) a jsou sdruženy do kolekce (tzv. buffer pool) pevné či proměnné velikosti umožňující snadné vyhledávání.

- Možná implementace:

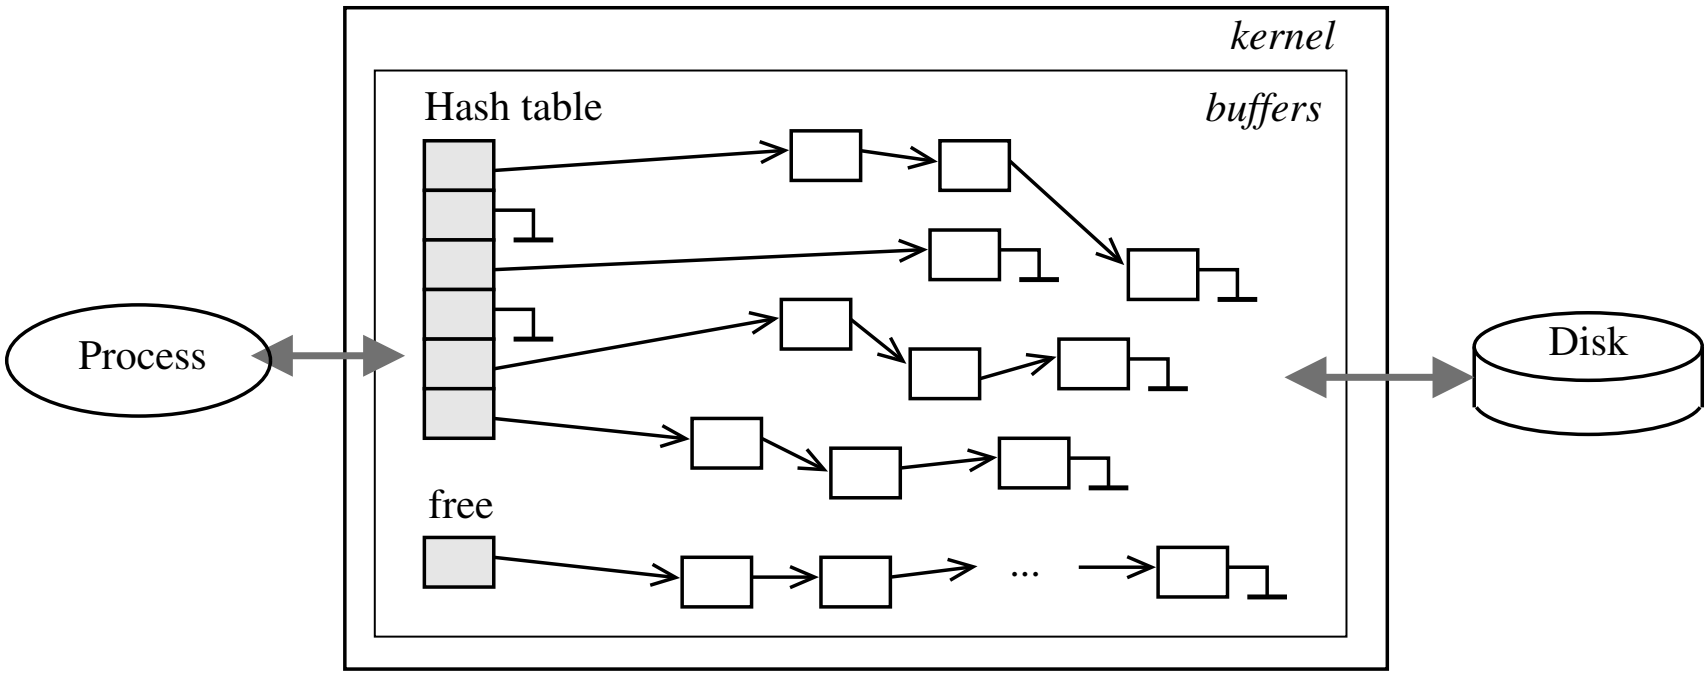

Čtení

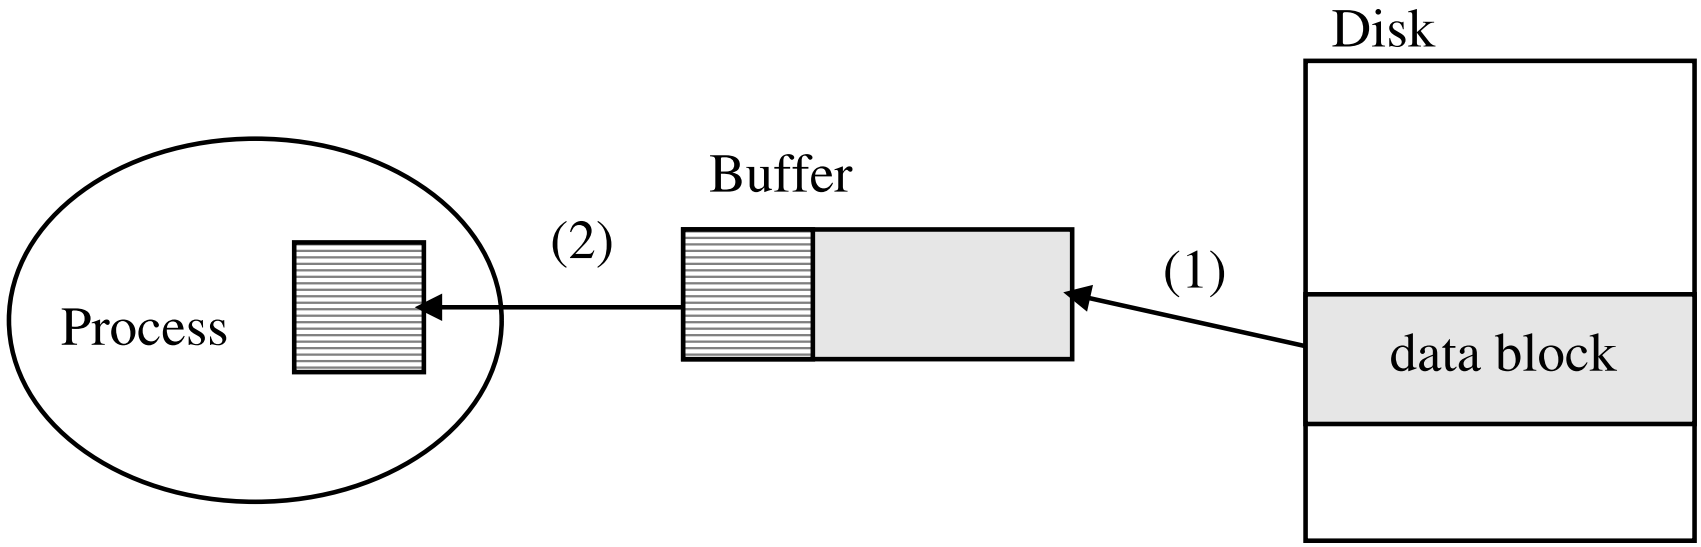

- Postup při prvním čtení (`read`):
  1. přidělení VP a načtení bloku,
  2. kopie požadovaných dat do adresového prostoru procesu (RAM→RAM).

- Při dalším čtení už pouze (2).

- Čtení, které překročí hranice bloku provede opět (1) a (2).

Zápis

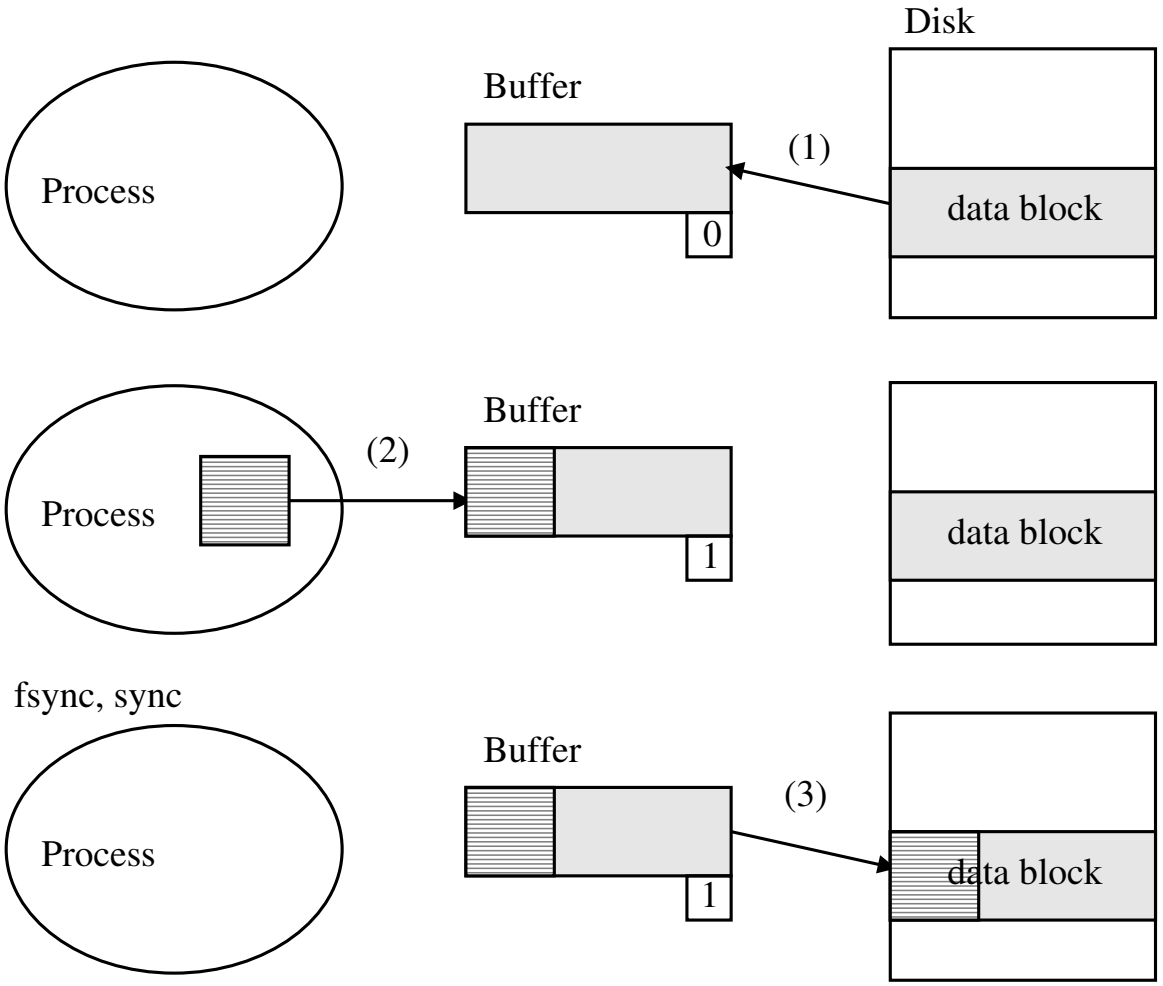

- Postup při zápisu (`write`):
  1. přidělení VP a čtení bloku do VP (pokud se netvoří nový/zcela nepřepisuje),
  2. zápis dat do VP (RAM→RAM), nastaví se příznak modifikace (dirty bit),
  3. zpožděný zápis na disk, nuluje příznak.

Otevření souboru pro čtení

```
fd = open("/dir/file", O_WRONLY | O_CREAT | O_EXCL);
```

❖ V případě, že soubor ještě nebyl otevřen:

1. Vyhodnotí cestu a nalezne číslo i-uzlu: postupně načítá i-uzly adresářů a obsah těchto adresářů, aby se dostal k číslům i-uzlů pod-adresářů či hledaného souboru – čísla i-uzlů pro některá jména mohou samozřejmě být ve speciálních vyrovnávacích pamětech, tzv. d-entry cache.
2. V systémové tabulce aktivních i-uzlů vyhradí novou položku a načte do ní i-uzel. Vzniká rozšířená paměťová kopie i-uzlu: v-uzel.
3. V systémové tabulce otevřených souborů vyhradí novou položku a naplní ji:
   - odkazem na položku tabulky v-uzlů,
   - režimem otevření,
   - pozicí v souboru (0),
   - čítačem počtu referencí na tuto položku (1).
4. V poli deskriptorů souborů v záznamu o procesu v jádře nebo v tzv. uživatelské oblasti procesu vyhradí novou položku (první volná) a naplní ji odkazem na položku v tabulce otevřených souborů.
5. Vrátí index položky v poli deskriptorů (nebo -1 při chybě).

❖ Ilustrace prvního otevření souboru (čísla v obrázku udávají čítače počtu referencí na danou položku):

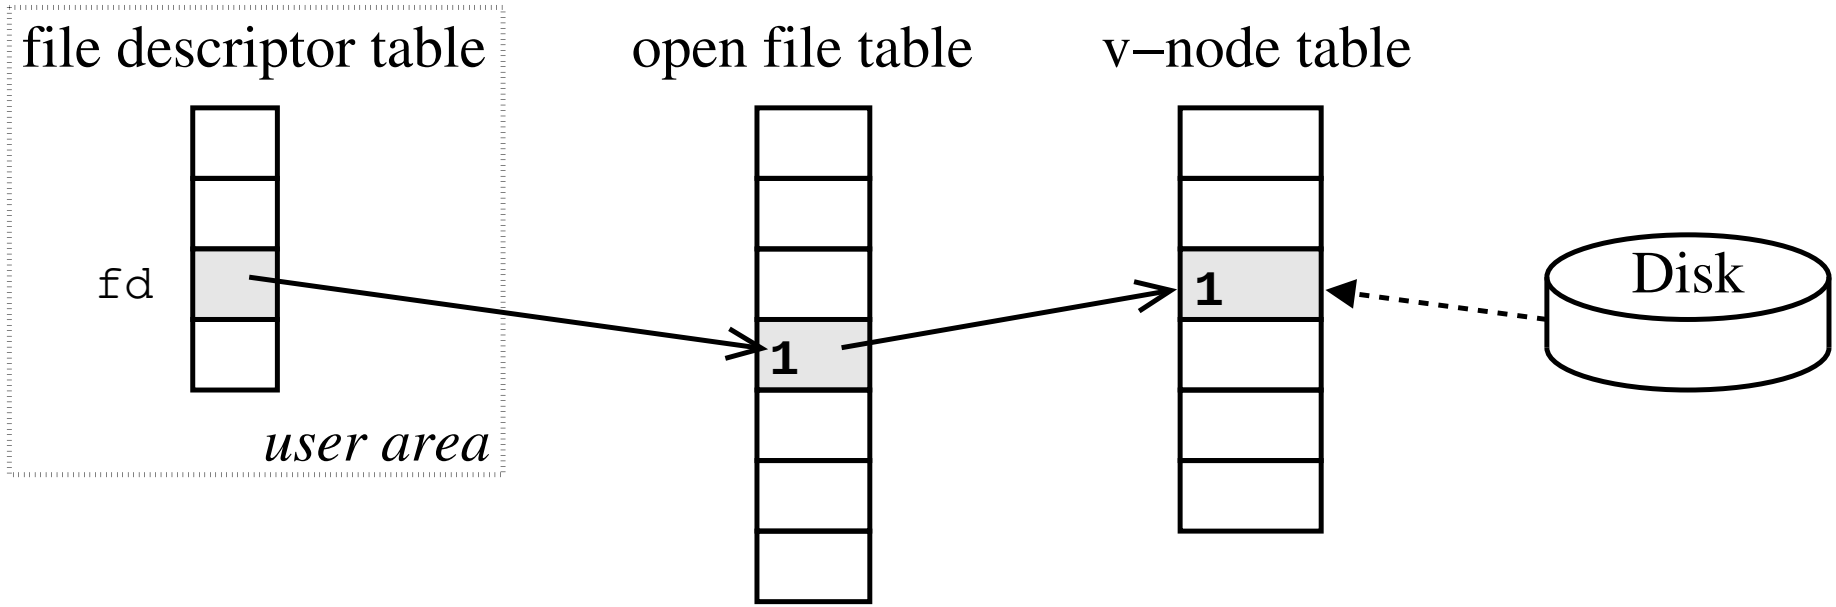

❖ Otevření již jednou otevřeného souboru:

1. Vyhodnotí cestu a získá číslo i-uzlu.
2. V systémové tabulce v-uzlů nalezne již načtený i-uzel: tabulka v-uzlů musí být implementována za tím účelem jako vyhledávací tabulka.
3. Zvýší počitadlo odkazů na v-uzel o 1.
4. A další beze změny.

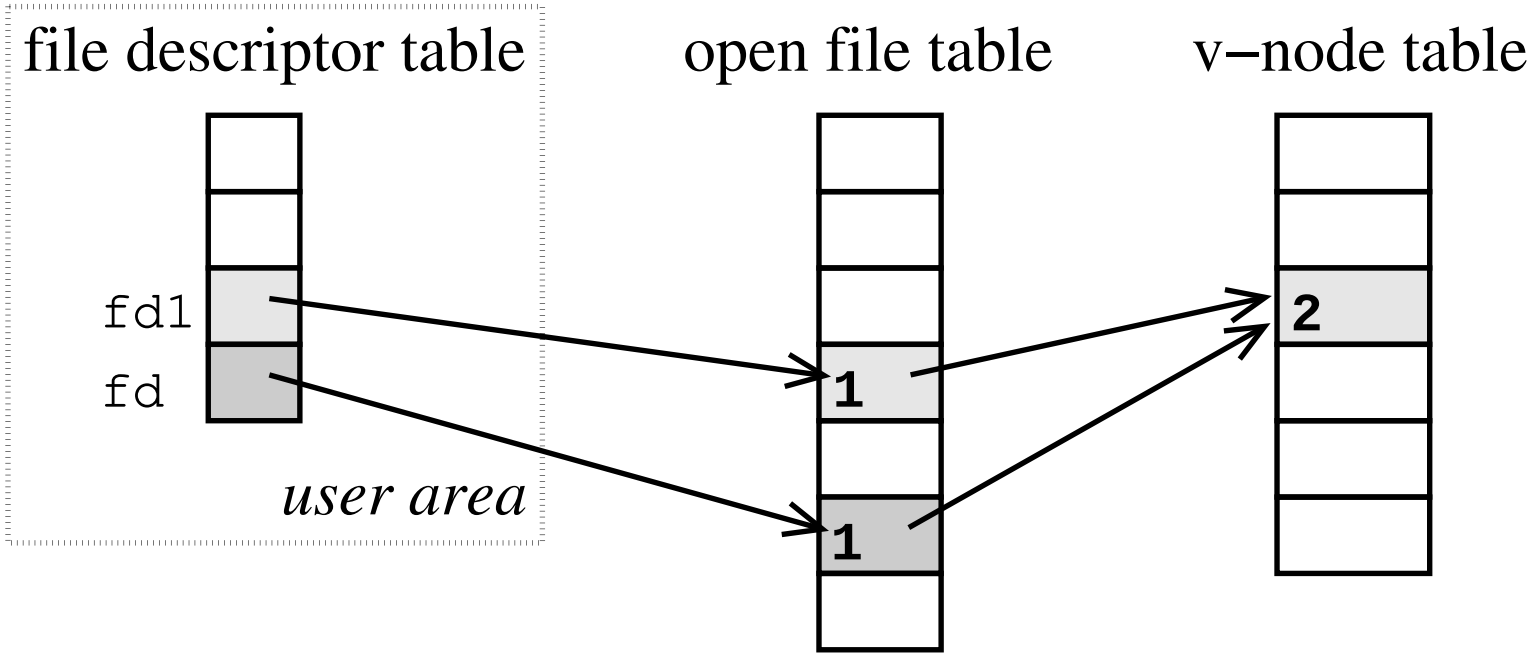

- Při otevírání se provádí kontrola přístupových práv.
- Soubor je možno otevřít v režimu:
  - čtení,
  - zápis,
  - čtení i zápis

modifikovaných volbou dalších parametrů otevření:

  - vytvoření/povinné vytvoření,
  - zkrácení na nulu,
  - přidávání,
  - synchronní zápis,
  - ...

- Při chybě vrací `-1` a nastaví chybový kód do knihovní proměnné `errno`.
  - Pro standardní chybové kódy viz `man errno`.
  - Lze užít knihovní funkcí `perror`.
  - Podobně je tomu i u ostatních systémových volání v UNIXu.

Čtení a zápis z/do souboru

❖ Čtení ze souboru – `n = read(fd, buf, 3000);`

1. Kontrola platnosti `fd`.
2. V případě, že jde o první přístup k příslušné části souboru, dojde k alokaci VP a načtení bloků souboru z disku do VP. Jinak dochází k alokaci VP a diskové operaci jen tehdy, je-li je to nutné (viz slajd k vyrovnávacím pamětem).
3. Kopie požadovaných dat z VP (RAM, jádro) do pole `buf` (RAM, adresový prostor procesu).
4. Funkce vrací počet opravdu přečtených bajtů nebo -1 při chybě (při současném nastevní `errno`).

❖ Zápis do souboru – `n = write(fd, buf, 3000);`

- Funguje podobně jako `read` (viz slajd k vyrovnávacím pamětem).
- Před vlastním zápisem kontroluje dostupnost diskového prostoru a prostor rezervuje.
- Funkce vrací počet opravdu zapsaných bajtů nebo -1 při chybě.

Přímý přístup k souboru

```
n = lseek(fd, offset, whence);
```

❖ Postup při žádosti o přímý přístup k souboru:

1. Kontrola platnosti `fd`.
2. Nastaví pozici `offset` bajtů od
   - začátku souboru pro `whence=SEEK_SET`,
   - aktuální pozice pro `whence=SEEK_CUR`,
   - konce souboru pro `whence=SEEK_END`.
3. Funkce vrací výslednou pozici od začátku souboru nebo -1 při chybě.

❖ Poznámka: Hodnota parametru `offset` může být záporná, nelze však nastavit pozici před začátek souboru.

❖ Sparse files – “řídké soubory”:

- Vznikají nastavením pozice za konec souboru a zápisem.
- Bloky, do kterých se nezapisovalo nejsou alokovány a nezabírají diskový prostor. Při čtení se považují za vynulované.
- Někdy také „hole punching“: mazání prostoru uvnitř souboru (např. `fallocate`).

Zavření souboru

```
x = close(fd);
```

- Postup při uzavírání souboru:
  1. Kontrola platnosti `fd`.
  2. Uvolní se odpovídající položka v tabulce deskriptorů, sníží se počitadlo odkazů v odpovídající položce tabulky otevřených souborů.
  3. Pokud je počitadlo odkazů nulové, uvolní se odpovídající položka v tabulce otevřených souborů a sníží se počitadlo odkazů ve v-uzlu.
  4. Pokud je počitadlo odkazů nulové, i-uzel se z v-uzlu okopíruje do VP a uvolní.
  5. Funkce vrací nulu nebo -1 při chybě.

- Pokud se ukončuje proces, automaticky se uzavírají všechny jeho deskriptory.

- Uzavření souboru nezpůsobí uložení obsahu jeho VP na disk!

Duplikace deskriptoru souboru

```
fd2 = dup(fd);
fd2 = dup2(fd,newfd);
```

- Postup při duplikaci deskriptoru:
  1. Kontrola platnosti `fd`.
  2. Kopíruje danou položku v tabulce deskriptorů do první volné položky (`dup`) nebo do zadané položky (`dup2`). Je-li deskriptor `newfd` otevřen, `dup2` ho automaticky uzavře.
  3. Zvýší počitadlo odkazů v odpovídající položce tabulky otevřených souborů.
  4. Funkce vrací index nové položky nebo -1 při chybě.

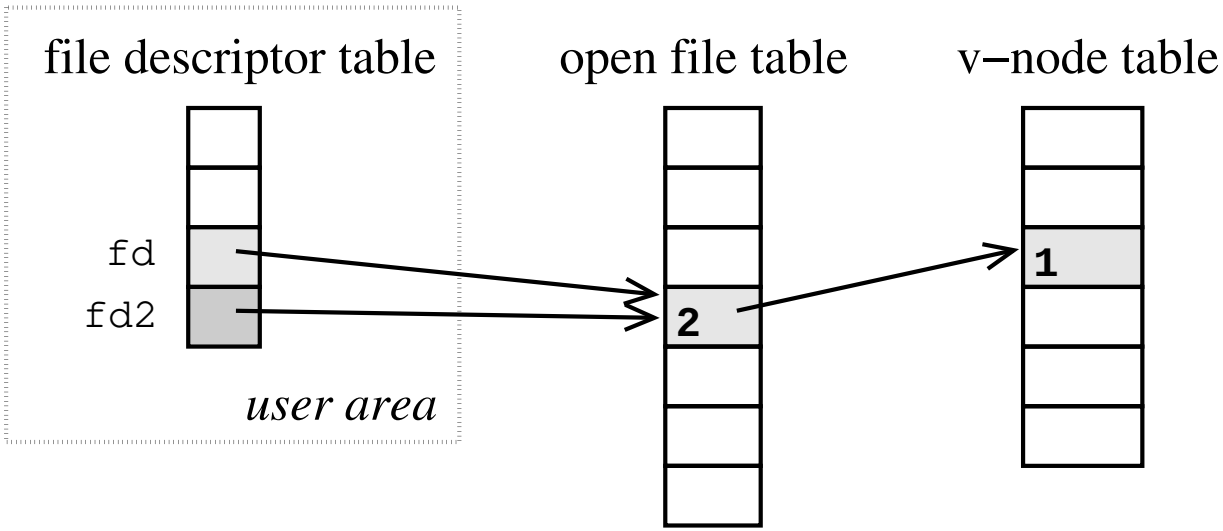

- Poznámka: Použití pro přesměrování stdin/stdout.

Rušení souboru

```
x = unlink("/dir/file");
```

- Postup při rušení souboru:
  1. Vyhodnocení cesty, kontrola platnosti jména souboru a přístupových práv.
  2. Odstraní pevný odkaz (hard link) mezi jménem souboru (`file`) a jeho i-uzlem v adresáři, ve kterém se maže (`/dir`). Vyžaduje právo zápisu do adresáře.
  3. Zmenší počitadlo jmen v i-uzlu.
  4. Pokud počet jmen klesne na nulu a i-uzel nikdo nepoužívá, je i-uzel uvolněn včetně všech používaných bloků souboru. Je-li i-uzel používán, bude uvolnění odloženo až do okamžiku zavření souboru (počitadlo otevření souboru klesne na 0).
  5. Funkce vrací nulu nebo -1 při chybě.

- Poznámky:
  - Lze provést `unlink` na otevřený soubor a dále s ním pracovat až do jeho uzavření.
  - Je možné zrušit spustitelný soubor, i když běží jím řízené procesy (výhoda při instalaci nových verzí programů).
  - Bezpečnější mazání: `shred`.

Další operace se soubory

- Vytvoření souboru: `creat`, `open`
- Přejmenování: `rename`
- Zkrácení: `truncate`, `ftruncate`
- Zamykání záznamů: `fcntl` nebo `lockf`
- Změna atributů: `chmod`, `chown`, `utime`
- Získání atributů: `stat`
- Zápis VP na disk: `sync`, `fsync`

Adresářové soubory

- Adresáře se liší od běžných souborů:
  - vytváří se voláním `mkdir` (vytvoří položky `.` a `..`),
  - mohou být otevřeny voláním `opendir`,
  - mohou být čteny voláním `readdir`,
  - mohou být uzavřeny voláním `closedir`,
  - modifikaci je možné provést pouze vytvářením a rušením souborů v adresáři (`creat`, `link`, `unlink`, ...).

- Poznámka: Adresáře nelze číst/zapisovat po bajtech!

- Příklad obsahu adresáře:

32577	.
2	..
2361782	Archiv
1058839	Mail
1661377	tmp

Blokové a znakové speciální soubory

❖ Představují rozhraní k blokovým/znakovým zařízením, buď fyzickým či virtuálním – disky, logické disky, terminály, myš, paměť, ...

- Lze vytvořit pomocí `mknod`.
- Normálně řeší přímo jádro či různí démoni (např. `udev`, `devd`).

❖ Jádro mapuje běžné souborové operace (`open`, `read`, ...) nad blokovými a znakovými speciálními soubory na odpovídající podprogramy tyto operace implementující nad příslušným zařízením prostřednictvím dvou tabulek:

- tabulky znakových zařízení a
- tabulky blokových zařízení.

❖ Zmíněné tabulky obsahují ukazatele na funkce implementující příslušné operace v ovladačích příslušných zařízení.

❖ Ovladač (*device driver*) je sada podprogramů pro řízení určitého *typu* zařízení.

❖ Speciální soubory typu zařízení (např. `/dev/sda`, `/dev/tty`, ...) mají v i-uzlu mj. typ souboru a dvě čísla, která lze vypsat např. pomocí `ls -l`:

číslo	*význam*
hlavní číslo (major number)	typ zařízení
vedlejší číslo (minor number)	instance zařízení

- Typ souboru (blokový nebo znakový) určuje tabulku.
- Hlavní číslo se použije jako index do tabulky zařízení.
- Vedlejší číslo se předá jako parametr funkce ovladače:
  – identifikace instance zařízení.

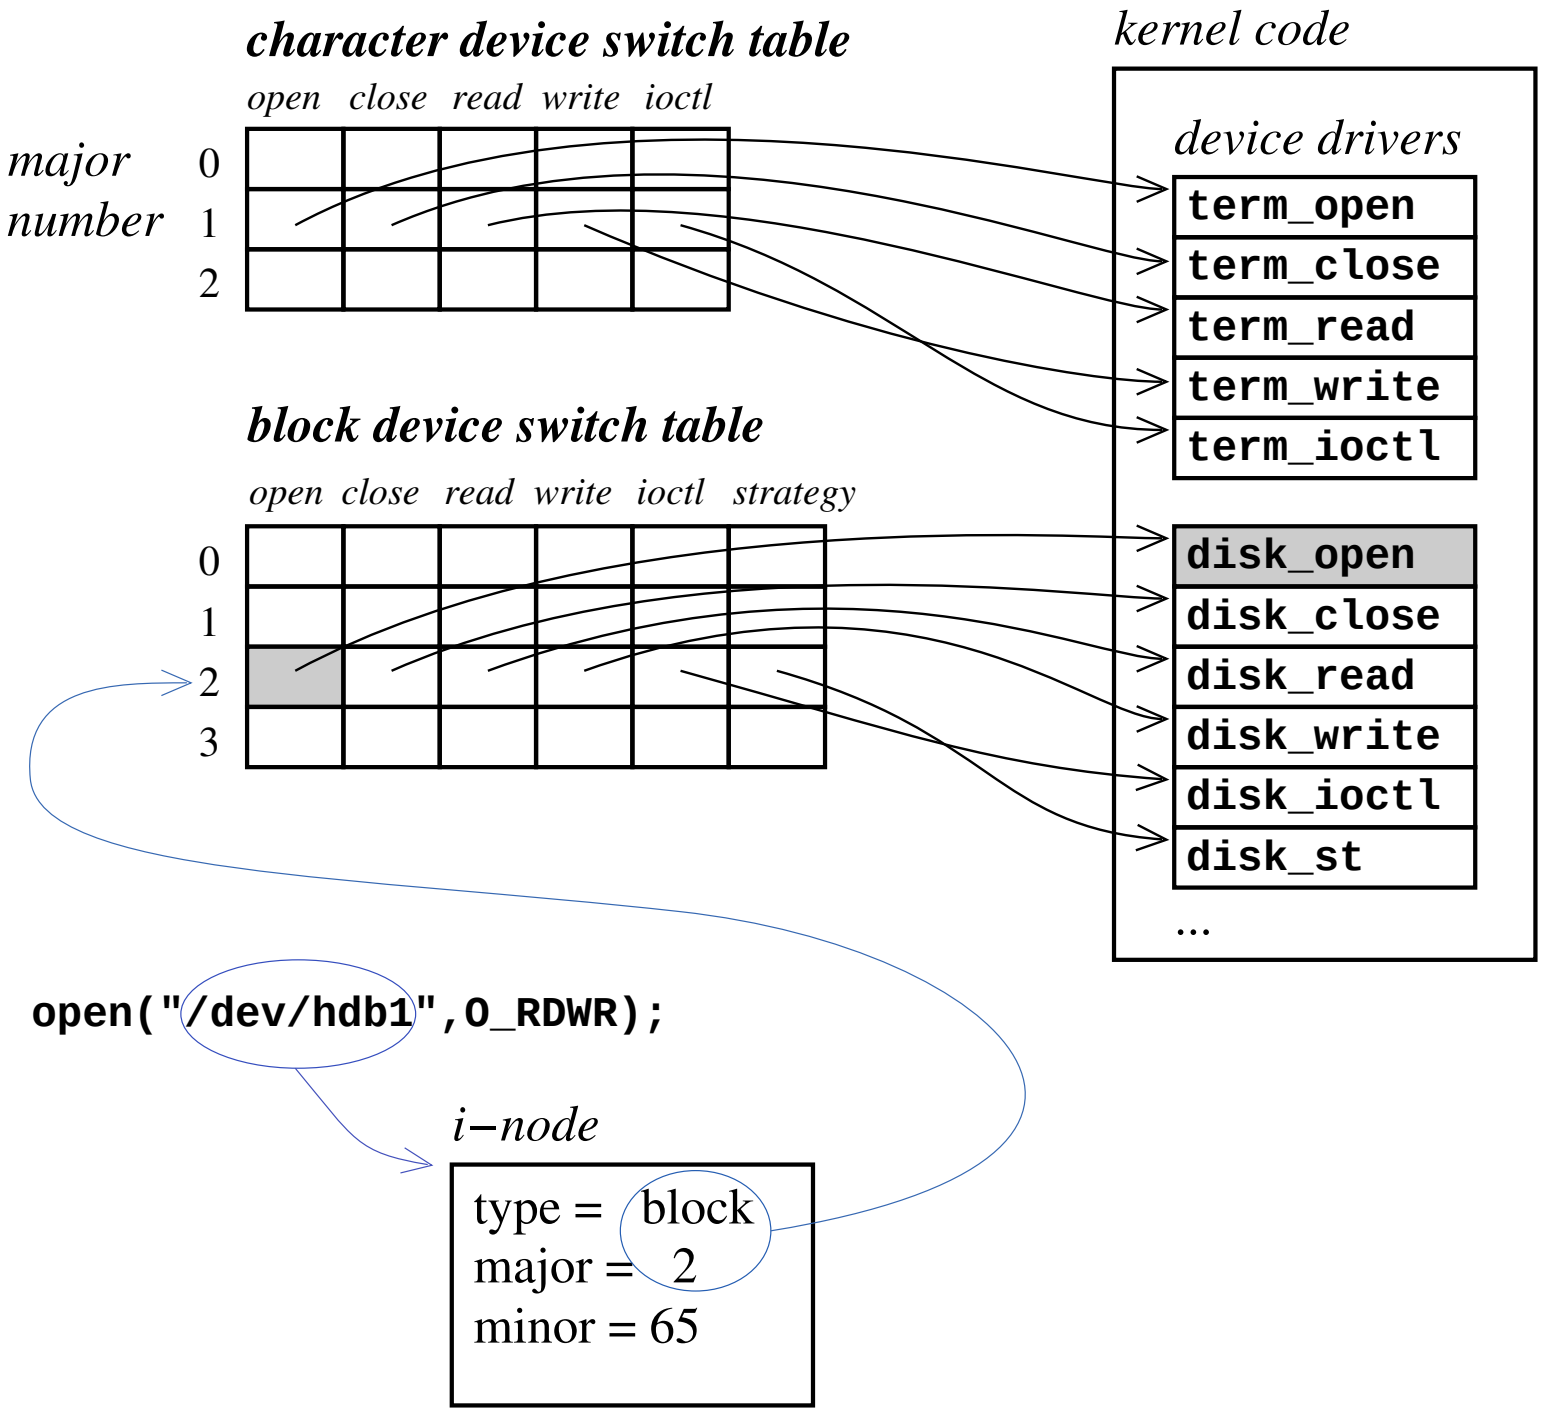
character device switch table
open close read write ioctl
major
number
0
1
2
kernel code
device drivers
term_open
term_close
term_read
term_write
term_ioctl
block device switch table
open close read write ioctl strategy
0
1
2
3
disk_open
disk_close
disk_read
disk_write
disk_ioctl
disk_st
...
open("/dev/hdb1",O_RDWR);
i−node
type = block
major = 2
minor = 65

Terminály

❖ Terminály – fyzická nebo logická zařízení umožňující (primárně) textový vstup/výstup systému: vstup/výstup po řádcích a pokračovacích řádcích, editace na vstupním řádku, speciální znaky (Ctrl-C, Ctrl-D, ...), ...

❖ Příkaz `tty` vypíše aktuální terminál.

❖ Rozhraní:

- `/dev/tty` – vnitřně svázán s řídícím terminálem aktuálního procesu,
- `/dev/ttyS1`, ... – terminál na sériové lince,
- `/dev/tty1`, ... – virtuální terminály (konzole),
- pseudoterminály (např. `/dev/ptmx` a `/dev/pts/1`, ...) – tvořeny párem master/slave emulujícím komunikaci přes sériovou linku (např. použito u X-terminálu či ssh).

❖ Různé režimy zpracování znaků (line discipline):

režim	význam
raw	bez zpracování
cbreak	zpracovává jen některé znaky (zejména Ctrl-C, mazání)
cooked	zpracovává vše

❖ Nastavení režimu zpracování znaků (nastavení ovladače terminálu): program `stty`.

❖ Nastavení režimu terminálu (tedy fyzického zařízení nebo emulujícího programu):

- proměnná `TERM` – typ aktuálního terminálu,
- databáze popisu terminálů (možnosti nastavení terminálu): `terminfo` či `termcap`.
- nastavení příkazy: `tset`, `tput`, `reset`, ...

❖ Knihovna `curses` – standardní knihovna pro řízení terminálu a tvorbu aplikací s terminálovým uživatelským rozhraním (včetně menu, textových oken apod.).

Roury

- Roury (pipes) – jeden z typů speciálních souborů. Rozlišujeme:
  - roury nepojmenované
    - nemají adresářovou položku,
    - `pipe` vrací dva deskriptory (čtecí a zápisový), jsou přístupné pouze příbuzným procesům (tvůrce fronty je přímý či nepřímý předek komunikujících procesů nebo jeden z nich) – případně lze zaslat přes Unixové sockety,
    - vytváří se v kolonách (např. `p1 | p2 | p3`),
  - Roury pojmenované – vytvoření `mknod` či `mkfifo`.

- Roury representují jeden z mechanismů meziprocesové komunikace.

- Implementace: kruhový buffer s omezenou kapacitou.

- Procesy komunikující přes rouru (producent a konzument) jsou synchronizovány.

Sockets

❖ Umožňují síťovou i lokální komunikaci.

❖ Lokální komunikace může probíhat přes sockety pojmenované a zpřístupněné v souborovém systému.

❖ API pro práci se sockets:

- vytvoření (`socket`),
- čekání na připojení (`bind`, `listen`, `accept`),
- připojení ke vzdálenému počítači (`connect`),
- příjem a vysílání (`recv`, `send`, `read`, `write`),
- uzavření (`close`).

❖ Sockets podporují blokující/neblokující I/O.

- Pro současnou obsluhu více sockets jedním procesem (vláknem) lze užít `select`.
- Testuje dostupnost/čeká na dostupnost operace na množině popisovačů.
- `select` lze užít i u jiných typů souborů.

VFS

❖ VFS (Virtual File System) vytváří jednotné rozhraní pro práci s různými souborovými systémy, odděluje vyšší vrstvy OS od konkrétní implementace jednotlivých souborových operací na jednotlivých souborových systémech.

❖ Pro popis souborů používá rozšířené i-uzly (tzv. v-uzly), které mohou obsahovat např. počet odkazů na v-uzel z tabulky otevřených souborů, ukazatele na funkce implementující operace nad i-uzlem v patřičném souborovém systému apod.

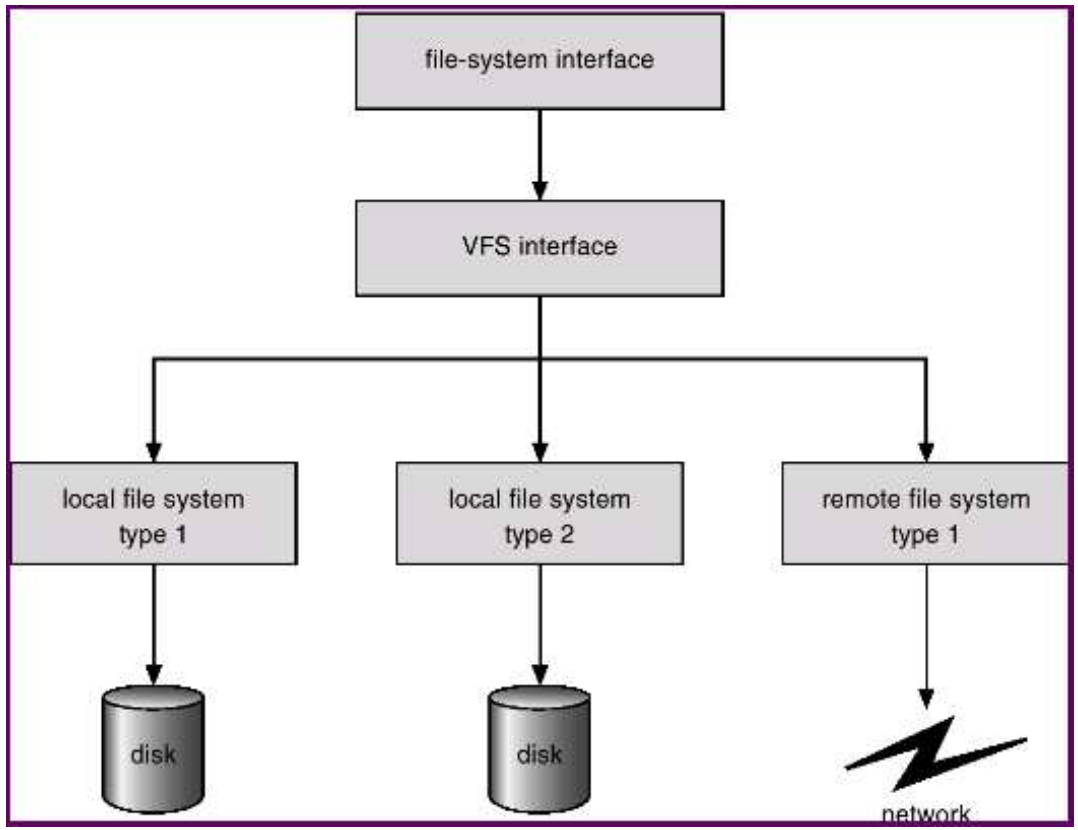

NFS

❖ NFS (Network File System) – transparentně zpřístupňuje soubory uložené na vzdálených systémech.

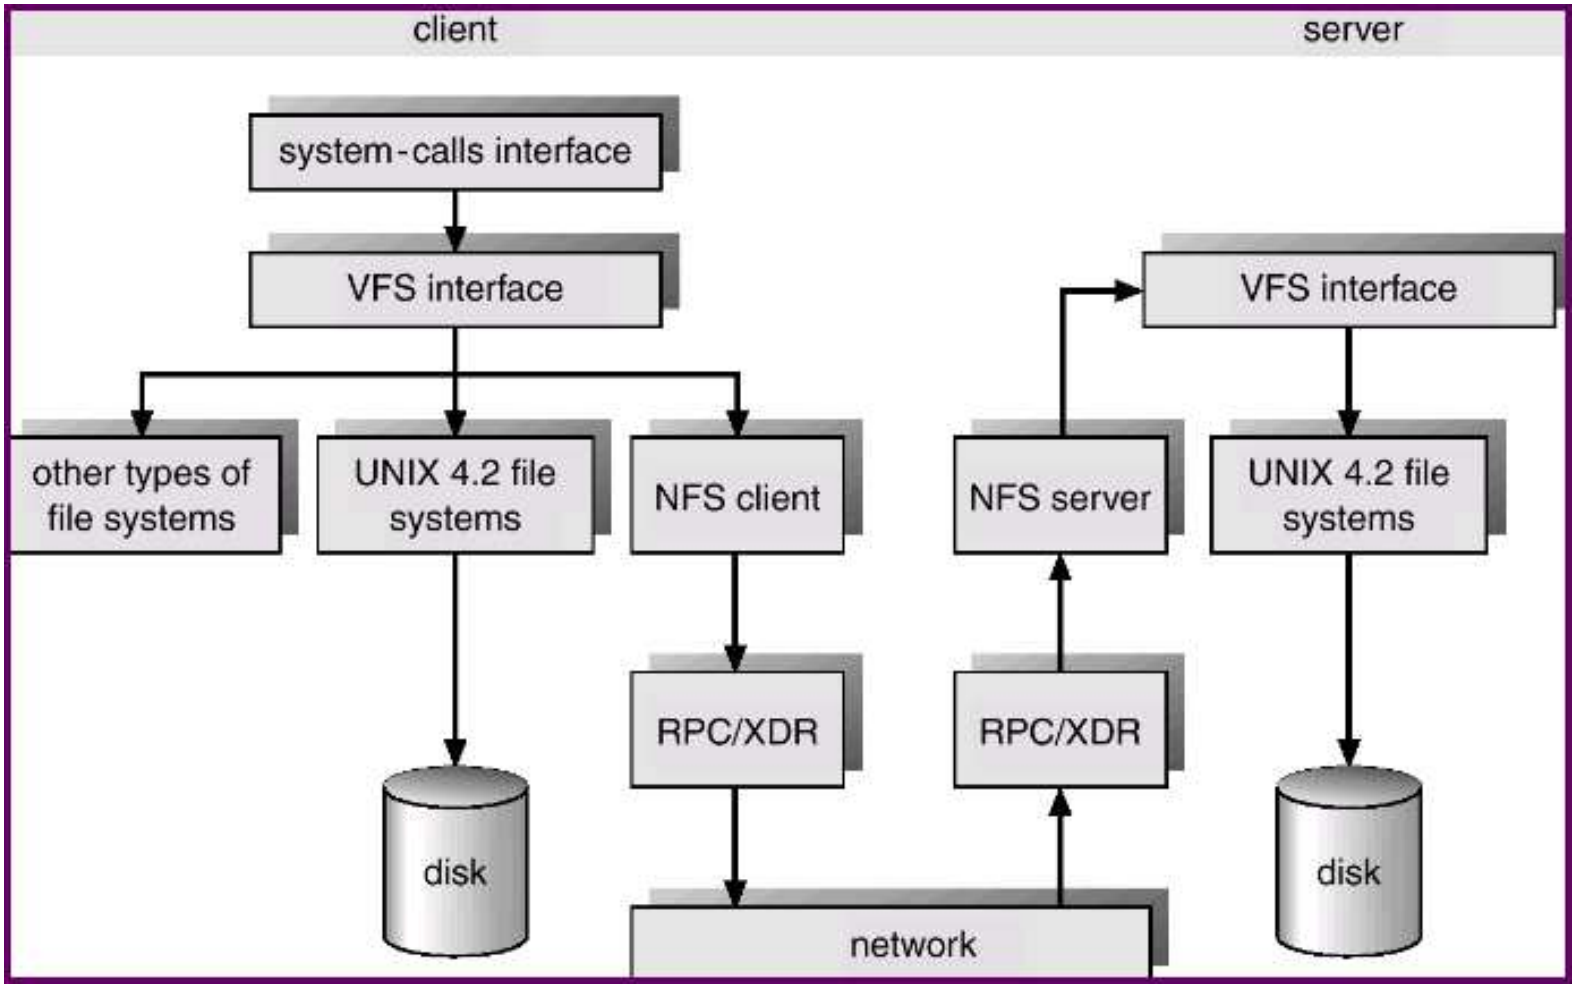

❖ Umožňuje kaskádování: lokální připojení vzdáleného adresářového systému do jiného vzdáleného adresářového systému.

❖ Autentizace často prostřednictvím uid a gid – pozor na bezpečnost!

❖ NFS verze 3:

- bezestavové – nepoužívá operace otevírání a uzavírání souborů, každá operace musí nést veškeré potřebné argumenty,
- na straně klienta se neužívá cache,
- nemá podporu zamykání.

❖ NFS verze 4:

- stavové,
- cache na straně klienta,
- podpora zamykání.

❖ Verze a další informace o použitém NFS: `nfsstat -s`.

Spooling

❖ Spooling = simultaneous peripheral operations on-line:

- v současné době hlavně u výstupních operací na pomalých periféríích (zejména tiskárny),
- paralelizace (a zdánlivé zrychlení) operací na periferiích, které přímo paralelizaci nepodporují.

❖ spool = vyrovnávací paměť (typicky soubor).

❖ Výstup je proveden do souboru, požadavek na jeho fyzické zpracování se zařadí do fronty, proces, který tiskl, může pokračovat a zpracování dat provede systém, až ně přijde řada.

❖ V Unixu/Linuxu: `/var/spool`.

Operační systémy

IOS 2020/2021

Tomáš Vojnar

vojnar@fit.vutbr.cz

Vysoké učení technické v Brně
Fakulta informačních technologií
Božetěchova 2, 612 66 Brno

Správa procesů

❖ Správa procesů (process management) zahrnuje:

- přepínání kontextu (dispatcher) – fyzické odebírání a přidělování procesoru na základě rozhodnutí plánovače,
- plánovač (scheduler) – rozhoduje, který proces (procesy) poběží a případně, jak dlouho,
- správu paměti (memory management) – přiděluje paměť,
- podporu meziprocesové komunikace (IPC) – signály, RPC, ...

Proces

- Proces = běžící program.

- Proces je v OS definován:
  - identifikátorem (PID),
  - stavem jeho plánování,
  - programem, kterým je řízen,
  - obsahem registrů (včetně EIP a ESP apod.),
  - zásobníkem – rozpracované funkce,
  - daty: statická inicializovaná a neinicializovaná data, hromada, individuálně alokované úseky paměti,
  - využitím dalších zdrojů OS a vazbami na další objekty OS: otevřené soubory, signály, PPID, UID, GID, semafory, sdílená paměť, sdílené knihovny, ...

Stavy plánování a jejich změny

❖ Běžně se rozlišují (různě přejmenované a případně zjemněné) následující stavy procesů:

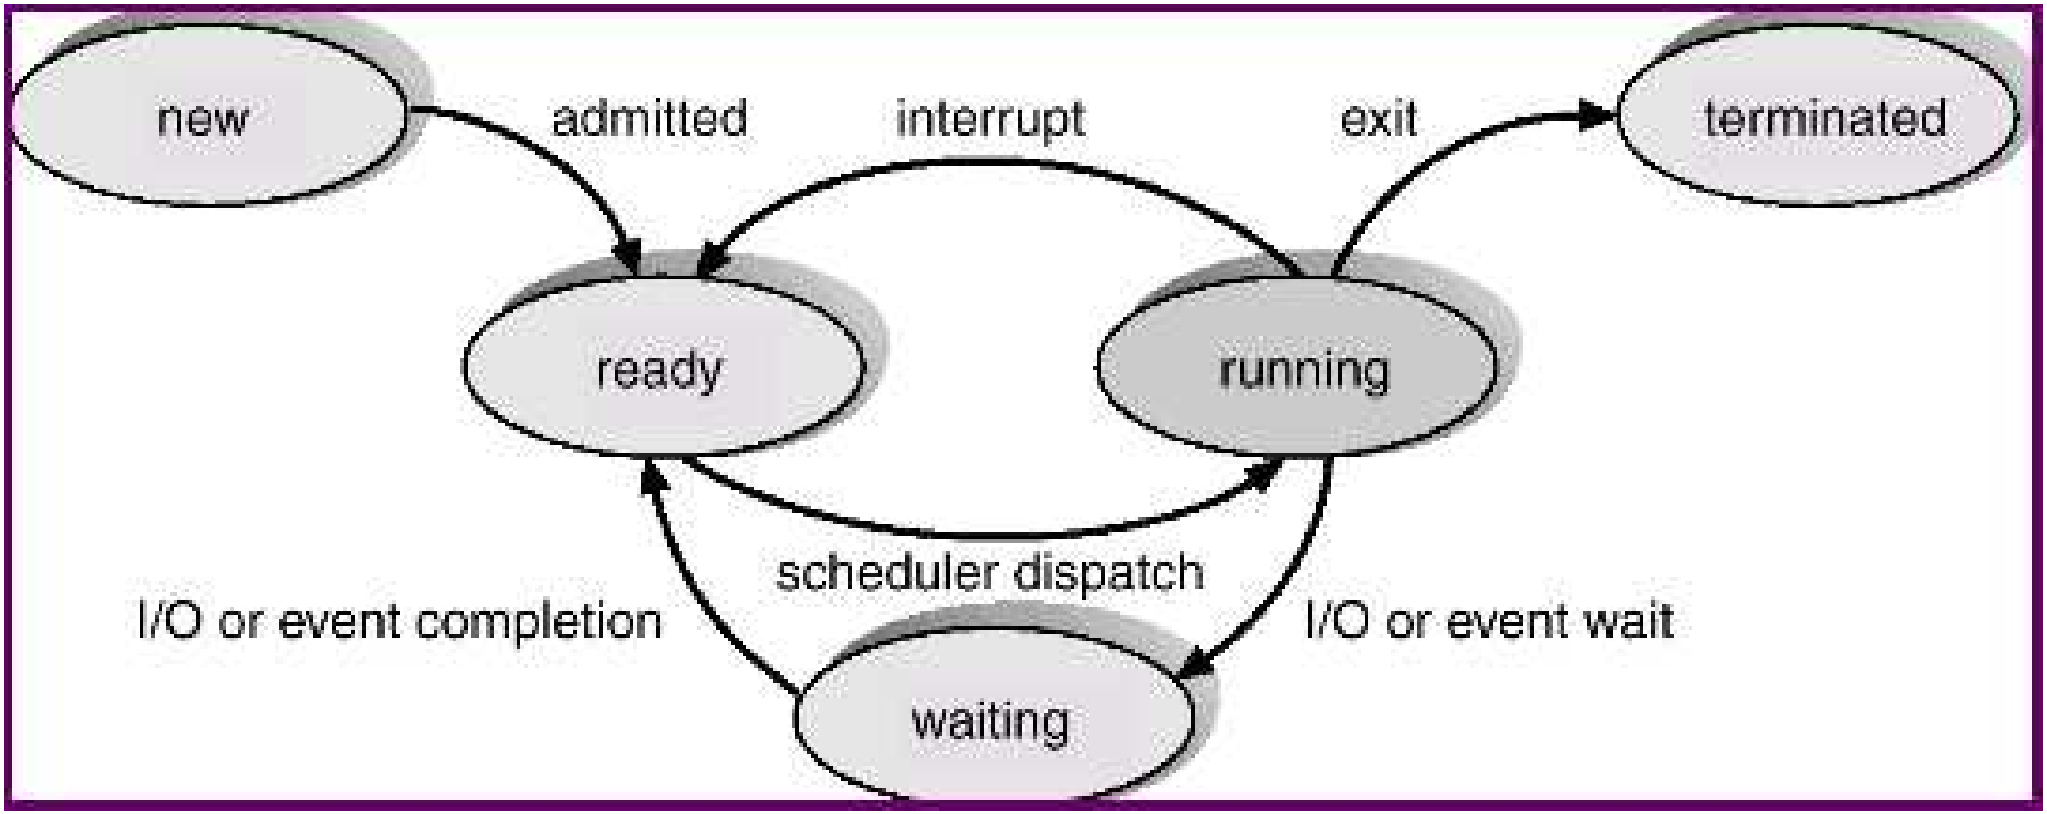

❖ Stavy plánování procesu v Unixu:

stav	význam
Vytvořený	ještě neinicializovaný
Připravený	mohl by běžet, ale nemá CPU
Běžící	používá CPU
Mátoha	po `exit`, rodič ještě nepřevzal exit-code
Čekající	čeká na událost (např. dokončení `read`)
Odložený	"zmrazený"signálem `SIGSTOP`

❖ Přechodový diagram stavů plánování procesu v Unixu:

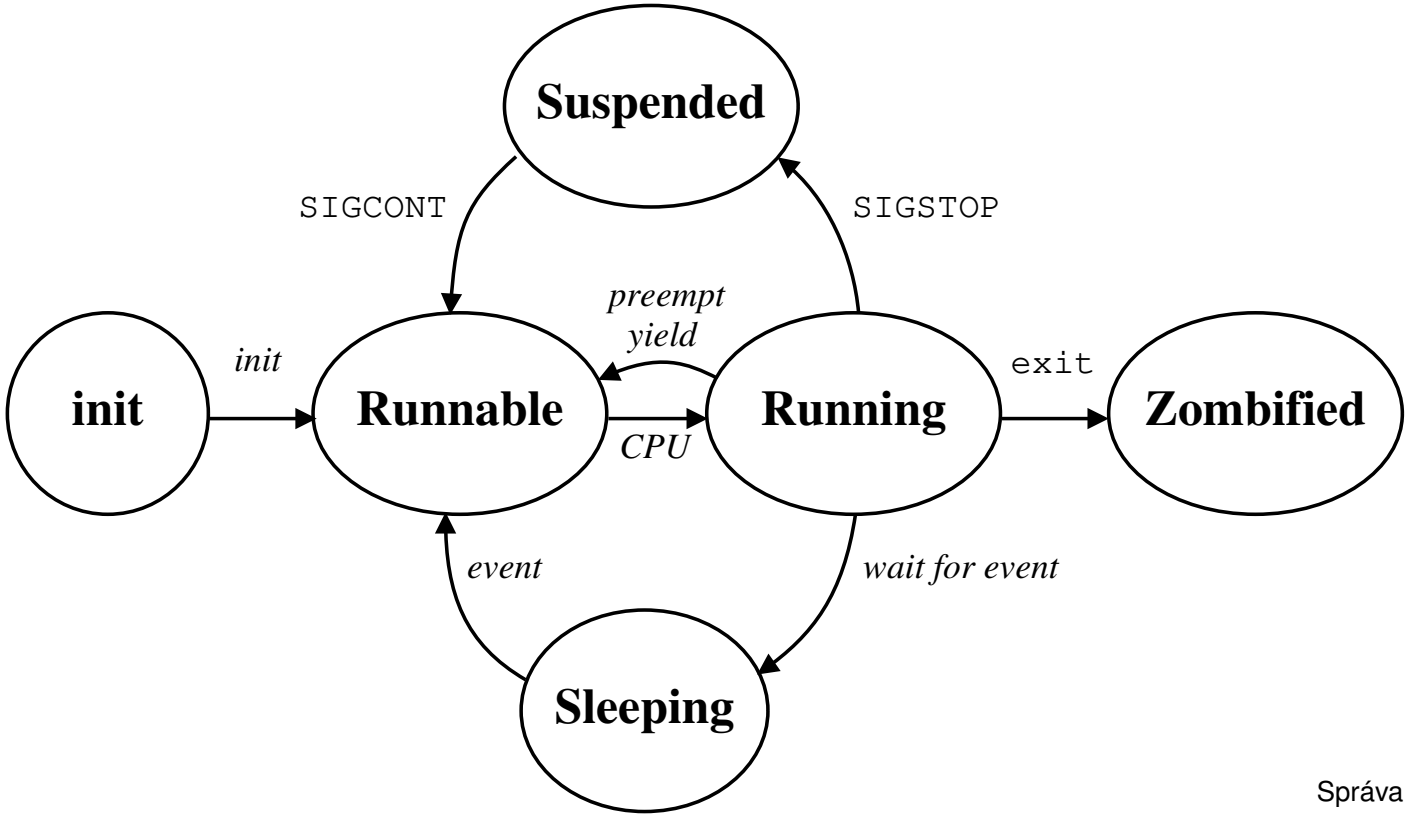

❖ V OS bývá proces reprezentován strukturou označovanou jako PCB (Process Control Block) nebo též *task control block* či *task struct* apod.

❖ PCB zahrnuje (buď přímo, nebo aspoň odkazuje na):

- identifikátory spojené s procesem,
- stav plánování procesu,
- obsah registrů (včetně EIP a ESP apod.),
- plánovací informace (priorita, ukazatele na plánovací fronty, ...),
- informace spojené se správou paměti (tabulky stránek, ...),
- informace spojené s účtováním (spotřeba procesoru, ...),
- využití I/O zdrojů (otevřené soubory, používaná zařízení, ...).

❖ PCB může být někdy rozdělen do několika dílčích struktur.

Části procesu v paměti v Unixu

- Uživatelský adresový prostor (user address space) přístupný procesu:
  - kód (code area/text segment),
  - data (inicializovaná/neinicializovaná data, hromada, individuálně alokovaná paměť),
  - zásobník,
  - soukromá data sdílených knihoven, sdílené knihovny, sdílená paměť.
- Uživatelská oblast (user area) – ne vždy použita:
  - Uložena zvlášť pro každý proces spolu s daty, kódem a zásobníkem v user address space příslušného procesu (s nímž může být odložena na disk).
  - Je ale přístupná pouze jádru.
  - Obsahuje část PCB, která je používána zejména za běhu procesu:
    - PID, PPID, UID, EID, GID, EGID,
    - obsah registrů,
    - deskriptory souborů,
    - obslužné funkce signálů,
    - účtování (spotřebovaný čas CPU, ...),
    - pracovní a kořenový adresář, ...

❖ Záznam v tabulce procesů (process table):

- Uložen trvale v jádru.
- Obsahuje zejména informace o procesu, které jsou důležité, i když proces neběží:
  - PID, PPID, UID, EID, GID, EGID,
  - stav plánování,
  - událost, na kterou se čeká,
  - plánovací informace (priorita, spotřeba času, ...),
  - čekající signály,
  - odkaz na tabulku paměťových regionů procesu,
  - ...

❖ Tabulka paměťových regionů procesu (per-process region table) – popis paměťových regionů procesu (spojitá oblast virtuální paměti použitá za určitým účelem: data, kód, zásobník, sdílenou paměť) + příslušné položky tabulky regionů, tabulka stránek.

❖ Zásobník jádra využívaný za běhu služeb jádra pro daný proces.

Kontext procesu

- Někdy se též používá pojem kontext procesu = stav procesu.

- Rozlišujeme:
  - uživatelský kontext (user-level context): kód, data, zásobník, sdílená data,
  - registrový kontext,
  - systémový kontext (system-level context): uživatelská oblast, položka tabulky procesů, tabulka paměťových regionů procesu, ...

Systémová volání nad procesy v Unixu

- Systémová volání spojená s procesy v Unixu:
  - `fork`, `exec`, `exit`, `wait`, `waitpid`,
  - `kill`, `signal`,
  - `getpid`, `getppid`,
  - ...
- Identifikátory spojené s procesy v UNIXu:
  - identifikace procesu PID,
  - identifikace předka PPID,
  - reálný (skutečný) uživatel, skupina uživatelů UID, GID,
  - efektivní uživatel, skupina uživatelů EUID, EGID,
  - uložená EUID, uložená EGID – umožňuje dočasně snížit efektivní práva a pak se k nim vrátit (při zpětném nastavení se kontroluje, zda se proces vrací k reálnému ID nebo k uloženému EUID),
  - v Linuxu navíc FSUID a FSGID (pro přístup k souborům se zvýšenými privilegii),
  - skupina procesů a sezení, do kterých proces patří – PGID, SID.

Vytváření procesů

❖ Vznik procesů v UNIXu – služba `fork`: duplikuje proces na takřka identického potomka:

- dědí řídící kód, data, zásobník, sdílenou paměť, otevřené soubory, obsluhu signálů, většinu synchronizačních prostředků, ...;
  - Pro efektivitu používá pro práci s pamětí copy-on-write.
- liší se v návratovém kódu `fork`, identifikátorech, údajích spojených s plánováním a účtováním (spotřeba času, ...), nedědí čekající signály, souborové zámky a některé další specilizované zdroje a nastavení.

```
pid=fork();
if (pid==0) {
    // kód pro proces potomka
    // exec(....), exit(exitcode)
} else if (pid==-1) {
    // kód pro rodiče, nastala chyba při fork()
    // errno obsahuje bližší informace
} else {
    // kód pro rodiče, pid = PID potomka
    // pid2 = wait(&stav);
}
```

❖ Vzniká vztah rodič–potomek (parent–child) a hierarchie procesů.

Hierarchie procesů v Unixu

❖ Předkem všech uživatelských procesů je init s PID=1.

❖ Pokud procesu skončí předek, jeho předkem se automaticky stane init, který později převezme jeho návratový kód (proces nemůže definitivně skončit a jako zombie čeká, dokud neodevzdá návratový kód).

❖ Výpis stromu procesů: např. `pstree`.

❖ Existují procesy jádra (kernel processes/threads), jejichž předkem init není:

- Jejich kód je součástí jádra, běží v režimu jádra.
- Vyskytuje se i proces s PID=0 s různými rolemi: podíl na inicializaci jádra, následně swapper (FreeBSD) či idle smyčka (Linux, nevypisuje se).
- Na Linuxu existuje process jádra kthreadd, který spouští ostatní procesy jádra a je jejich předkem.
- Vztahy mezi procesy jádra nejsou příliš významné a mohou se lišit.

Změna programu – `exec`

❖ Skupina funkcí:

- `execve` – základní volání,
- `execl`, `execlp`, `execle`, `execv`, `execvp`.
- `execl("/bin/ls", "ls", "-l", NULL);`
  – spouštěný program a jeho argumenty odpovídající `$0`/`argv[0]`, `$1`/`argv[1]`, ...

❖ Nevrací se, pokud nedojde k chybě!

❖ Procesu zůstává řada jeho zdrojů a vazeb v OS (identifikátory, otevřené soubory, ...), zanikají vazby a zdroje vázané na původní řídící kód (obslužné funkce signálů, sdílená paměť, paměťově mapované soubory, semafory).

❖ Windows: `CreateProcess(...)` – zahrnuje funkčnost `fork` i `exec`.

Čekání na potomka – `wait, waitpid`

- Systémové volání `wait` umožňuje pasivní čekání na potomka.
  - Vrací PID ukončeného procesu (nebo -1: příchod signálu, neexistence potomků).
  - Přes argument zpřístupňuje návratový kód potomka.
  - Pokud nějaký potomek je již ukončen a čeká na předání návratového kódu, končí okamžitě.

- Obecnější je systémové volání `waitpid`:
  - Umožňuje čekat na určitého potomka či potomka z určité skupiny.
  - Umožňuje čekat i na pozastavení či probuzení z pozastavení příjmem signálu.

Start systému

- Typická posloupnost akcí při startu systému:
  1. Firmware (BIOS/UEFI).
  2. Načtení a spuštění zavaděče OS, někdy v několika fázích (např. BIOS využívá kód v MBR a následně v dalších částech disku).
  3. Načtení jádra, spuštění jeho inicializační funkcí.
  4. Inicializační funkce jádra mj. vytvoří proces jádra 0, ten vytvoří případné další procesy jádra a proces *init*.
  5. *init* (systemd) načítá inicializační konfigurace a spouští další procesy.
     - V určitém okamžiku spustí *gdm*/*sddm*/*lightdm*/... pro přihlášení v grafickém režimu: z něj či z něj notifikovaných spolupracujících procesů se pak spouští další procesy pro práci pod X Window.
     - Na konzolích spustí *getty*, který umožní zadat přihlašovací jméno a změní se na *login*. Ten načte heslo a změní se na shell, ze kterého se spouští další procesy. Po ukončení se na terminálu spustí opět *getty*.
     - Proces *init* i nadále běží, přebírá návratové kódy procesů, jejichž rodič již skončil a řeší případnou reinicializaci systému či jeho částí při výskytu různých nakonfigurovaných událostí nebo na přání uživatele.

Úrovně běhu

- V UNIXu System V byl zaveden systém úrovní běhu – SYSV init run-levels: 0-6, s/S (0=halt, 1=single user, s/S=alternativní přechod do single user, 6=reboot).
- Změna úrovně běhu: `telinit N`.
- Konfigurace:
  - Adresáře */etc/rcX.d* obsahují odkazy na skripty spouštěné při vstupu do určité úrovně. Spouští se v pořadí daném jejich jmény, skripty se jménem začínajícím *K* s argumentem *stop*, skripty se jménem začínajícím *S* s parametrem *start*.
  - Vlastní implementace v adresáři */etc/init.d*, lze spouštět i ručně (např. také s argumentem *reload* či *restart* – reinicializace různých služeb, např. sítě).
  - Soubor */etc/inittab* obsahuje hlavní konfigurační úroveň: např. implicitní úroveň běhu, odkaz na skript implementující výše uvedené chování, popis akcí při mimořádných situacích, inicializace konzolí apod.
- Existují různé nové implementace procesu *init* – např. systemd:
  - Úrovně běhu nahrazují jednotky (units) různých typů (služby, sockets, přípojné body, ...): `/lib/systemd/`, `/usr/lib/systemd/`, ...
  - Spouští inicializační jednotky paralelně na základě jejich závislostí.
  - Emuluje úrovně běhu.

Plánování procesů

❖ Plánovač rozhoduje, který proces (procesy) poběží a případně, jak dlouho.

❖ Nepreemptivní plánování: ke změně běžícího procesu může dojít pouze tehdy, pokud to běžící proces umožní předáním řízení jádru tím, že požádá o službu:

- typicky I/O operace, konec – volání `exit`, vzdání se procesoru – volání `yield`.

❖ Preemptivní plánování: mimo výše uvedené může navíc ke změně běžícího procesu dojít, aniž by tento jakkoliv přepnutí kontextu napomohl, a to na základě přerušení:

- typicky od časovače, ale může se jednat i o jiné přerušení (např. disk, ...).

❖ Vlastní přepnutí kontextu řeší na základě rozhodnutí plánovače tzv. dispečer.

❖ Plánování může být též ovlivněno systémem swapování rozhodujícím o tom, kterým procesům je přidělena paměť, aby mohly běžet, případně systémem spouštění nových procesů, který může spuštění procesů odkládat na vhodný okamžik.

- V těchto případech někdy hovoříme o střednědobém a dlouhodobém plánování.

Přepnutí procesu (kontextu)

❖ Dispečer odebere procesor procesu A a přidělí ho procesu B, což typicky zahrnuje:

- úschovu stavu (některých) registrů (včetně různých řídicích registrů) v rámci procesu A do PCB,
- úpravu některých řídicích struktur v jádře,
- obnovu stavu (některých) registrů v rámci procesu B z PCB,
- předání řízení na adresu, kde bylo dříve přerušeno provádění procesu B.

❖ Neukládá se/neobnovuje se celý stav procesů: např. se uloží jen ukazatel na tabulku stránek, tabulka stránek a vlastní obsah paměti procesu může zůstat.

❖ Přepnutí trvá přesto typicky stovky až tisíce instrukcí: interval mezi přepínámím musí být tedy volen tak, aby režie přepnutí nepřevážila běžný běh procesů.

Klasické plánovací algoritmy

❖ Klasické plánovací algoritmy uvedené níže se používají přímo, případně v různých modifikacích a/nebo kombinacích.

❖ FCFS (First Come, First Served):

- Procesy čekají na přidělení procesoru ve FIFO frontě.
- Při vzniku procesu, jeho uvolnění z čekání (na I/O, synchronizaci apod.), nebo vzdá-li se proces procesoru, je tento proces zařazen na konec fronty.
- Procesor se přiděluje procesu na začátku fronty.
- Algoritmus je nepreemptivní a k přepnutí kontextu dojde pouze tehdy, pokud se běžící proces vzdá procesoru (voláním služeb např. pro I/O, konec, dobrovolné vzdání se procesoru – volání `yield`, Linux: `sched_yield`).

❖ Round-robin – preemptivní obdoba FCFS:

- Pracuje podobně jako FCFS, navíc má ale každý proces přiděleno časové kvantum, po jehož vypršení je mu odebrán procesor a proces je zařazen na konec fronty připravených procesů.

Klasické plánovací algoritmy

- SJF (Shortest Job First):
  - Přiděluje procesor procesu, který požaduje nejkratší dobu pro své další provádění na procesoru bez I/O operací – tzv. CPU burst.
  - Nepreemptivní algoritmus, který nepřerušuje proces před dokončením jeho aktuální výpočetní fáze.
  - Minimalizuje průměrnou dobu čekání, zvyšuje propustnost systému.
  - Nutno znát dopředu dobu běhu procesů na procesoru nebo mít možnost tuto rozumně odhadnout na základě předchozího chování.
  - Používá se pro opakovaně prováděné podobné úlohy, zejména ve specializovaných (např. dávkových) systémech.
  - Hrozí stárnutí (někdy též hladovění – starvation):
    - Stárnutí při přidělování zdrojů (procesor, zámek, ...) je obecně situace, kdy některý proces, který o zdroj žádá, na něj čeká bez záruky, že jej někdy získá.
    - V případě SJF hrozí hladovění procesů čekajících na procesor a majících dlouhé výpočetní fáze, které mohou být neustále předbíhány kratšími výpočty.
- SRT (Shortest Remaining Time): obdoba SJF s preempcí při vzniku či uvolnění procesu.

Klasické plánovací algoritmy

- Víceúrovňové plánování:
  - Procesy jsou rozděleny do různých skupin:
    – typicky podle priority, ale lze i jinak, např. dle typu procesu.
  - V rámci každé skupiny může být použit jiný dílčí plánovací algoritmus (např. FCFS či round-robin).
  - Je použit také algoritmus, který určuje, ze které skupiny bude vybrán proces, který má aktuálně běžet – často jednoduše na základě priority skupin.
  - Může hrozit hladovění některých (obvykle nízko prioritních) procesů.
- Víceúrovňové plánování se zpětnou vazbou:
  - Víceúrovňové plánování se skupinami procesů rozdělenými dle priorit.
  - Proces nově připravený běžet je zařazen do fronty s nejvyšší prioritou, postupně klesá do nižších prioritních front, nakonec plánován round-robin na nejnižší úrovni.
  - Používají se varianty, kdy je proces zařazen do počáteční fronty na základě své statické priority. Následně se může jeho dynamická priorita snižovat, spotřebovává-li mnoho procesorového času, nebo naopak zvyšovat, pokud hodně čeká na vstup/výstupních operacích.
    - Cílem je zajistit rychlou reakci interaktivních procesů.

Plánovač v Linuxu od verze 2.6.23

❖ Víceúrovňové prioritní plánovaní se 100 základními statickými prioritními úrovněmi, doplněné o rozlišování několika typů procesů:

- Priority 1–99 pro procesy reálného času plánované FCFS (doplněného o preempci na základě priorit) nebo round-robin.
- Priorita 0 pro běžné procesy plánované tzv. CFS plánovačem.
- V rámci úrovně 0:
  - jsou používány podúrovně v rozmezí -20 (nejvyšší) až 19 (nejnižší), nastavené uživatelem příkazy `nice` či `renice`;
  - rozlišuje se plánování pro běžné, dávkové (delší kvantum, jistá penalizace) a „idle“ procesy (zvláště nízká priorita).
- Základní prioritní úroveň a typ plánování mohou ovlivnit procesy s patřičnými právy: viz služba `sched_setscheduler`.
- Později přidáno plánování pro sporadické periodické úlohy s očekávanou dobou výpočetní fáze a časovým limitem, do kdy se má provést.
  - Založeno na strategii *earliest deadline first*.

Completely Fair Scheduler

❖ CFS (Completely Fair Scheduler):

- Snaží se explicitně každému procesu poskytnout odpovídající procento strojového času (dle jejich priorit).
- Vede si u každého procesu údaj o tom, kolik (virtuálního) procesorového času strávil.
- Navíc si vede údaj o minimálním stráveném procesorovém čase, který dává nově připraveným procesům.
- Procesy udržuje ve vyhledávací stromové struktuře podle využitého procesorového času (pro zajímavost: red-black strom).
- Vybírá jednoduše proces s nejmenším stráveným časem.
- Procesy nechává běžet po nějaké časové kvantum s rychlostí virtuálního času ovlivněnou prioritou (nižší prioritě běží virtuální čas rychleji) a pak je zařadí zpět do plánovacího stromu.
- Obsahuje podporu pro skupinové plánování: Může rozdělovat čas spravedlivě pro procesy spuštěné z různých terminálů (a tedy např. patřící různým uživatelům nebo u jednoho uživatele sloužící různým účelům).

Plánování ve Windows NT a novějších

- Víceúrovňové prioritní plánovaní se zpětnou vazbou na základě interaktivity:
  - 32 prioritních úrovní: 0 – nulování volných stránek, 1 – 15 běžné procesy, 16 – 31 procesy reálného času.
  - Základní priorita je dána staticky nastavenou kombinací plánovací třídy a plánovací úrovně v rámci třídy.
  - Systém může prioritu běžných procesů dynamicky zvyšovat či snižovat:
    - Zvyšuje prioritu procesů spojených s oknem, které se dostane na popředí.
    - Zvyšuje prioritu procesů spojených s oknem, do kterého přichází vstupní zprávy (myš, časovač, klávesnice, ...).
    - Zvyšuje prioritu procesů, které jsou uvolněny z čekání (např. na I/O operaci).
    - Zvýšená priorita se snižuje po každém vyčerpání kvanta o jednu úroveň až do dosažení základní priority.

Inverze priorit

❖ Problém inverze priorit:

- Nízko prioritní proces si naalokuje nějaký zdroj, více prioritní procesy ho předbíhají a nemůže dokončit práci s tímto zdrojem.
- Časem tento zdroj mohou potřebovat více prioritní procesy, jsou nutně zablokovány a musí čekat na nízko prioritní proces.
- Pokud v systému jsou v tomto okamžiku středně prioritní procesy, které nepotřebují daný zdroj, pak poběží a budou dále předbíhat nízko prioritní proces.
- Tímto způsobem uvedené středně a nízko prioritní procesy získávají efektivně vyšší prioritu.

❖ Inverze priorit nemusí, ale může, vadit: může zvyšovat odezvu systému a způsobit i vážnější problémy, zejména pokud jsou blokovány nějaké kritické procesy reálného času (ovládání hardware apod.).

Inverze priorit a další komplikace plánování

- Možnosti řešení inverze priorit:
  - Priority ceiling: procesy v kritické sekci získávají nejvyšší prioritu.
  - Priority inheritance: proces v kritické sekci, který blokuje výše prioritní procesy, dědí (po dobu běhu v kritické sekci) prioritu čekajícího procesu s největší prioritou.
  - Zákaz přerušení po dobu běhu v kritické sekci (na jednoprocesorovém systému): proces v podstatě získává vyšší prioritu než všichni ostatní.

- Další výraznou komplikaci plánování představují:
  - víceprocesorové systémy – nutnost vyvažovat výkon, respektovat obsah cache procesorů, příp. lokalitu pamětí (při neuniformním přístupu do paměti),
  - hard real-time systémy – nutnost zajistit garantovanou odezvu některých akcí.

Vlákna, úlohy, skupiny procesů

- Vlákno (thread):
  - „odlehčený proces“ (LWP – lightweight process), „podproces“,
  - jednotka výpočtu, kterých může v rámci procesu běžet více paralelně,
  - vlastní obsah registrů (včetně EIP a ESP) a zásobník,
  - sdílí kód, data a další zdroje (otevřené soubory, signály),
  - výhody – nižší režie: rychlejší spouštění, přepínání apod.

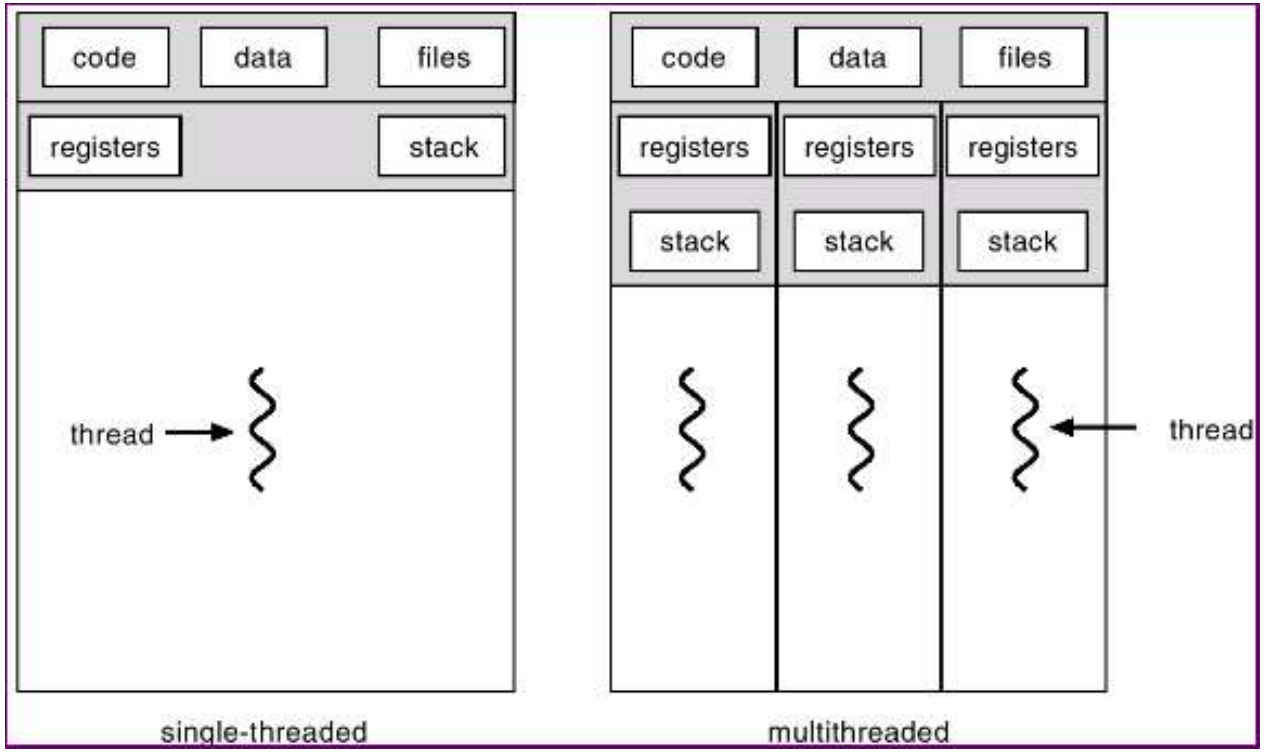

Úlohy, skupiny procesů, sezení

❖ Úloha (job) v bashi (a podobných shellech): skupina paralelně běžících procesů spuštěných jedním příkazem a propojených do kolony (pipeline).

❖ Skupina procesů (process group) v UNIXu:

- Množina procesů, které je možno poslat signál jako jedné jednotce. Předek také může čekat na dokončení potomka z určité skupiny (`waitpid`).
- Každý proces je v jedné skupině procesů, po vytvoření je to skupina jeho předka.
- Skupina může mít tzv. vedoucího – její první proces, pokud tento neskončí (skupina je identifikována číslem procesu svého vedoucího).
- Zjišťování a změna skupiny: `getpgid`, `setpgid`.

❖ Sezení (session) v UNIXu:

- Každá skupina procesů je v jednom sezení. Sezení může mít vedoucího.
- Vytvoření nového sezení: `setsid`.
- Sezení může mít řídící terminál (`/dev/tty`).
- Jedna skupina sezení je tzv. na popředí (čte z terminálu), ostatní jsou na pozadí.
- O ukončení terminálu je signálem SIGHUP informován vedoucí sezení (typicky shell), který ho dále řeší – všem, na které nebyl užit nohup/disown, SIGHUP, pozastaveným navíc SIGCONT.

Komunikace procesů

- IPC = Inter-Process Communication:
  - signály (`kill`, `signal`, ...)
  - roury (`pipe`, `mknod p`, ...)
  - zprávy (`msgget`, `msgsnd`, `msgrcv`, `msgctl`, ...)
  - sdílená paměť (`shmget`, `shmat`, ...)
  - sockety (`socket`, ...)
  - RPC = Remote Procedure Call
  - ...

Signály

❖ Signál (v základní verzi) je číslo (`int`) zaslané procesu prostřednictvím pro to zvláště definovaného rozhraní. Signály jsou generovány

- při chybách (např. aritmetická chyba, chyba práce s pamětí, ...),
- externích událostech (vypršení časovače, dostupnost I/O, ...),
- na žádost procesu – IPC (`kill`, ...).

❖ Signály často vznikají asynchronně k činnosti programu – není tedy možné jednoznačně předpovědět, kdy daný signál bude doručen.

❖ Nutno pečlivě zvažovat obsluhu, jinak mohou vzniknout „záhadné“, zřídka se objevující a velice špatně laditelné chyby – mj. také motivace pro pokročilé testování (vkládání šumu, systematická enumerace prokládání do určité meze) a verifikaci s formálními základy (statická analýza, model checking).

❖ Mezi běžně používané signály patří:

- `SIGHUP` – odpojení, ukončení terminálu
- `SIGINT` – přerušení z klávesnice (`Ctrl-C`)
- `SIGKILL` – tvrdé ukončení
- `SIGSEGV`, `SIGBUS` – chybný odkaz do paměti
- `SIGPIPE` – zápis do roury bez čtenáře
- `SIGALRM` – signál od časovače (`alarm`)
- `SIGTERM` – měkké ukončení
- `SIGUSR1`, `SIGUSR2` – uživatelské signály
- `SIGCHLD` – pozastaven nebo ukončen potomek
- `SIGCONT` – pokračuj, jsi-li pozastaven
- `SIGSTOP`, `SIGTSTP` – tvrdé/měkké pozastavení

❖ Další signály – viz `man 7 signal`.

Předefinování obsluhy signálů

❖ Mezi implicitní (přednastavené) reakce na signál patří: ukončení procesu (příp. s generováním core dump), ignorování signálu, zmrazení/rozmrazení procesu.

❖ Lze předefinovat obsluhu všech signálů mimo `SIGKILL` a `SIGSTOP`. `SIGCONT` lze předefinovat, ale vždy dojde k odblokování procesu.

❖ K předefinování obsluhy signálů slouží funkce:

- `sighandler_t signal(int signum, sighandler_t handler);` kde `typedef void (*sighandler_t)(int);`
  - `handler` je ukazatel na obslužnou funkci, příp. `SIG_DFL` či `SIG_IGN`.
- `int sigaction(int signum, const struct sigaction *act, struct sigaction *oldact);`
  - komplexnější a přenosné nastavení obsluhy,
  - nastavení blokování signálů během obsluhy (jinak stávající nastavení + obsluhovaný signál),
  - nastavení režimu obsluhy (automatické obnovení implicitní obsluhy, ...),
  - nastavení obsluhy s příjmem dodatečných informací spolu se signálem.

❖ Z obsluhy signálu lze volat pouze vybrané bezpečné knihovní funkce: u ostatních hrozí nekonzistence při interferenci s rozpracovanými knihovními voláními.

Blokování signálů

❖ K nastavení masky blokovaných signálů lze užít:

- `int sigprocmask(int how, const sigset_t *set, sigset_t *oldset);`
- `how` je `SIG_BLOCK`, `SIG_UNBLOCK` či `SIG_SETMASK`.

❖ K sestavení masky signálů slouží `sigemptyset`, `sigfillset`, `sigaddset`, `sigdelset`, `sigismember`.

❖ Nelze blokovat: `SIGKILL`, `SIGSTOP`, `SIGCONT`.

❖ Nastavení blokování se dědí do potomků. Dědí se také obslužné funkce signálů, při použití `exec` se ovšem nastaví implicitní obslužné funkce.

❖ Zjištění čekajících signálů: `int sigpending(sigset_t *set);`

❖ Upozornění: Pokud je nějaký zablokovaný signál přijat vícekrát, zapamatuje se jen jedna instance! (Neplatí pro tzv. real-time signály.)

Zasílání signálů

❖ `int kill(pid_t pid, int sig);` umožňuje zasílat signály

- určitému procesu,
- skupině procesů – odesílatelovy či explictně zadané,
- všem procesům, kterým daný proces může signál poslat (mimo `init`, pokud nemá pro příslušný signál definovánu obsluhu).

❖ Aby proces mohl zaslat signál jinému procesu musí odpovídat jeho UID nebo EUID UID nebo saved set-user-ID cílového procesu (`SIGCONT` lze zasílat všem procesům v sezení – session), případně se musí jednat o privilegovaného odesílatele (např. EUID=0, nebo kapabilita `CAP_KILL`).

❖ Poznámka: `sigqueue` – zasílání signálu spolu s dalšími daty.

Čekání na signál

- Jednoduché čekání: `int pause(void);`
  - Nelze spolehlivě přepínat mezi signály, které mají být blokovány po dobu, kdy se čeká, a mimo dobu, kdy se čeká.

- Zabezpečené čekání: `int sigsuspend(const sigset_t *mask);`
  - Lze spolehlivě přepínat mezi signály blokovanými mimo a po dobu čekání.
  - `mask` jsou blokovány po dobu čekání, po ukončení se nastaví původní blokování.

❖ Příklad – proces spustí potomka a počká na signál od něj:

```
#include <signal.h>
#include <stdio.h>
#include <sys/types.h>
#include <unistd.h>

/* When a SIGUSR1 signal arrives, set this variable. */
volatile sig_atomic_t usr_interrupt = 0;

void synch_signal (int sig) {
  usr_interrupt = 1;
}

/* The child process executes this function. */
void child_function (void) {

  /* Let the parent know you're here. */
  kill (getppid (), SIGUSR1);

  exit(0);

}
```

❖ Pokračování příkladu – pozor na zamezení ztráty signálu mezi testem a čekáním:

```
int main (void) {
  struct sigaction usr_action;
  sigset_t block_mask, old_mask;
  pid_t pid;

  /* Establish the signal handler. */
  sigfillset (&block_mask);
  usr_action.sa_handler = synch_signal;
  usr_action.sa_mask = block_mask;
  usr_action.sa_flags = 0;
  sigaction (SIGUSR1, &usr_action, NULL);

  /* Create the child process. */
  if ((pid = fork()) == 0) child_function ();  /* Does not return. */
  else if (pid==-1) { /* A problem with fork - exit. */ }

  /* Wait for the child to send a signal */
  sigemptyset (&block_mask);
  sigaddset (&block_mask, SIGUSR1);
  sigprocmask (SIG_BLOCK, &block_mask, &old_mask);
  while (!usr_interrupt)
    sigsuspend (&old_mask);
  sigprocmask (SIG_UNBLOCK, &block_mask, NULL);
  ...
```